Lista1

Tadeusz Jagniewski

2025-11-21

Contents

1 Zadanie 3 **1**
1.1 podpunkt a 1
1.2 podpunkt b 3

2 Zadanie 4 **11**

1 Zadanie 3

1.1 podpunkt a

Generator realizacji szumu iid N(0,1), który jest kanonicznym przykładem białego szumu

```
gen_realizacji_szumu_iid <- function(n,k) {
  x <- matrix(rnorm(n*k),n,k)
  return(x)
}
```

Genetrator realizacji błądzenia losowego, który nie będzie białym szumem

```
gen_realizacji_bladzenia_losowego <- function(n, k) {
  kroki_macierz <- matrix(rnorm(n * k), nrow = n, ncol = k)

  bladzenie_macierz <- apply(kroki_macierz, 2, cumsum)

  return(bladzenie_macierz)
}
```

Na wykresie funkcji autokorelacji widzimy, że poza opóźnieniem 0 (gdzie ACF z definicji równa się 1), prawie wszystkie słupki dla dodatnich opóźnień mieszczą się w standardowych asymptotycznych przedziałach ufności $\pm 1.96/\sqrt{n}$ odpowiadających poziomowi istotności $\alpha = 0.05$. Otrzymany kształt ACF jest zgodny z tym, czego oczekujemy dla realizacji białego szumu. Na podstawie testu graficznego **nie ma podstaw do odrzucenia hipotezy, że szereg jest białym szumem.**

Dla 1000 realizacji o długości 50 empiryczna średnia częstość odrzucania H_0 o białoszumowości wynosi:

- dla testu Boxa-Pierce 0.026.
- dla testu Ljung-Box 0.069.

Obie otrzymane wartości są bliskie nominalnemu poziomowi istotności $\alpha = 0.05$, co oznacza, że przy danych parametrach symulacji oba testy zachowują się zgodnie z oczekiwaniami (empiryczny poziom testu jest zbliżony do poziomu zadeklarowanego).

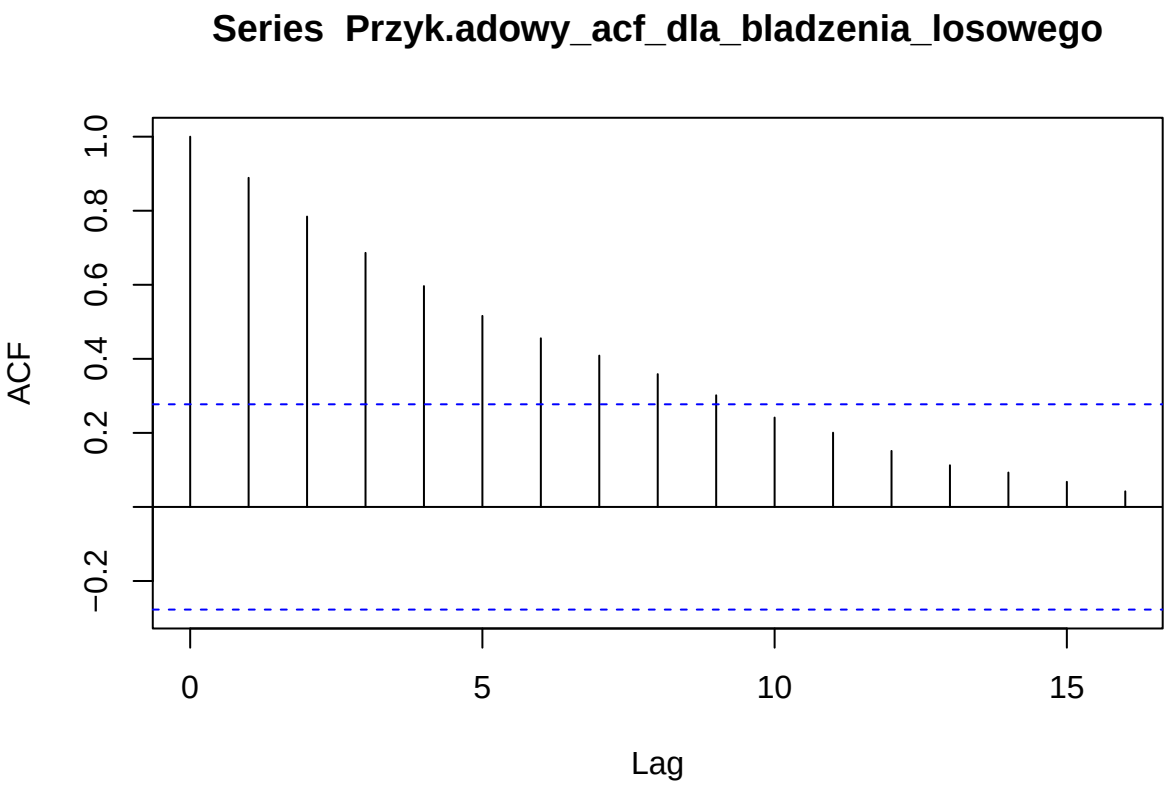

Na wykresie ACF dla błądzenia losowego widzimy bardzo wolno malejące, dodatnie autokorelacje dla wielu kolejnych opóźnień. Taki kształt jest typowy dla procesów z silną zależnością i wyraźnie odbiega od zachowania białego szumu, dla którego oczekujemy wartości bliskich 0 (poza opóźnieniem 0) i losowych wahań wokół zera. Mimo tego przeprowadzę testy Boxa–Pierce'a i Ljunga–Boxa przy poziomie istotności $\alpha = 0.05$, aby formalnie zweryfikować hipotezę o białoszumowości.

Dla 1000 realizacji błądzenia losowego o długości 50 empiryczna częstość odrzucania hipotezy H_0 o białoszumowości wynosi:

- dla testu Boxa-Pierce 0.998 .
- dla testu Ljung-Box 0.999 .

Obie wartości są bardzo bliskie 1, co oznacza, że testy praktycznie zawsze odrzucają hipotezę i że błądzenie losowe nie jest białym szumem. Jest to zgodne z teoretycznym faktem, że błądzenie losowe jest procesem silnie skorelowanym i niestacjonarnym, więc powinno być wyraźnie odróżnialne od białego szumu.

1.2 podpunkt b

W podpunkcie (b) przeprowadzam badania symulacyjne porównujące trzy podejścia do testowania białoszumowości: test graficzny oparty na funkcji autokorelacji oraz formalne testy Boxa–Pierce'a i Ljunga–Boxa. Dla każdego scenariusza symulacyjnego generowałem realizacje różnych procesów czasowych o długościach $n \in \{20, 50, 100, 250\}$, przy trzech wartościach maksymalnego opóźnienia $h_{max} \in \{5, 10, 20\}$ oraz różnych liczbach replikacji $R \in \{100, 500, 1000, 5000\}$. Na wykresach przedstawiono empiryczne częstości odrzucenia hipotezy zerowej H_0 w funkcji długości szeregu n, osobno dla każdego procesu, poziomu h_max oraz liczby realizacji R.

W badaniu uwzględniłem zarówno procesy zgodne z hipotezą H_0 (szum biały o rozkładzie normalnym oraz szum iid o rozkładzie t-Studenta), jak i procesy stanowiące alternatywę wobec białoszumowości: słabo skorelowany model MA(1) z parametrem $\theta = 0.3$, błądzenie losowe, szum z deterministycznym trendem liniowym oraz szum z narzuconą sezonowością sinusoidalną. Na każdym z wykresów słupki odpowiadają trzem testom

(graficznemu, Boxa–Pierce'a oraz Ljunga–Boxa), dzięki czemu możliwe jest jednoczesne porównanie ich zachowania dla różnych długości szeregów czasowych, różnych poziomów h_{max} oraz róznej liczbie realizacji R.

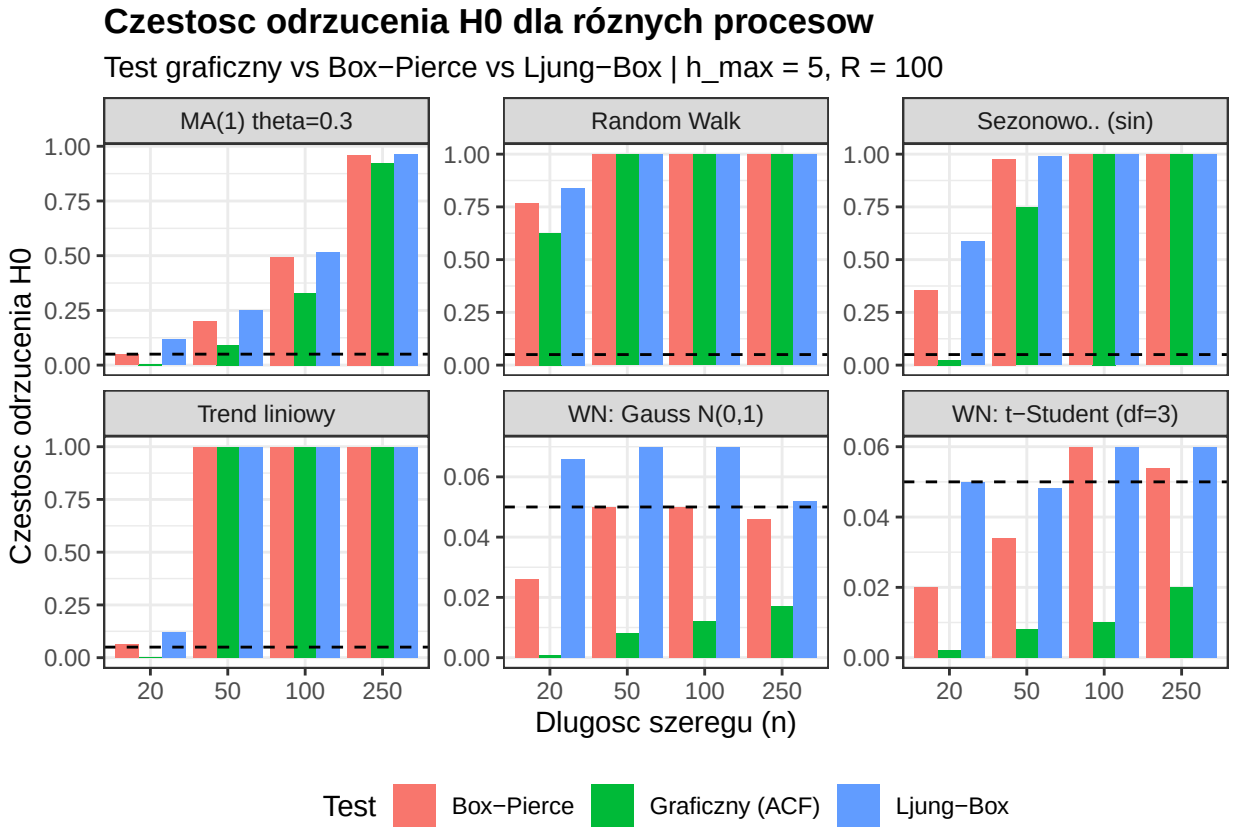

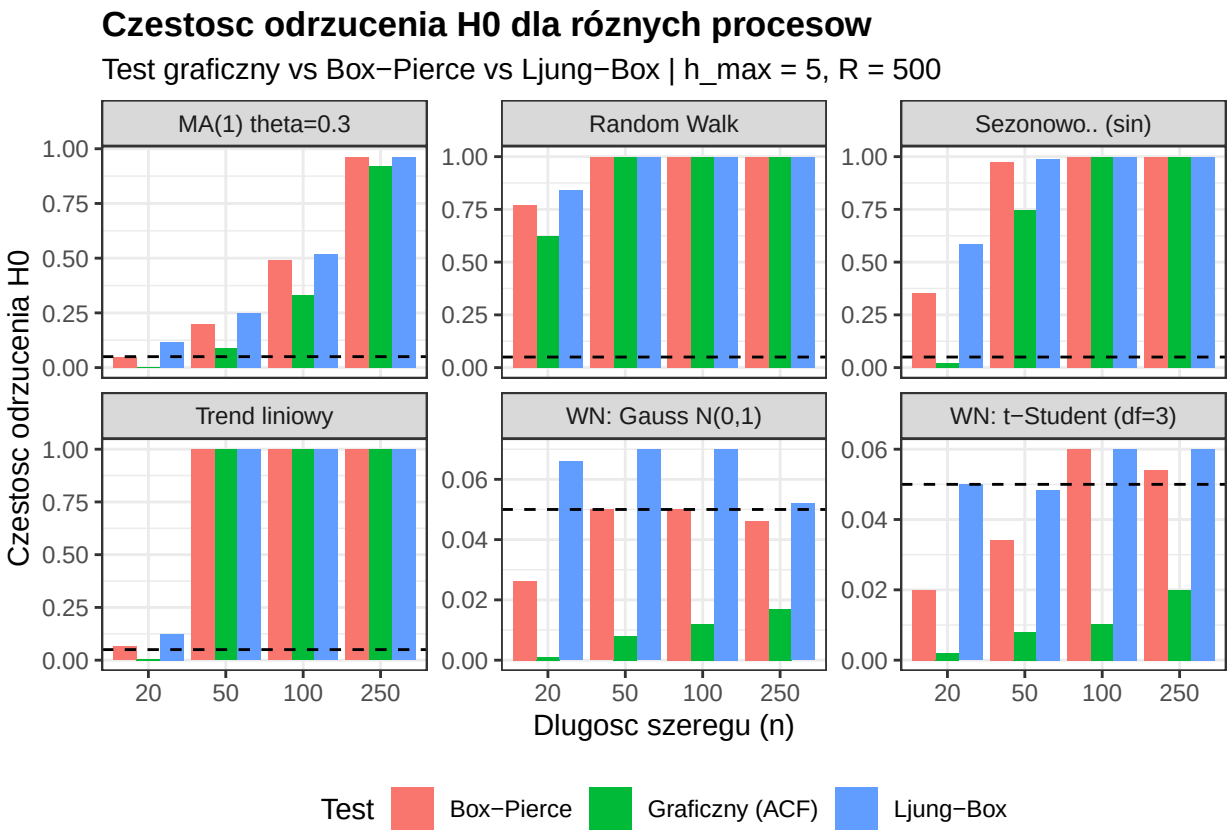
Czestosc odrzucenia H0 dla róznych procesow
Test graficzny vs Box−Pierce vs Ljung−Box | h_max = 5, R = 500
MA(1) theta=0.3
Random Walk
Sezonowo.. (sin)
Trend liniowy
WN: Gauss N(0,1)
WN: t−Student (df=3)
Czestosc odrzucenia H0
Dlugosc szeregu (n)
Test
Box−Pierce
Graficzny (ACF)
Ljung−Box

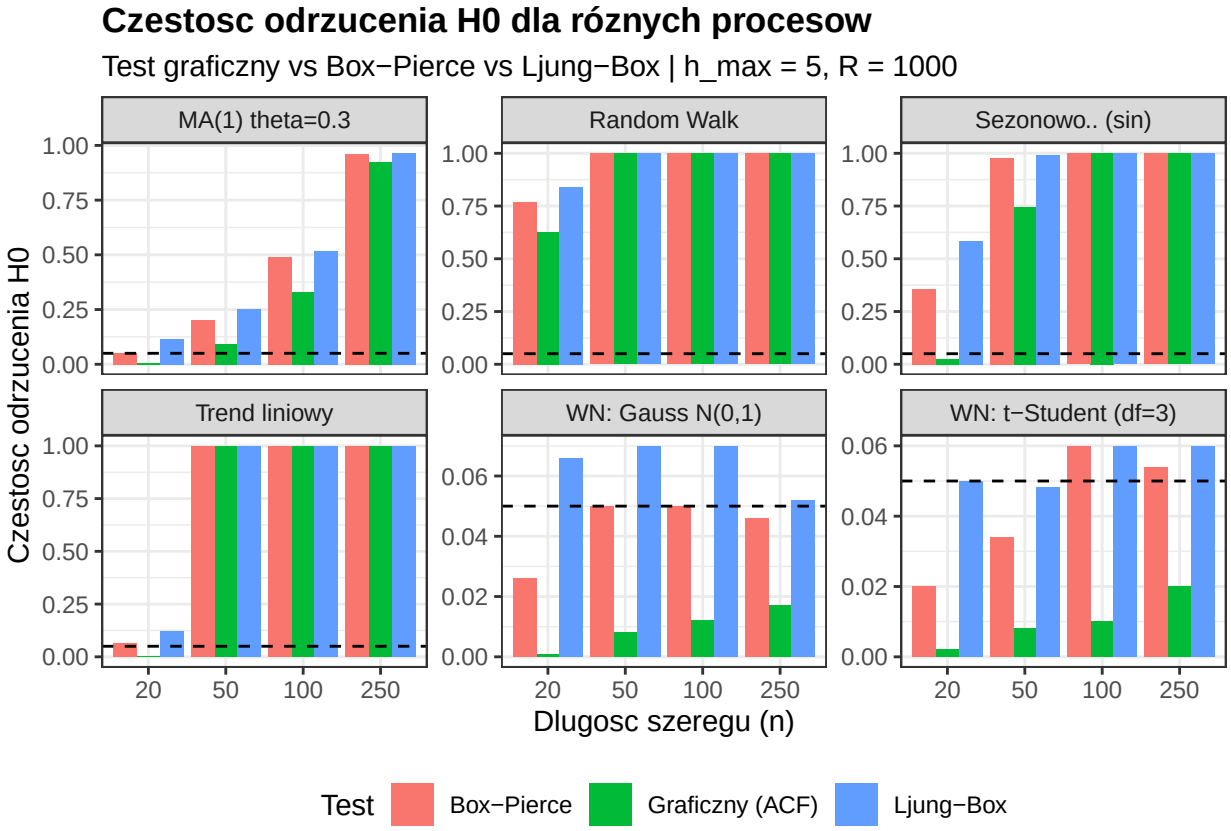
Czestosc odrzucenia H0 dla róznych procesow
Test graficzny vs Box−Pierce vs Ljung−Box | h_max = 5, R = 1000
MA(1) theta=0.3
Random Walk
Sezonowo.. (sin)
Trend liniowy
WN: Gauss N(0,1)
WN: t−Student (df=3)
Czestosc odrzucenia H0
Dlugosc szeregu (n)
Test
Box−Pierce
Graficzny (ACF)
Ljung−Box

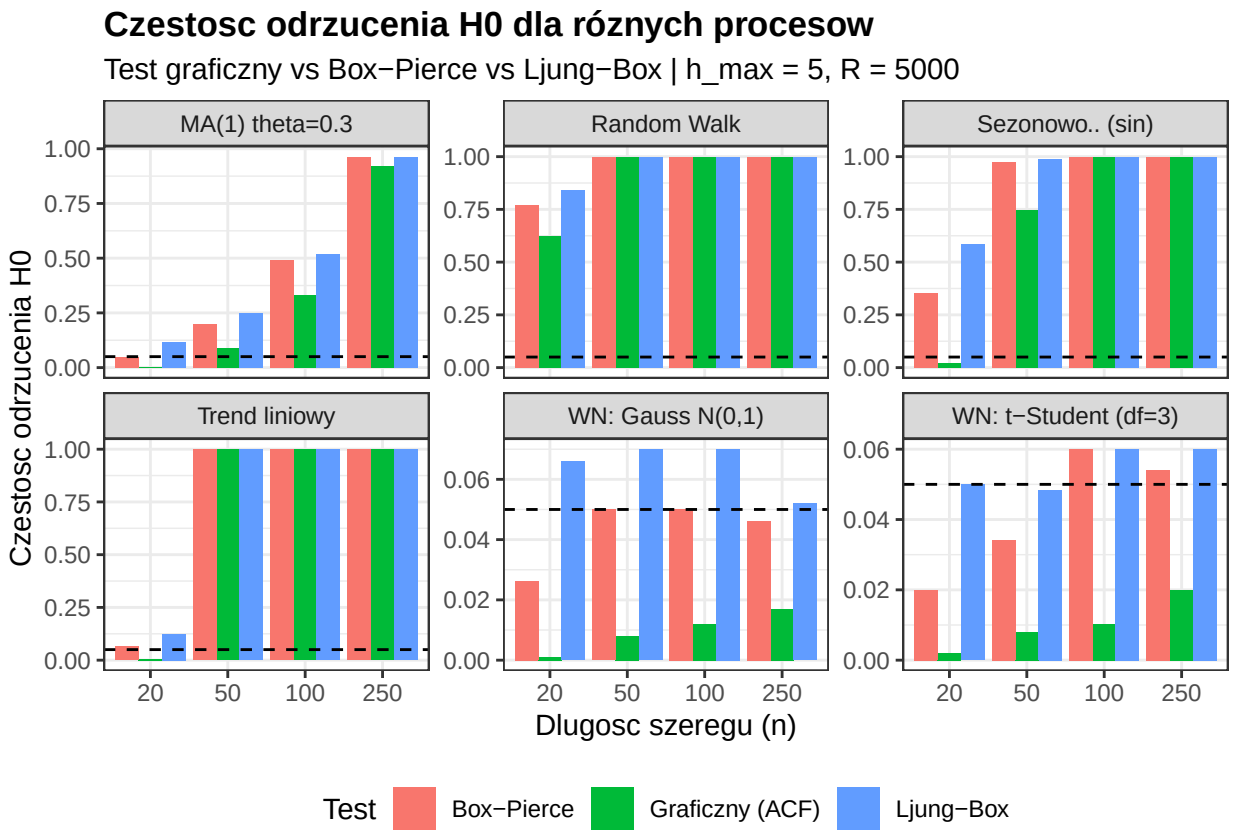
Czestosc odrzucenia H0 dla róznych procesow
Test graficzny vs Box−Pierce vs Ljung−Box | h_max = 5, R = 5000
MA(1) theta=0.3
Random Walk
Sezonowo.. (sin)
Trend liniowy
WN: Gauss N(0,1)
WN: t−Student (df=3)
Czestosc odrzucenia H0
Dlugosc szeregu (n)
Test
Box−Pierce
Graficzny (ACF)
Ljung−Box

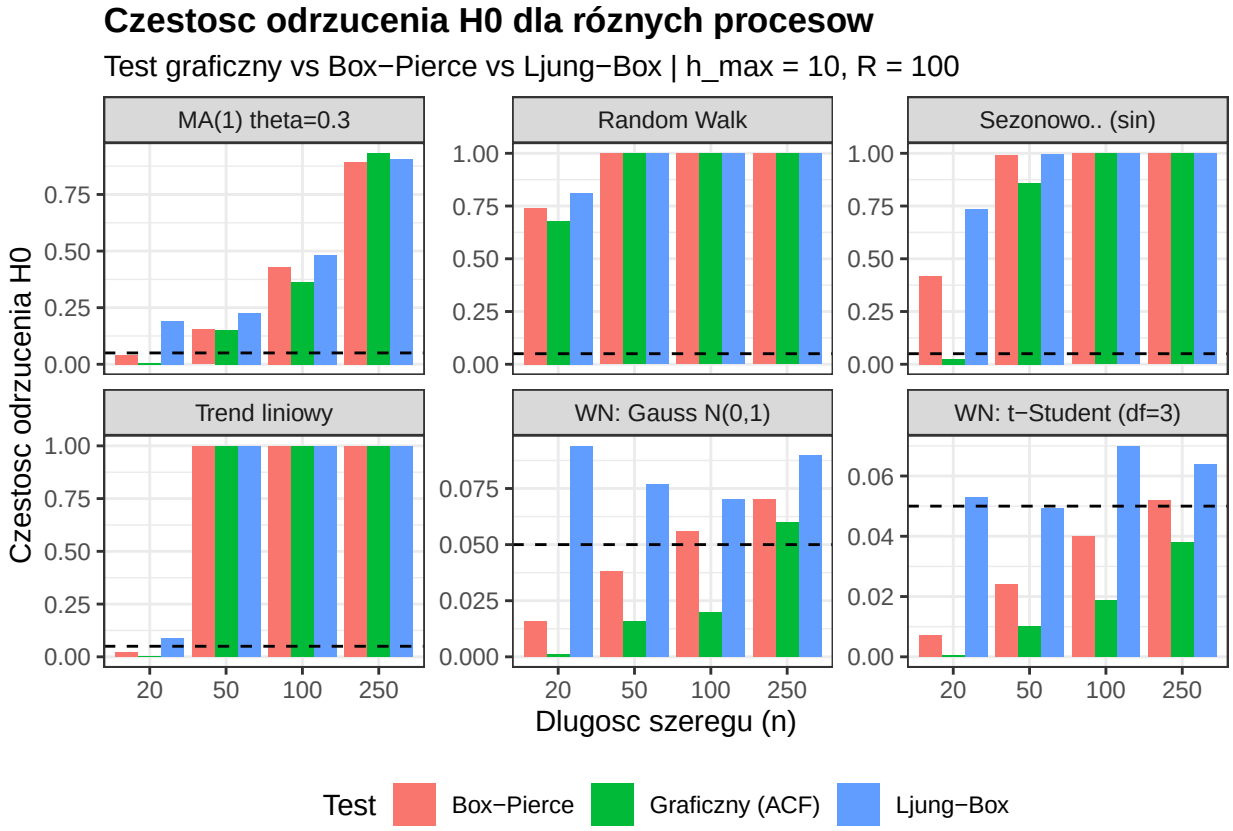
Czestosc odrzucenia H0 dla róznych procesow
Test graficzny vs Box−Pierce vs Ljung−Box | h_max = 10, R = 100
MA(1) theta=0.3
Random Walk
Sezonowo.. (sin)
Trend liniowy
WN: Gauss N(0,1)
WN: t−Student (df=3)
Czestosc odrzucenia H0
Dlugosc szeregu (n)
Test
Box−Pierce
Graficzny (ACF)
Ljung−Box

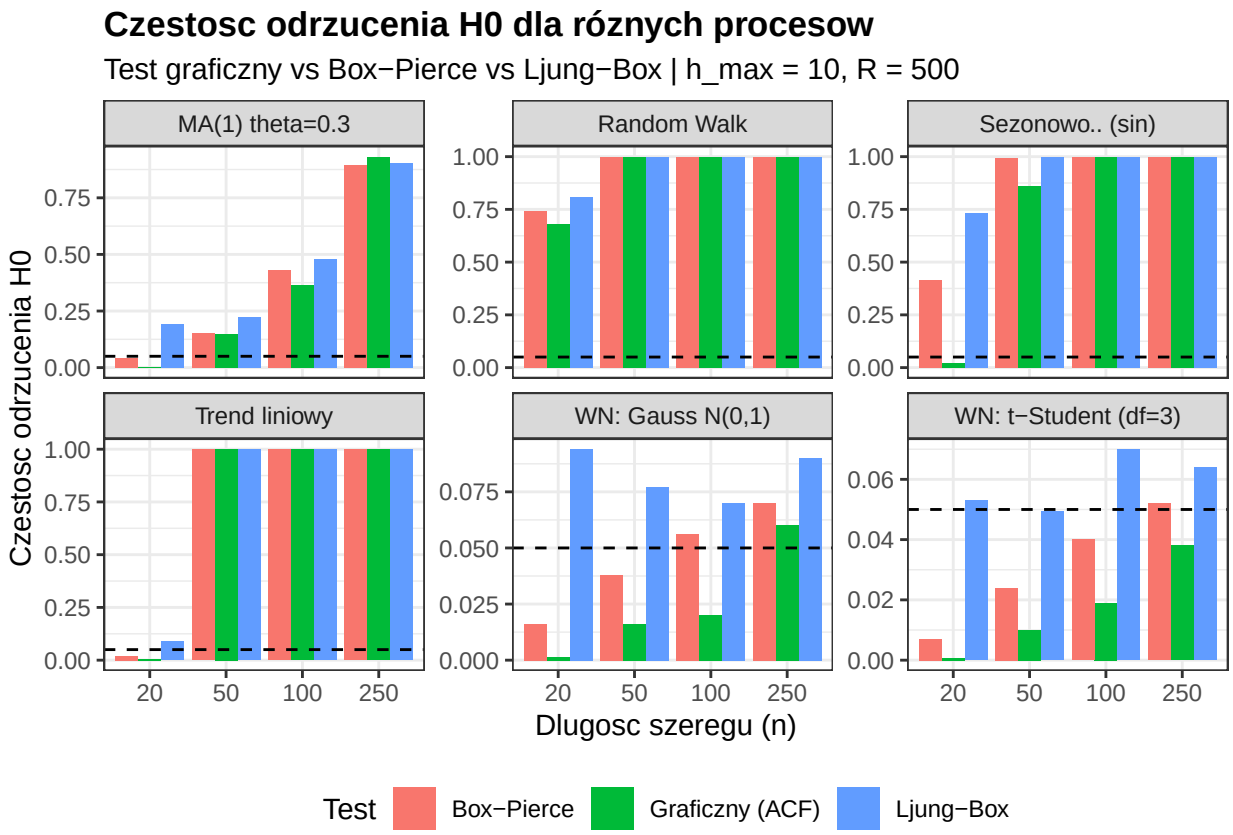
Czestosc odrzucenia H0 dla róznych procesow
Test graficzny vs Box−Pierce vs Ljung−Box | h_max = 10, R = 500
MA(1) theta=0.3
Random Walk
Sezonowo.. (sin)
Trend liniowy
WN: Gauss N(0,1)
WN: t−Student (df=3)
Czestosc odrzucenia H0
Dlugosc szeregu (n)
Test
Box−Pierce
Graficzny (ACF)
Ljung−Box

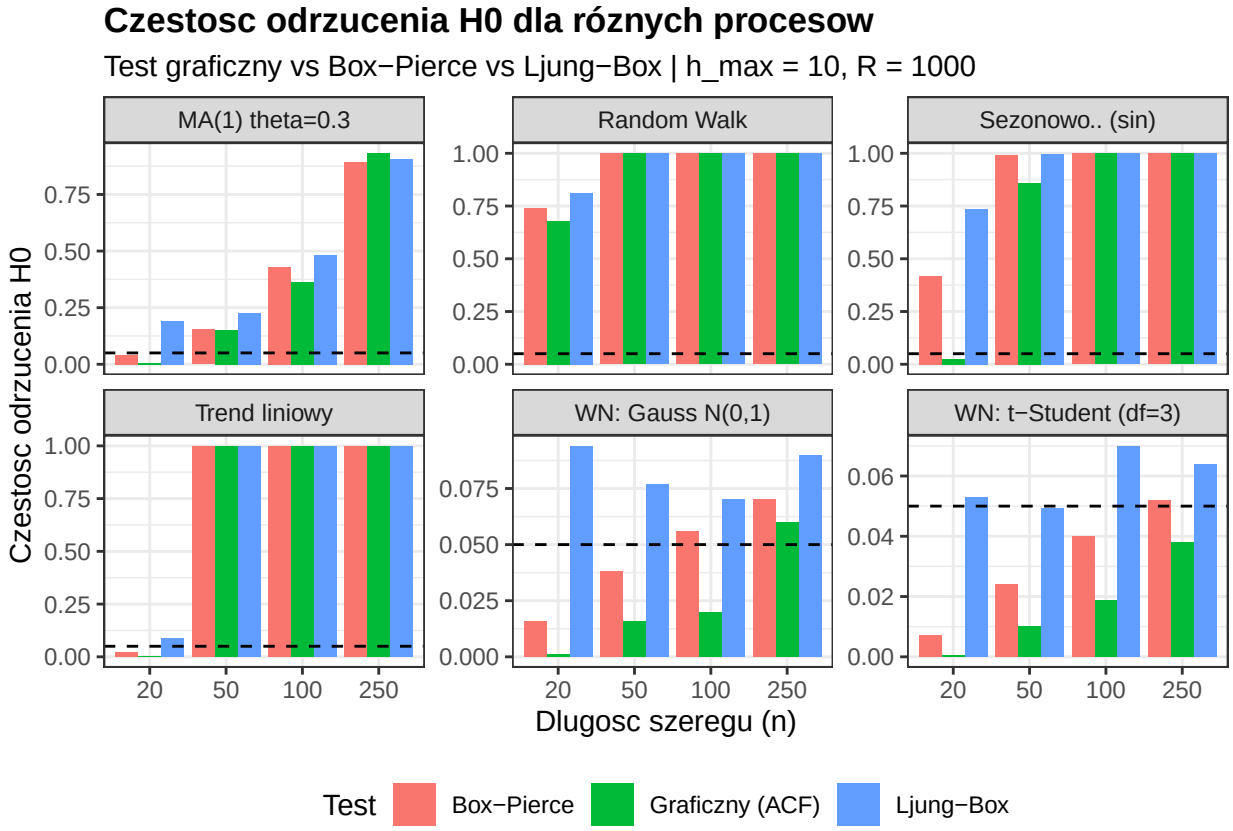
Czestosc odrzucenia H0 dla róznych procesow
Test graficzny vs Box−Pierce vs Ljung−Box | h_max = 10, R = 1000
MA(1) theta=0.3
Random Walk
Sezonowo.. (sin)
Trend liniowy
WN: Gauss N(0,1)
WN: t−Student (df=3)
Czestosc odrzucenia H0
Dlugosc szeregu (n)
Test
Box−Pierce
Graficzny (ACF)
Ljung−Box

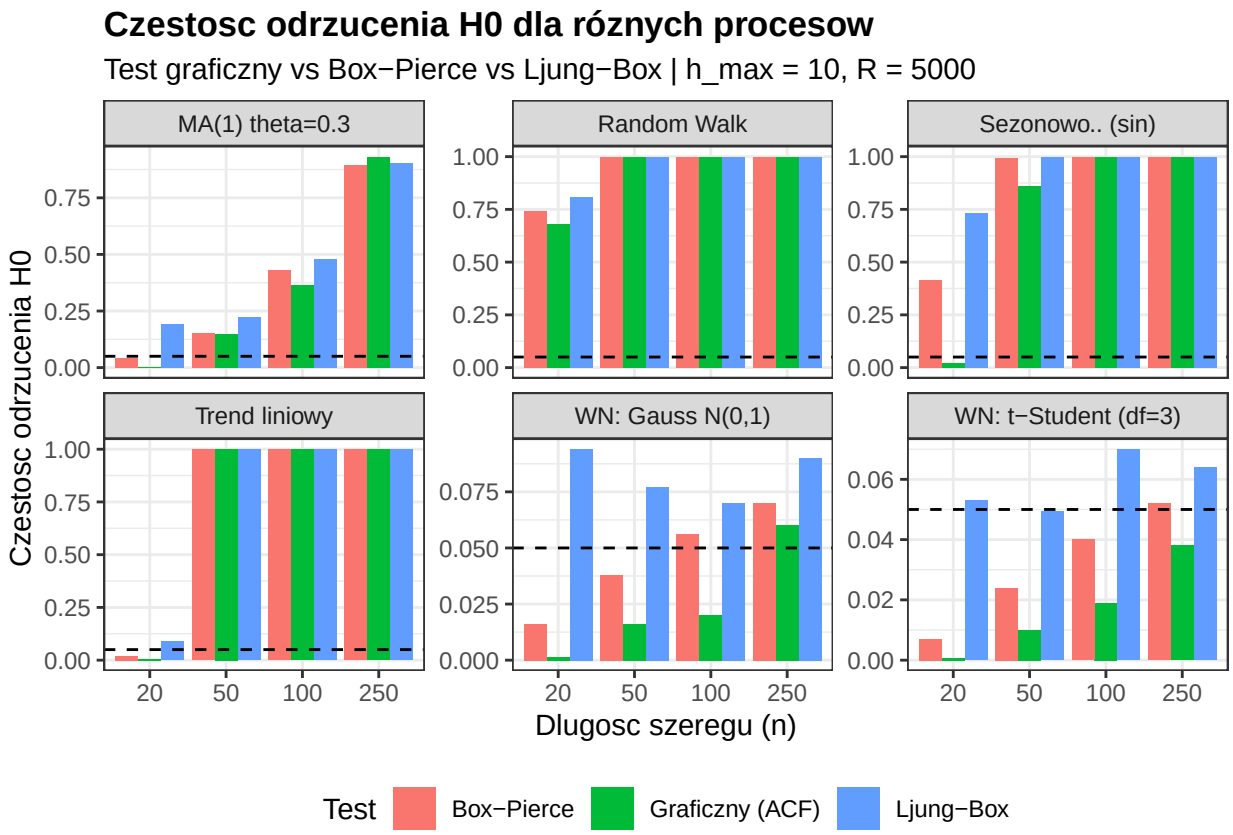
Czestosc odrzucenia H0 dla róznych procesow
Test graficzny vs Box−Pierce vs Ljung−Box | h_max = 10, R = 5000
MA(1) theta=0.3
Random Walk
Sezonowo.. (sin)
Trend liniowy
WN: Gauss N(0,1)
WN: t−Student (df=3)
Czestosc odrzucenia H0
Dlugosc szeregu (n)
Test
Box−Pierce
Graficzny (ACF)
Ljung−Box

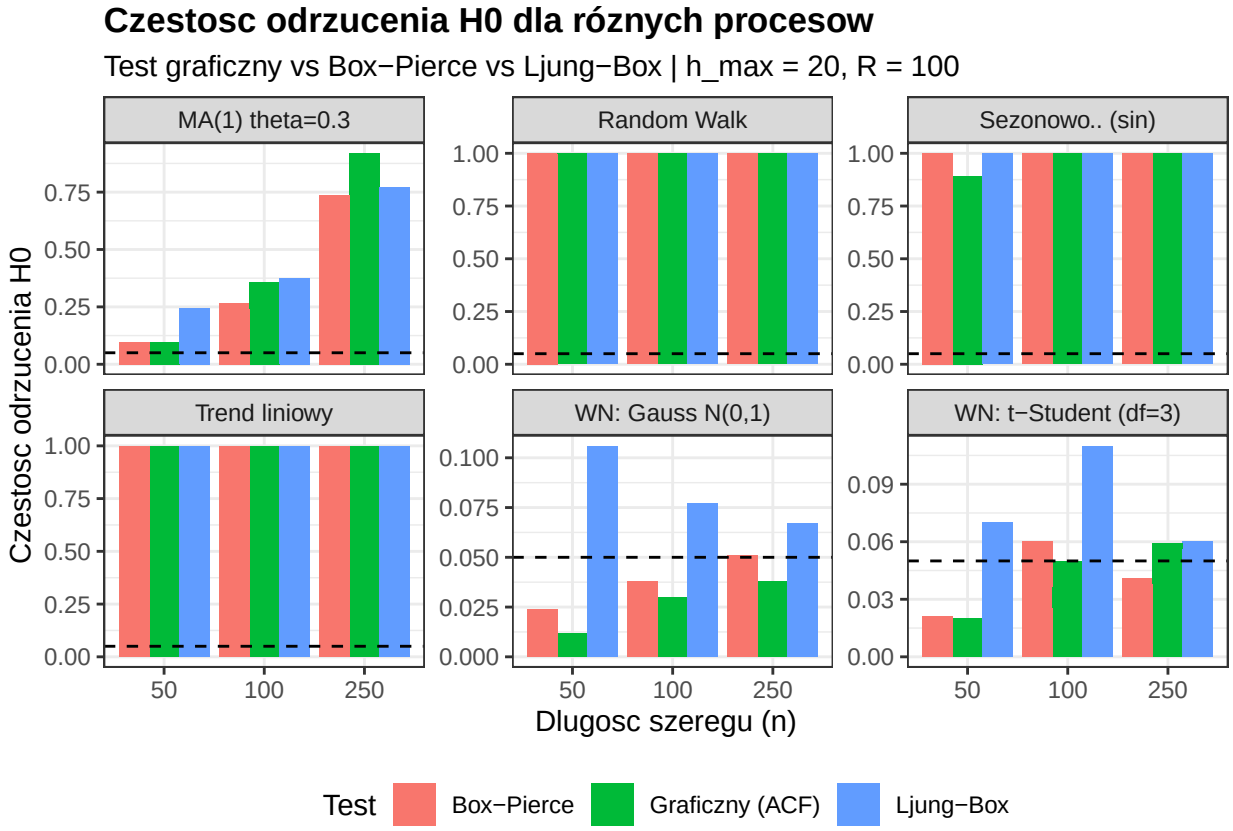
Czestosc odrzucenia H0 dla róznych procesow
Test graficzny vs Box−Pierce vs Ljung−Box | h_max = 20, R = 100
MA(1) theta=0.3
Random Walk
Sezonowo.. (sin)
Trend liniowy
WN: Gauss N(0,1)
WN: t−Student (df=3)
Czestosc odrzucenia H0
Dlugosc szeregu (n)
Test
Box−Pierce
Graficzny (ACF)
Ljung−Box

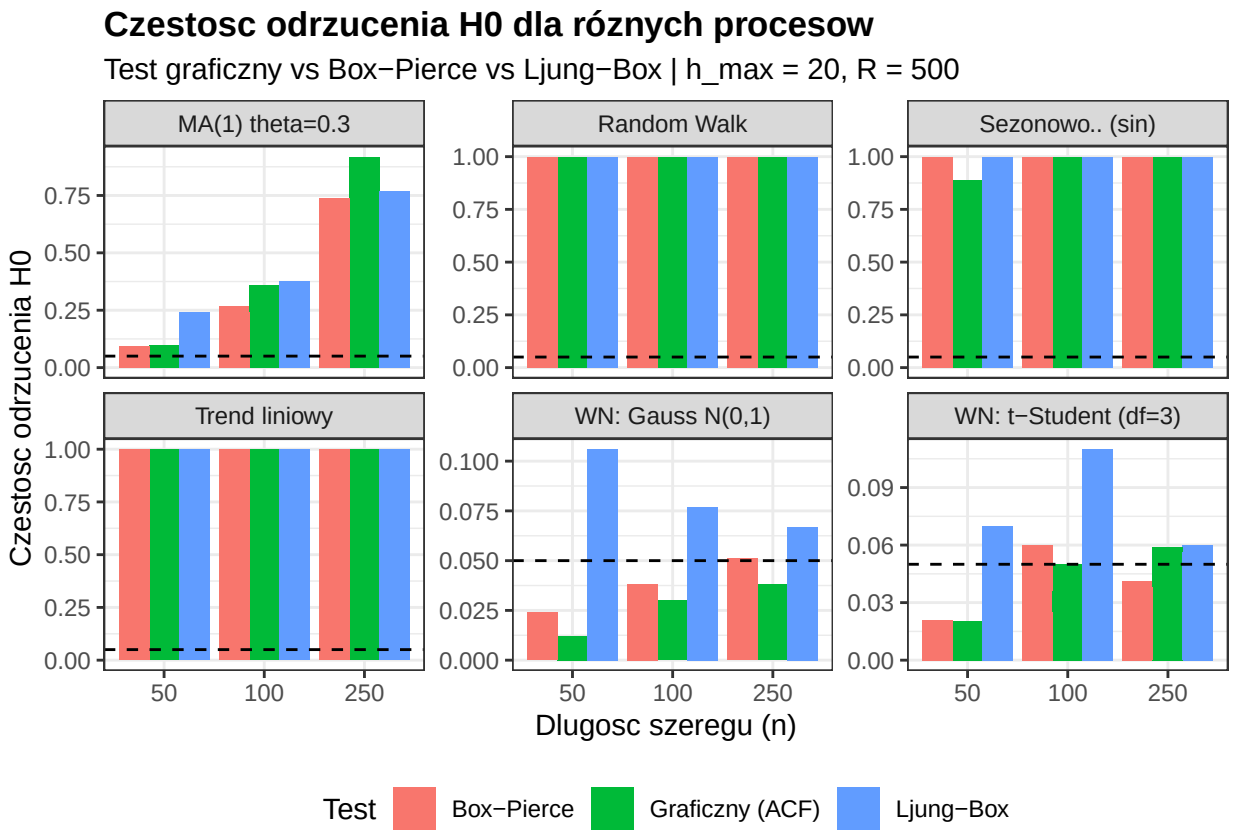
Czestosc odrzucenia H0 dla róznych procesow
Test graficzny vs Box−Pierce vs Ljung−Box | h_max = 20, R = 500
MA(1) theta=0.3
Random Walk
Sezonowo.. (sin)
Trend liniowy
WN: Gauss N(0,1)
WN: t−Student (df=3)
Czestosc odrzucenia H0
Dlugosc szeregu (n)
Test
Box−Pierce
Graficzny (ACF)
Ljung−Box

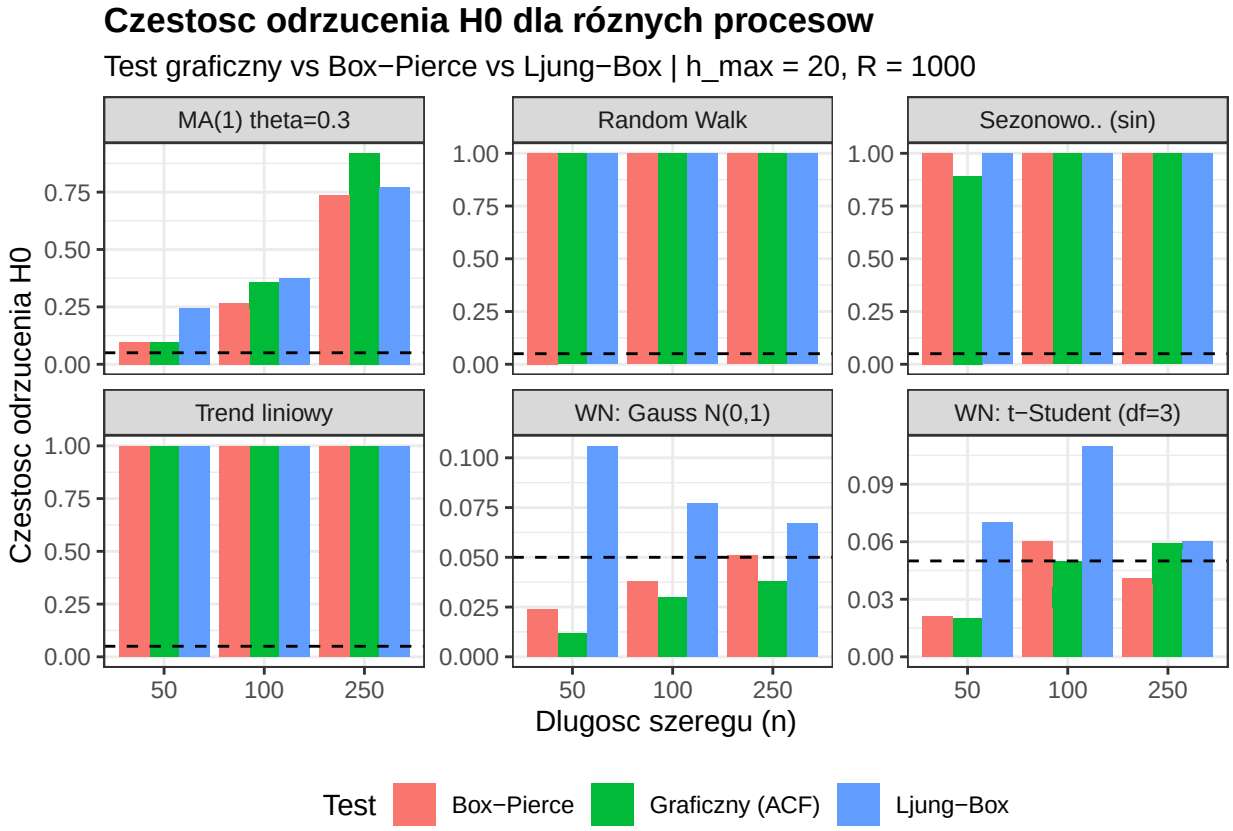
Czestosc odrzucenia H0 dla róznych procesow
Test graficzny vs Box−Pierce vs Ljung−Box | h_max = 20, R = 1000
MA(1) theta=0.3
Random Walk
Sezonowo.. (sin)
Trend liniowy
WN: Gauss N(0,1)
WN: t−Student (df=3)
Czestosc odrzucenia H0
Dlugosc szeregu (n)
Test
Box−Pierce
Graficzny (ACF)
Ljung−Box

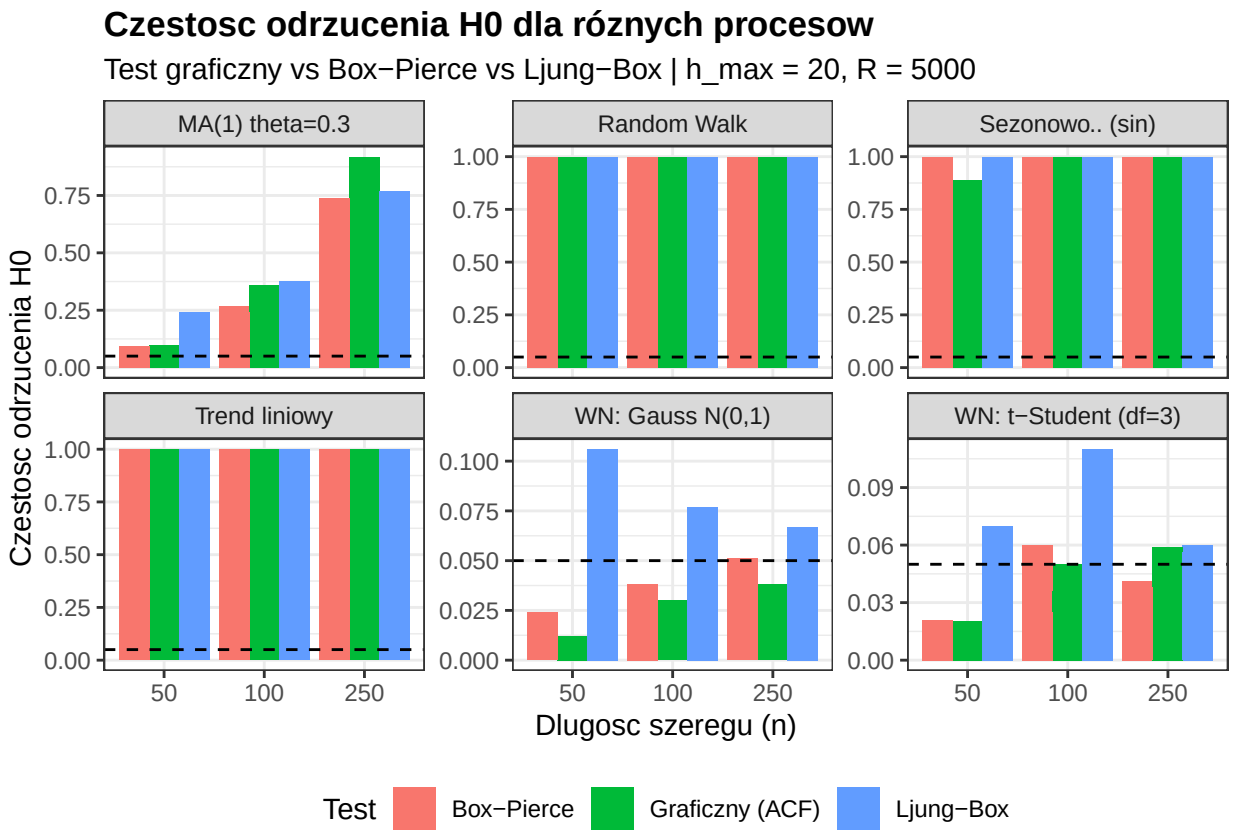

Wnioski:

1. Kontrola poziomu istotności dla białego szumu poprawia się wraz ze wzrostem n. Dla procesów spełniających H_0 (szum biały normalny oraz t-Studenta) empiryczne częstości odrzucenia hipotezy zerowej zbliżają się do nominalnego poziomu $\alpha = 0.05$ wraz ze wzrostem długości szeregu. Dla najkrótszych szeregów (n=20) obserwuje się większe odchylenia od wartości 0,05, natomiast dla n=50 i n=100 słupki dla wszystkich trzech testów stabilizują się w pobliżu poziomu istotności, zwłaszcza przy umiarkowanych wartościach h_{max} (=10 lub =5). Z kolei dla h_{max}=20 testy najbardziej stabilizują się dla większych n to znaczy n=250, co ma sens teoretyczny (zwłaszcza dla testu Ljung-Box).

2. Test graficzny jest na ogół bardziej konserwatywny niż testy formalne. Przy procesach spełniających H_0 częstość odrzucania hipotezy w teście graficznym jest zwykle nieco niższa lub porównywalna z testami Boxa–Pierce'a i Ljunga–Boxa, zwłaszcza dla krótszych szeregów i większych h_{max}. Wynika to z przyjętej reguły „co najmniej jeden lag wykracza poza pasmo" (pasmo -> reguła trzech sigm), opartej na przybliżeniu asymptotycznym. W efekcie test graficzny rzadziej „alarmuje" o odchyleniach od białoszumowości, co można interpretować jako zachowanie bardziej konserwatywne – szczególnie w sytuacjach, w których dostępne są tylko krótkie szeregi.

3. Moc testów rośnie z długością szeregu, ale wrażliwość zależy od typu alternatywy Dla procesów z silną zależnością (błądzenie losowe, trend liniowy, sezonowość sinusoidalna) wszystkie trzy testy bardzo szybko osiągają wysoką moc – częstość odrzucenia H_0 zbliża się do 1 już dla n=50 i n=100, niezależnie od wartości R. W przypadku „łagodniejszej" alternatywy MA(1) z $\theta = 0.3$ wzrost mocy jest wyraźnie wolniejszy: dla małych n testy często nie odróżniają szeregu od białego szumu, dopiero przy większych długościach i umiarkowanym h_{max} częstość odrzucenia zaczyna istotnie rosnąć. Pokazuje to, że zdolność wykrywania odchyleń zależy nie tylko od długości szeregu, ale też od charakteru zależności w procesie.

4. Liczba replikacji R stabilizuje szacunki, ale nie zmienia jakościowych wniosków. Porównując wykresy dla R = 100, 500, 1000 i 5000, widać, że ogólny kształt słupków (relacje między testami i procesami)

pozostaje taki sam – zmienia się jedynie „gładkość” oszacowań. Dla małego R wartości częstości odrzucenia bardziej „skaczą” pomiędzy kolejnymi długościami n, natomiast przy R=5000 są już bardzo stabilne.

2 Zadanie 4

Wybieram zbiór danych opisujący produkcje piwa na przestrzeni lat w Australii - $ausbeer\{fpp2\}$.

2.0.1 Analiza wstępna

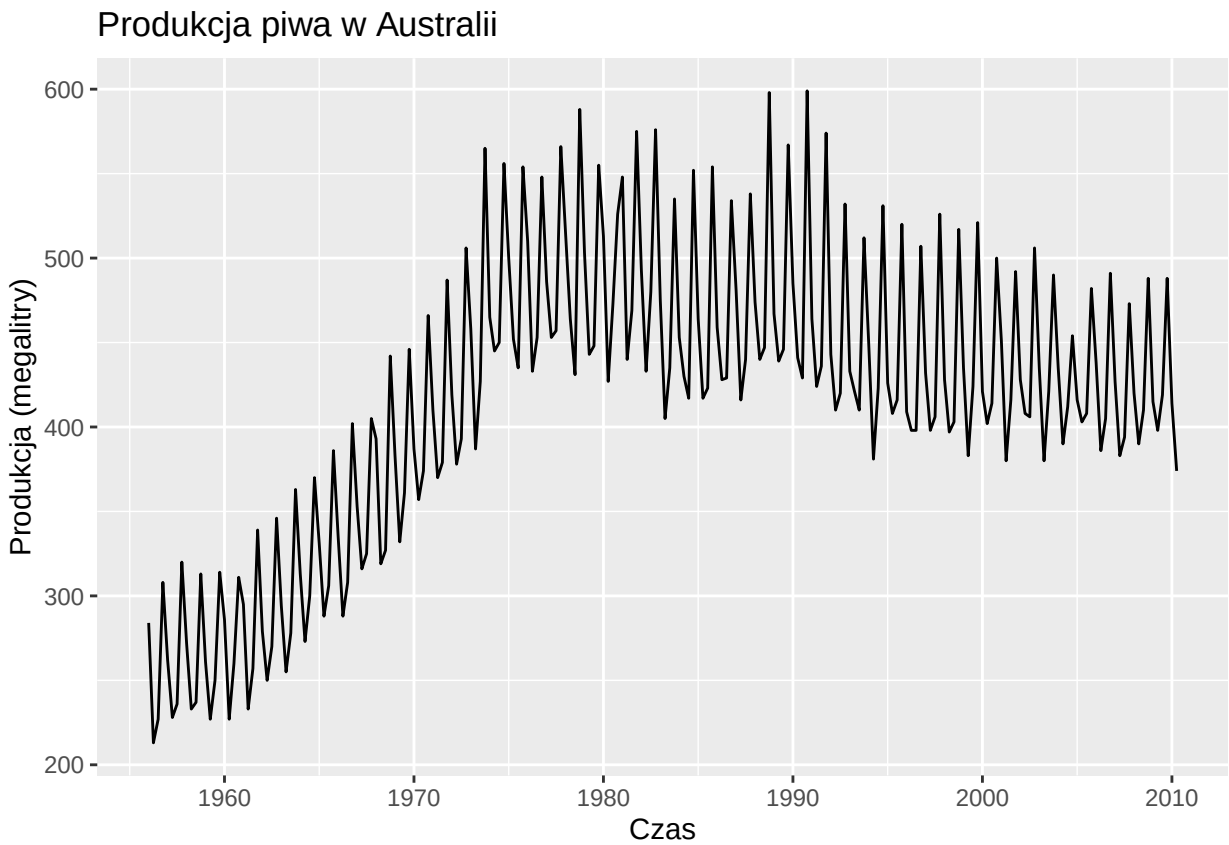

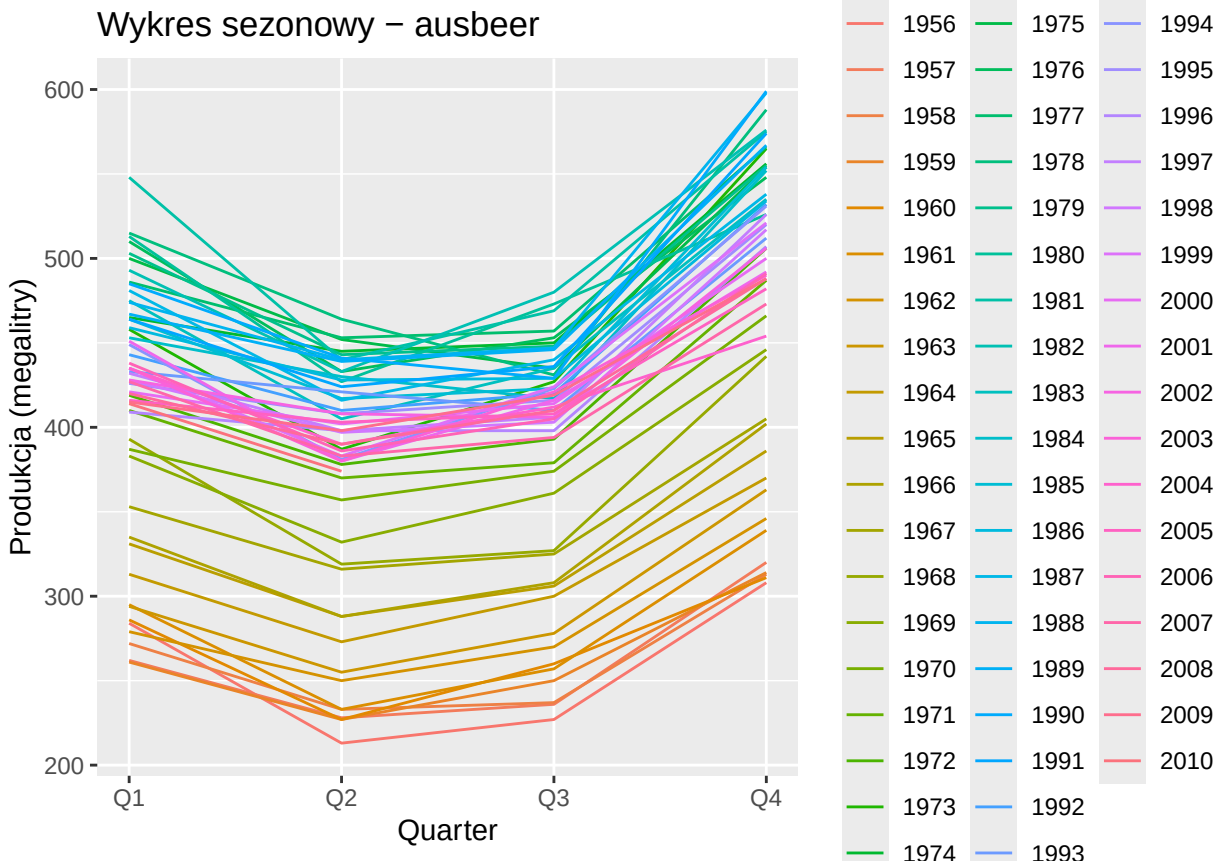

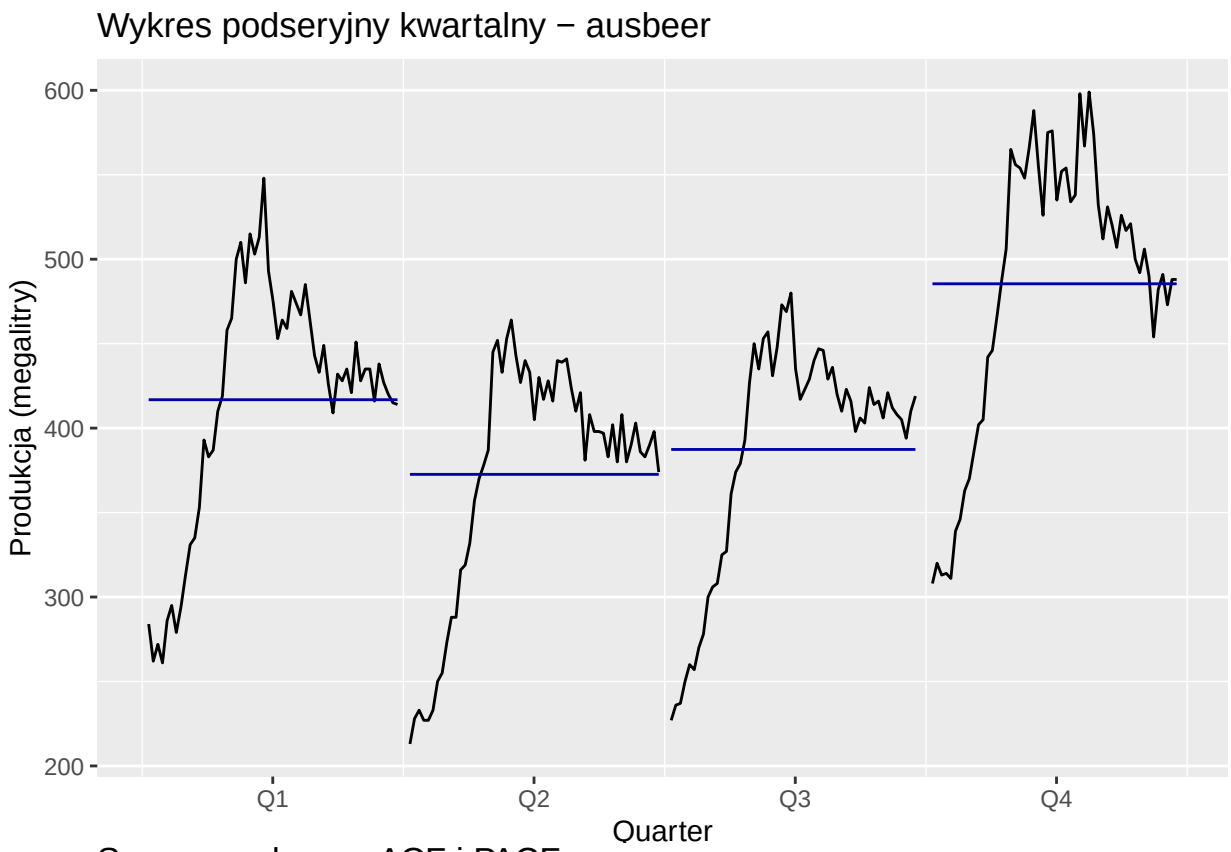
Wykres podseryjny kwartalny − ausbeer
Produkcja (megalitry)
600
500
400
300
200
Q1
Q2
Q3
Q4
Quarter

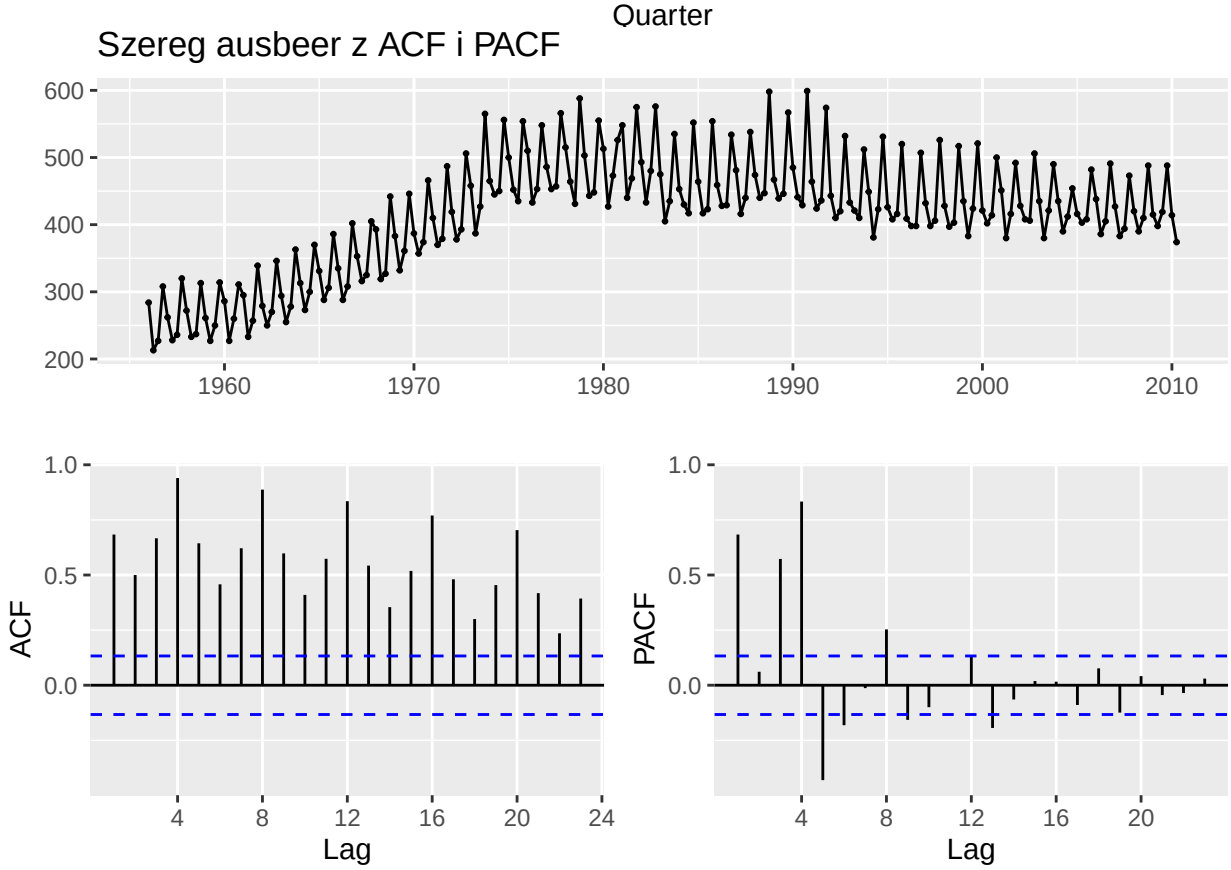
Szereg ausbeer z ACF i PACF
600
500
400
300
200
1960
1970
1980
1990
2000
2010
ACF
1.0
0.5
0.0
4
8
12
16
20
24
Lag
PACF
1.0
0.5
0.0
4
8
12
16
20
Lag

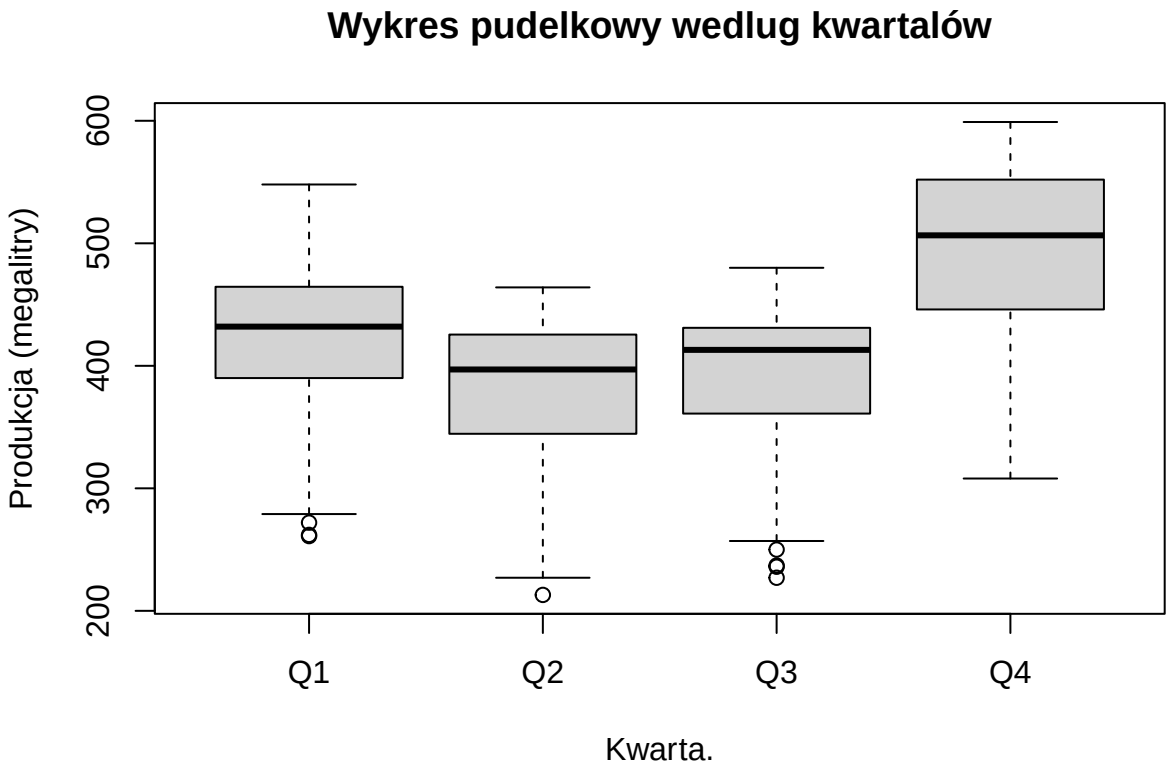

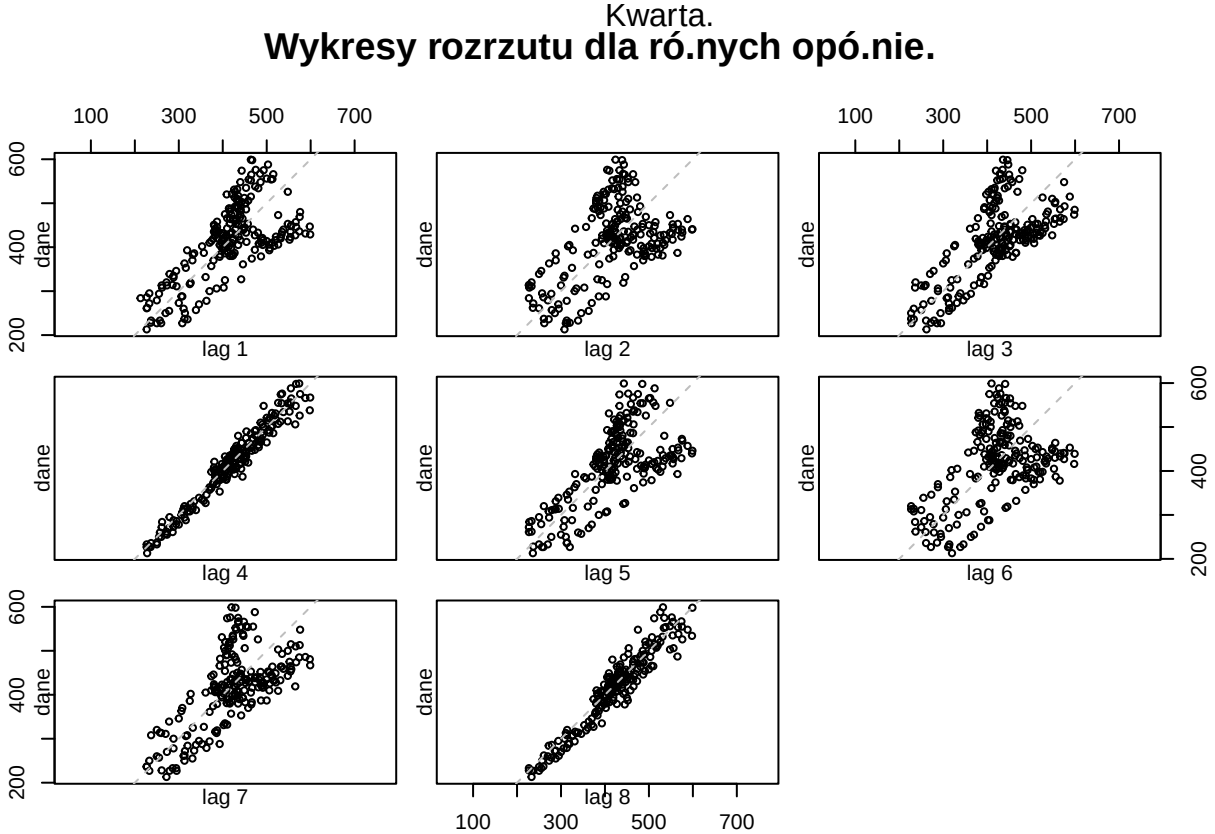

Wnioski wstępne:

- Szereg wykazuje silny trend rosnący od roku 1956 do połowy lat 70. (szczyt), następnie następuje stabilizacja i lekki trend spadkowy po roku 1980.

- Wyraźna sezonowość o okresie 4 (kwartalna)
- Najwyższa produkcja w Q4, najniższa w Q2
- ACF zanika powoli i okresowo - potwierdza trend i sezonowość
- Brak wyraźnych obserwacji odstających
- Największa korelacja dla opóźnienia 4 (sezonowość)

2.0.2 Dekompozycja addytywna

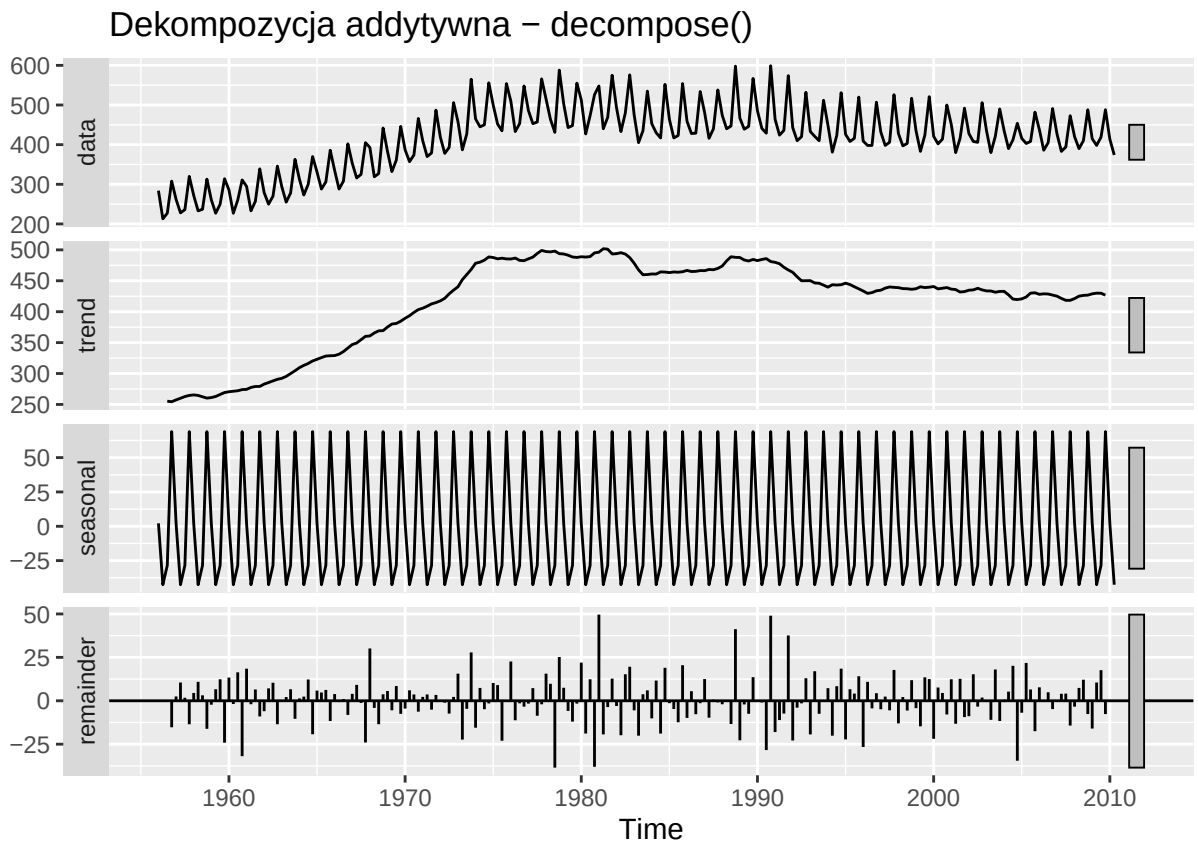

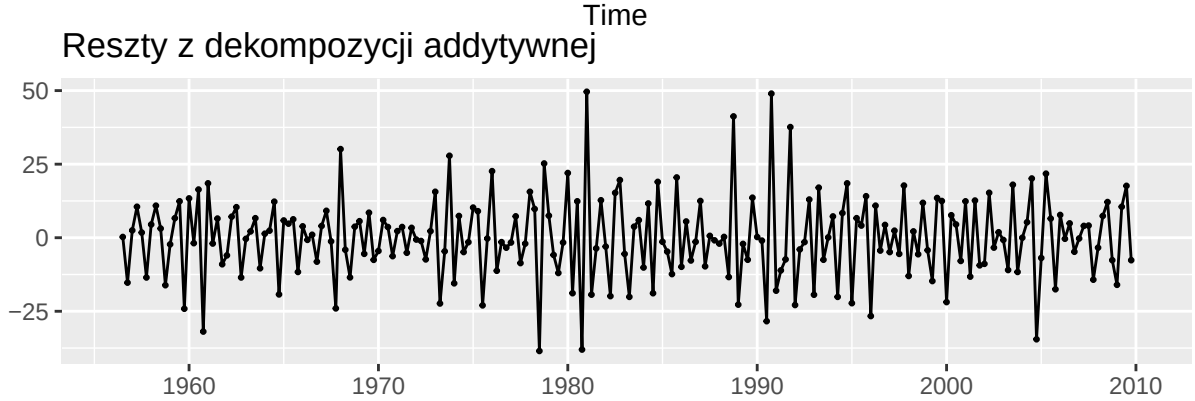

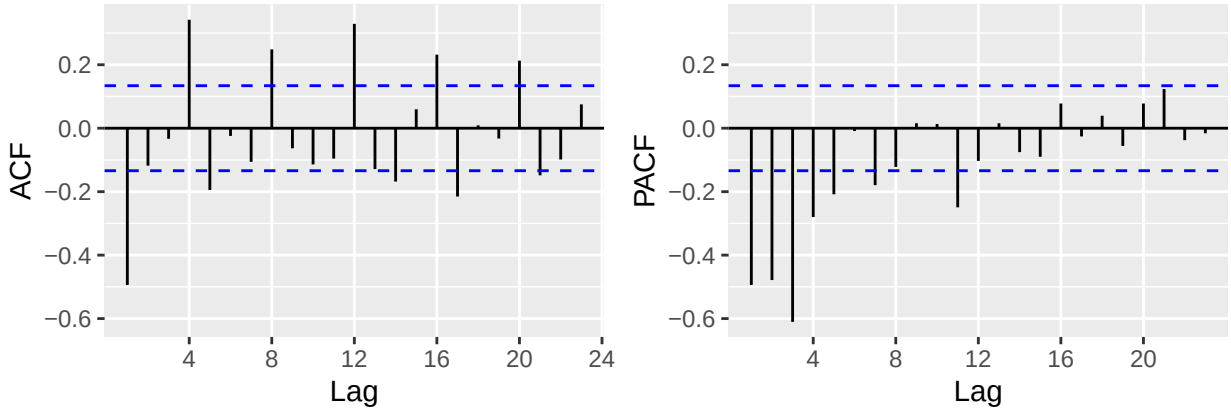

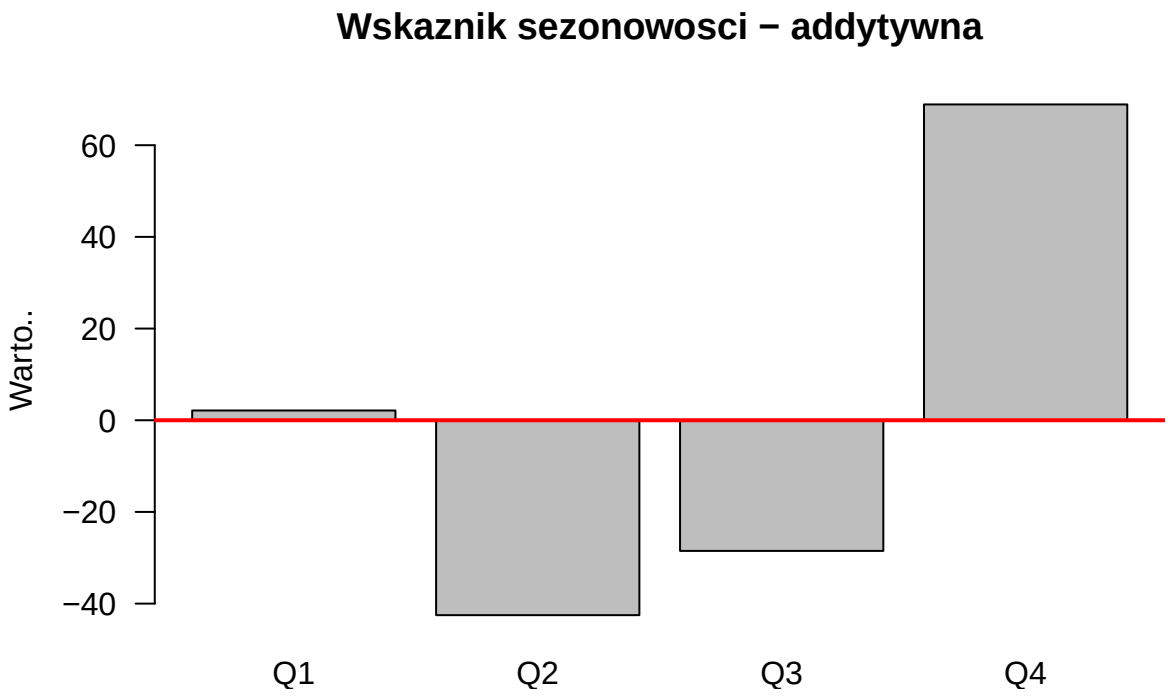

Wnioski dla dekompozycji addytywnej:

- Sezonowość stabilna w czasie
- Reszty zawierają jeszcze pewne wzorce
- Reszty w modelu addytywnym wykazują wyraźną niejednorodność wariancji, co sugeruje, że model addytywny nie do końca radzi sobie ze zmienną amplitudą. Model multiplikatywny nieco lepiej stabilizuje reszty.

2.0.3 Dekompozycja multiplikatywna

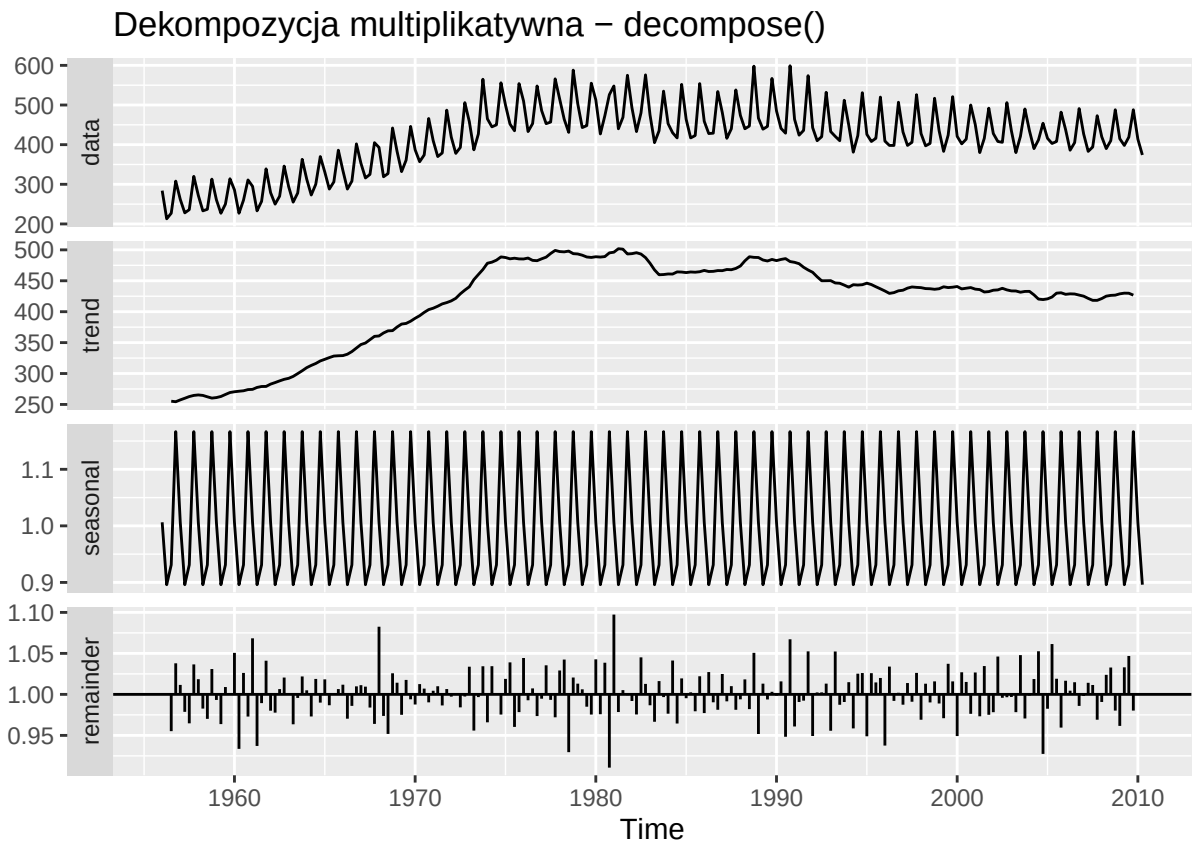

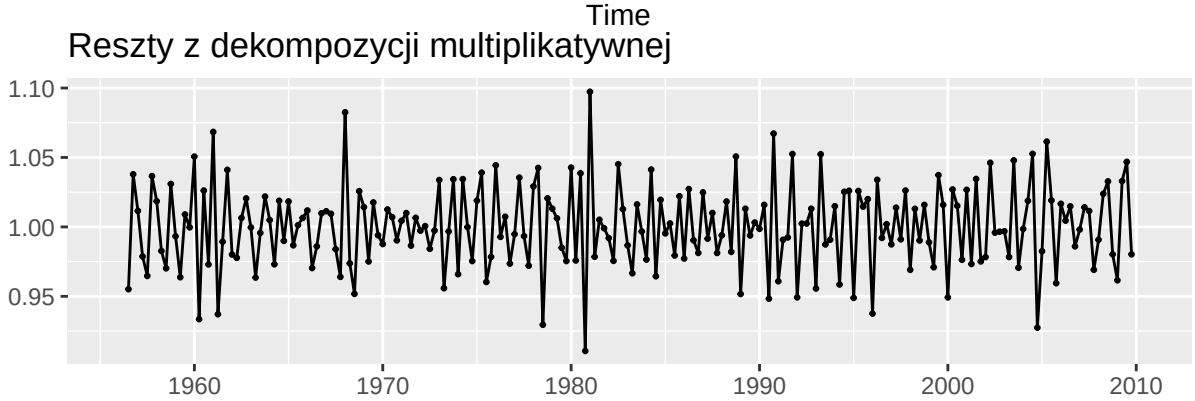

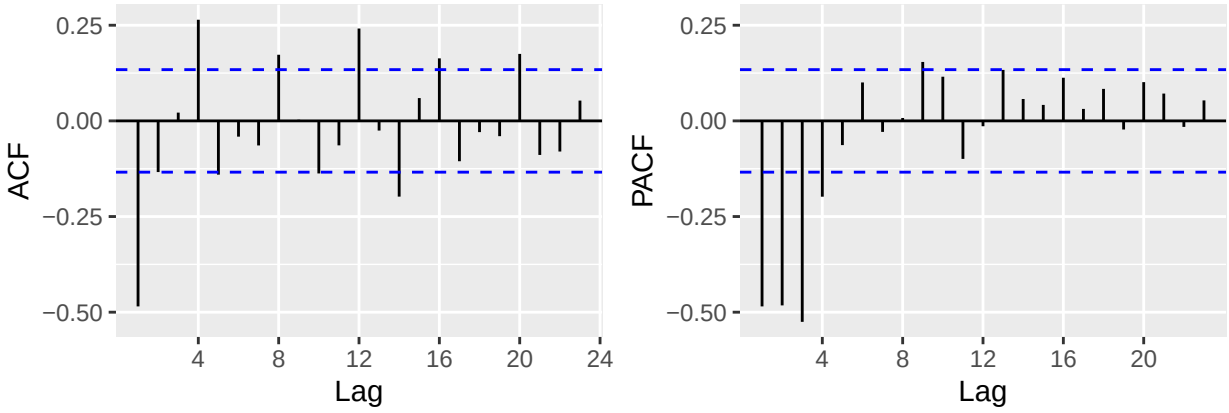

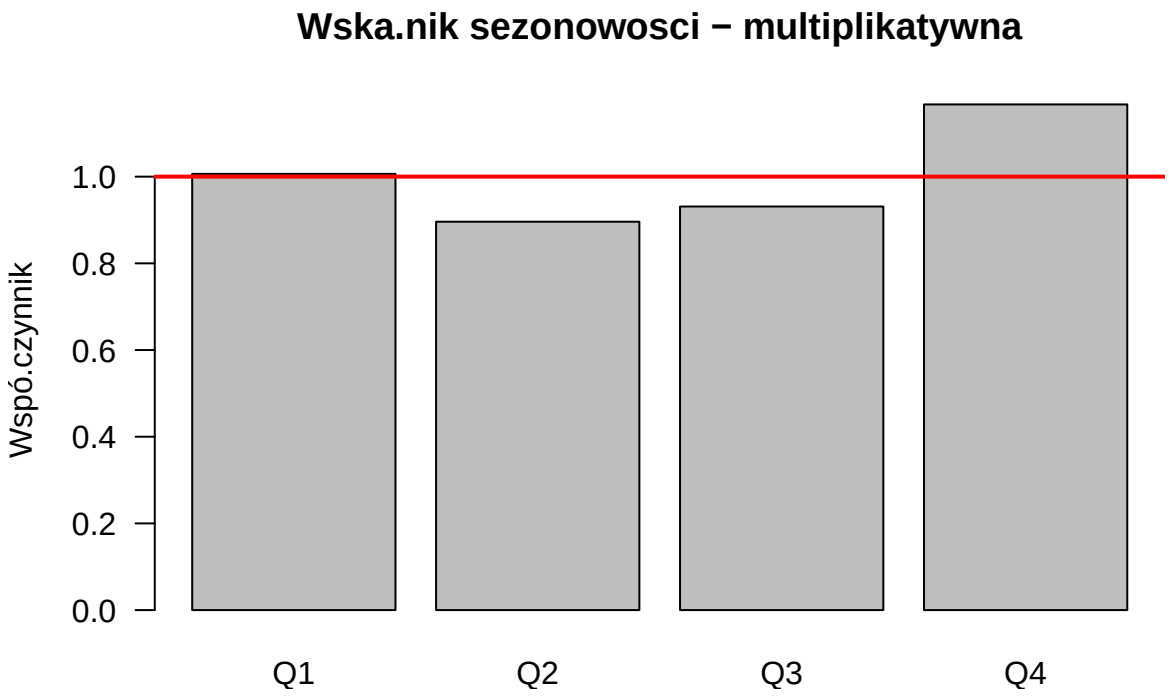

Wnioski dla dekompozycji multiplikatywnej:

- Podobny charakter jak addytywna
- Wskaźniki sezonowości wokół 1.0
- Model multiplikatywny jest teoretycznie lepszy, ponieważ amplituda wahań sezonowych rośnie wraz ze wzrostem poziomu trendu (widać to na wykresie surowych danych – w latach 70. wahania są większe niż w 60.).

2.0.4 Model regresji tslm()

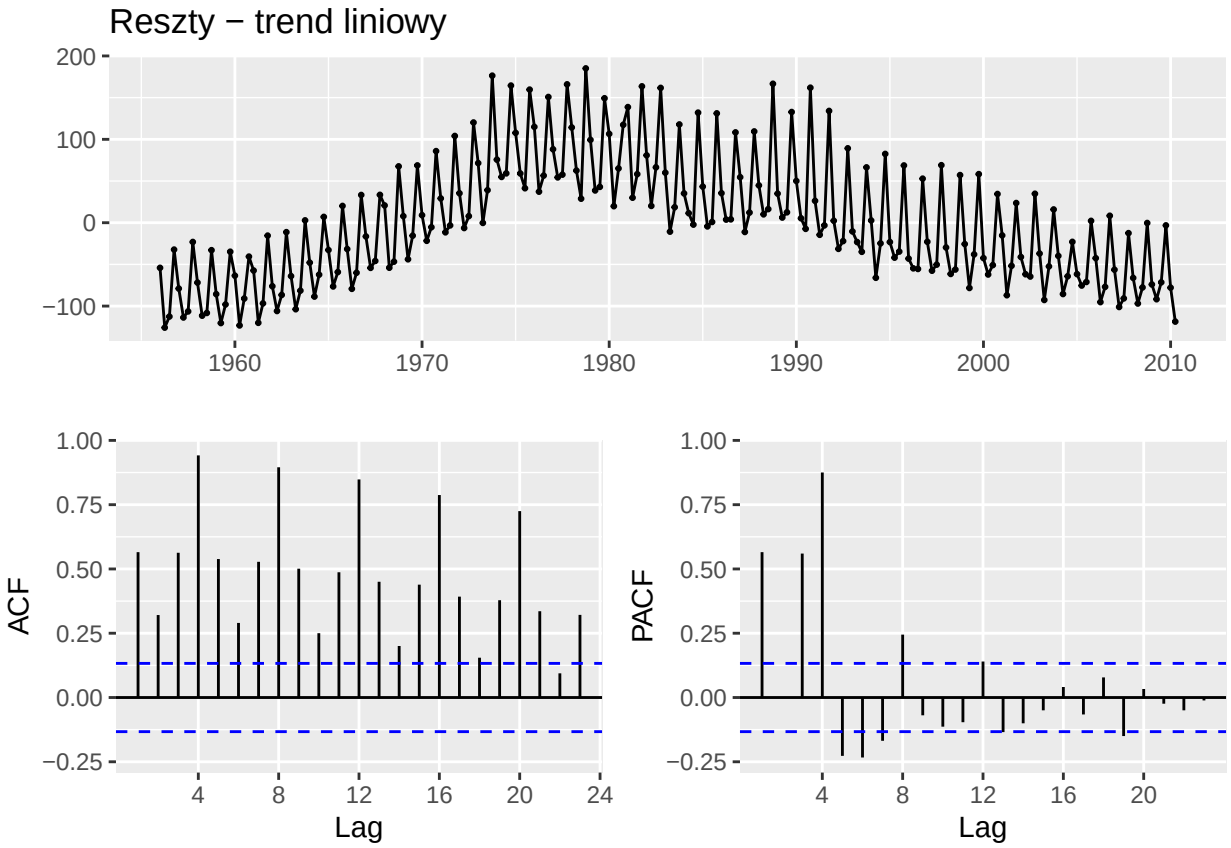

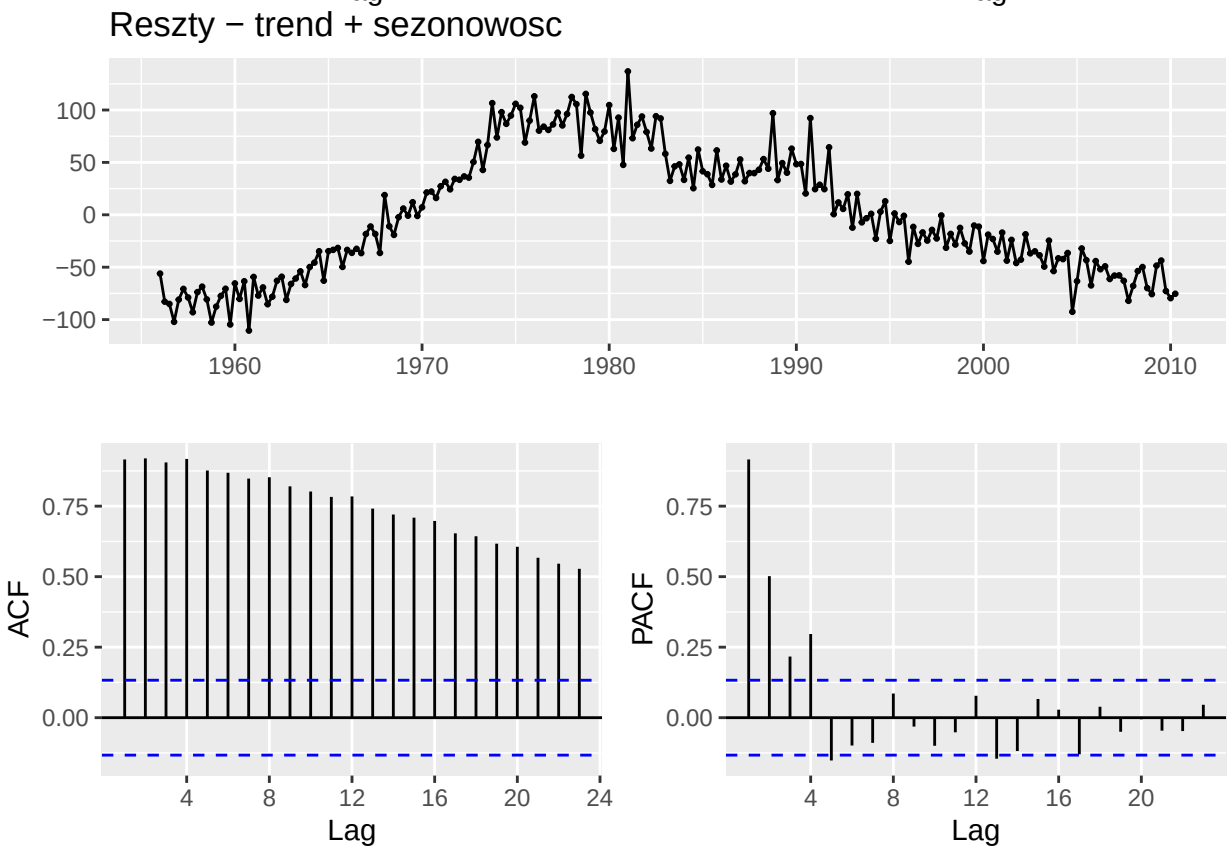

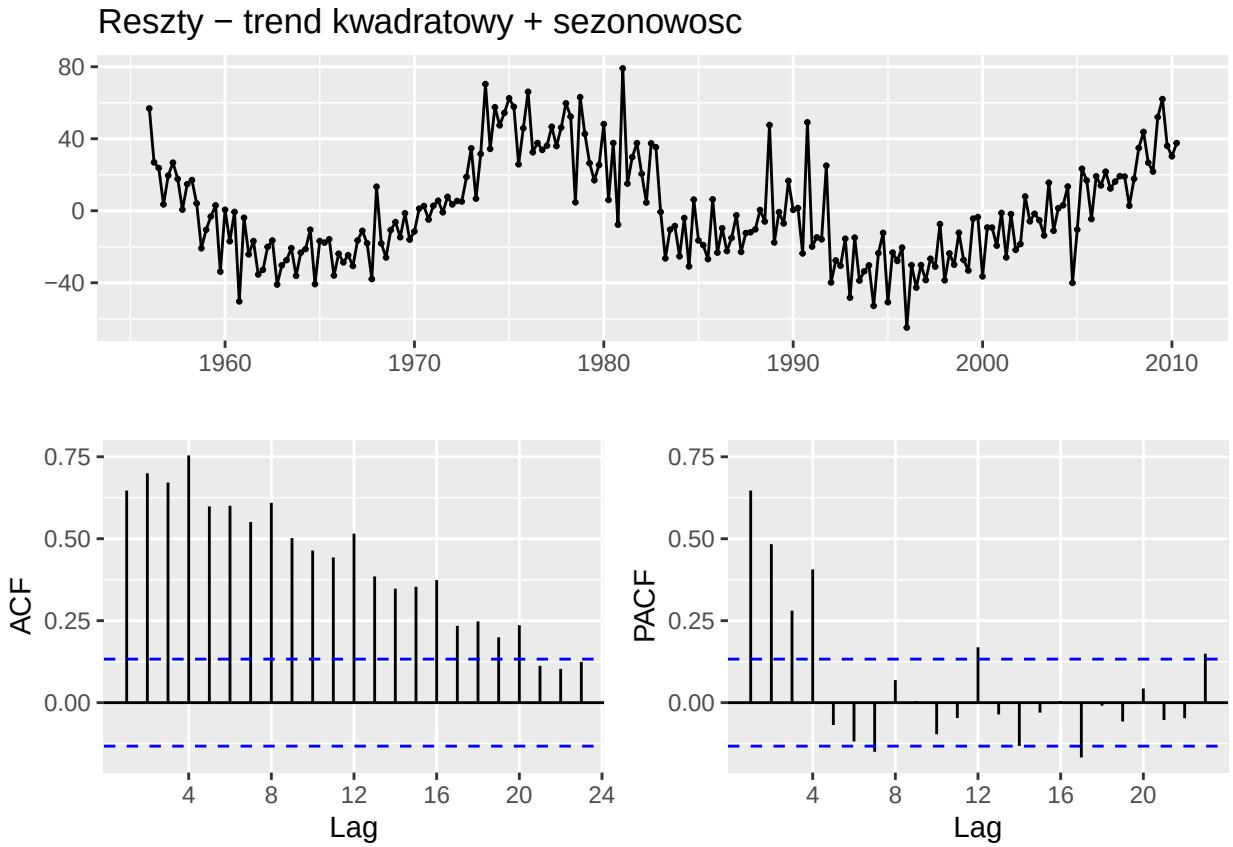
Reszty − trend kwadratowy + sezonowosc
80
40
0
−40
1960
1970
1980
1990
2000
2010
ACF
0.75
0.50
0.25
0.00
4
8
12
16
20
24
Lag
PACF
0.75
0.50
0.25
0.00
4
8
12
16
20
Lag

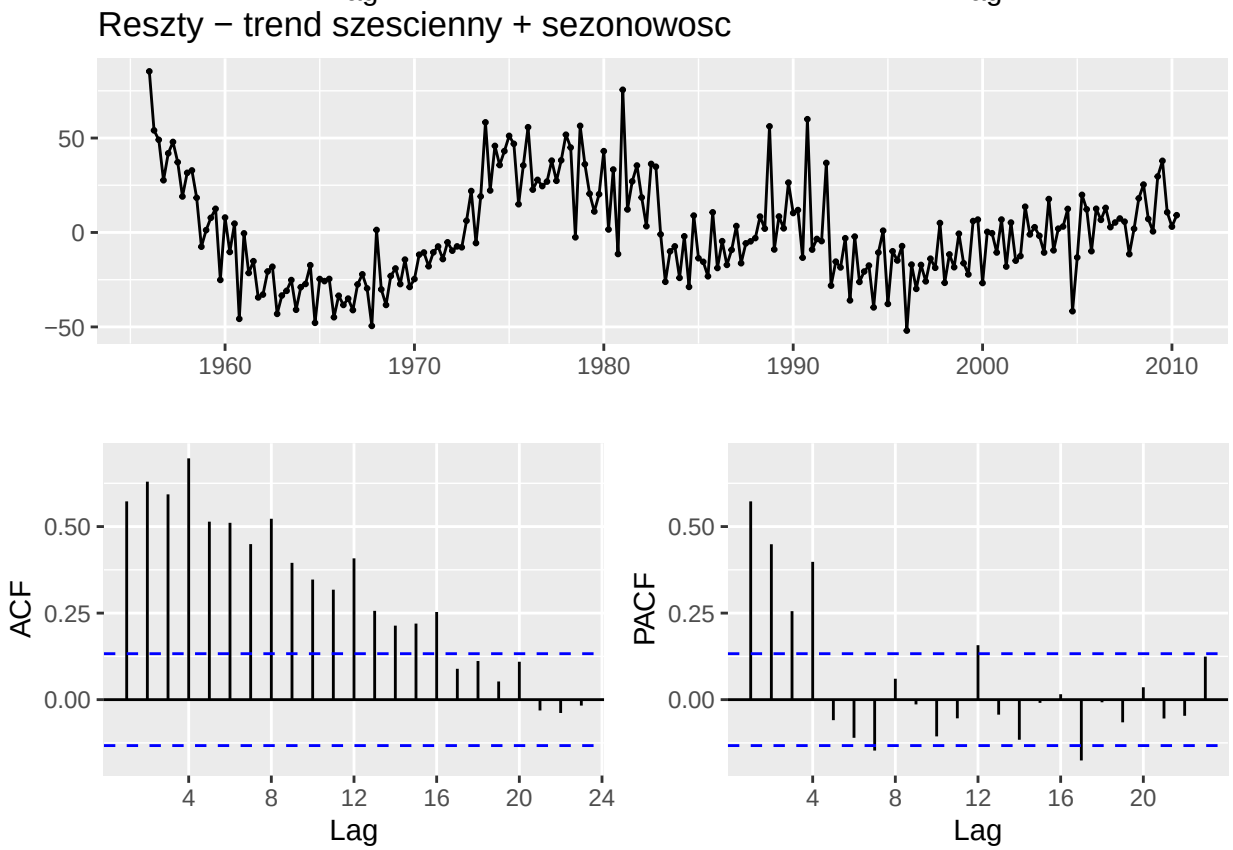
Reszty − trend szescienny + sezonowosc
50
0
−50
1960
1970
1980
1990
2000
2010
ACF
0.50
0.25
0.00
4
8
12
16
20
24
Lag
PACF
0.50
0.25
0.00
4
8
12
16
20
Lag

Table 1: Porównanie modeli tslm

Model	R_squared	Adj_R_squared	AIC	BIC
Model 0: trend	0.2735	0.2701	2495.501	2505.654
Model 1: trend + season	0.5272	0.5183	2407.836	2428.143
Model 2: trend^2 + season	0.8909	0.8883	2090.206	2113.898
Model 3: trend^3 + season	0.9077	0.9051	2055.728	2082.804

Wnioski dla modeli tslm:

- Modele liniowe (Model 0 i 1) są nieakceptowalne ze względu na silną autokorelację i nielosowy kształt reszt.
- Dopiero Model 2 i 3 dają reszty oscylujące wokół zera bez wyraźnego trendu w samych resztach. To widać też w tabeli AIC – Model 3 ma najniższe AIC (2055) w porównaniu do Modelu 1 (2407), co jest kolosalną różnicą.

2.0.5 Metoda LOESS stl()

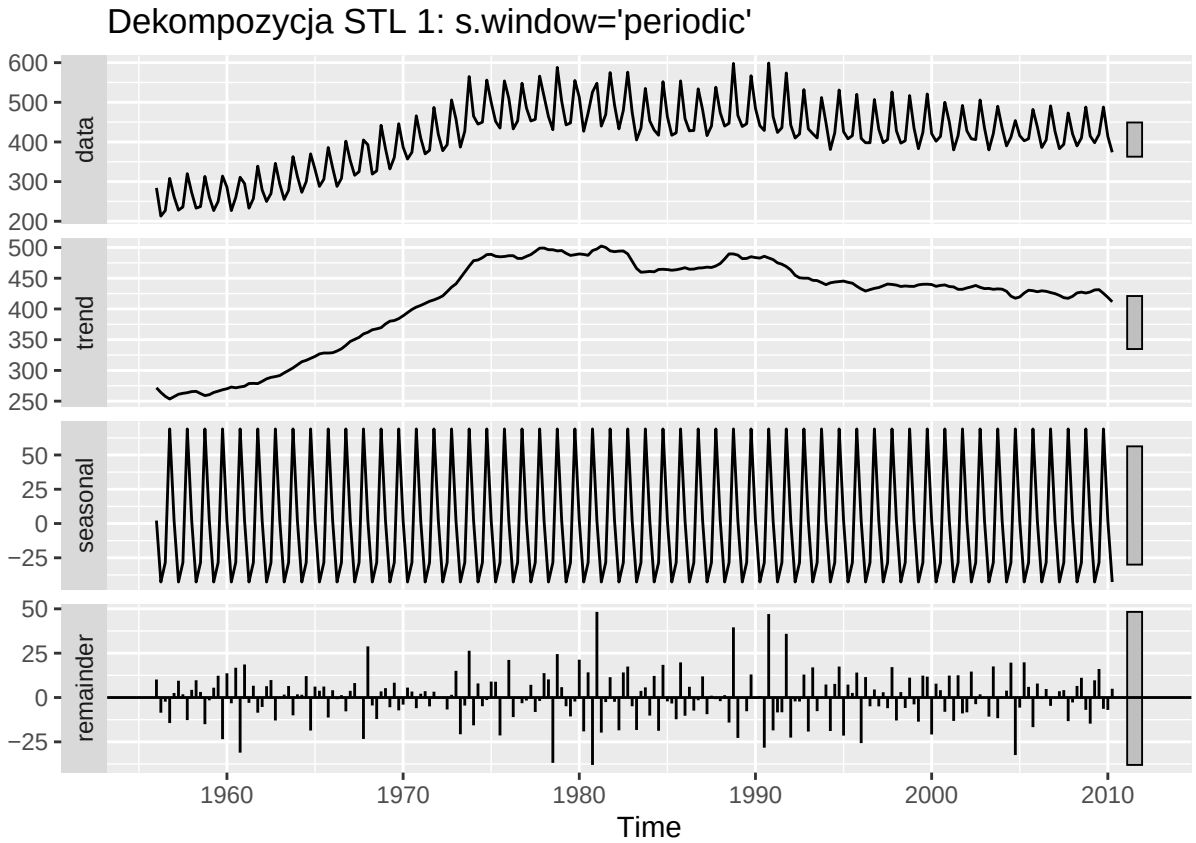

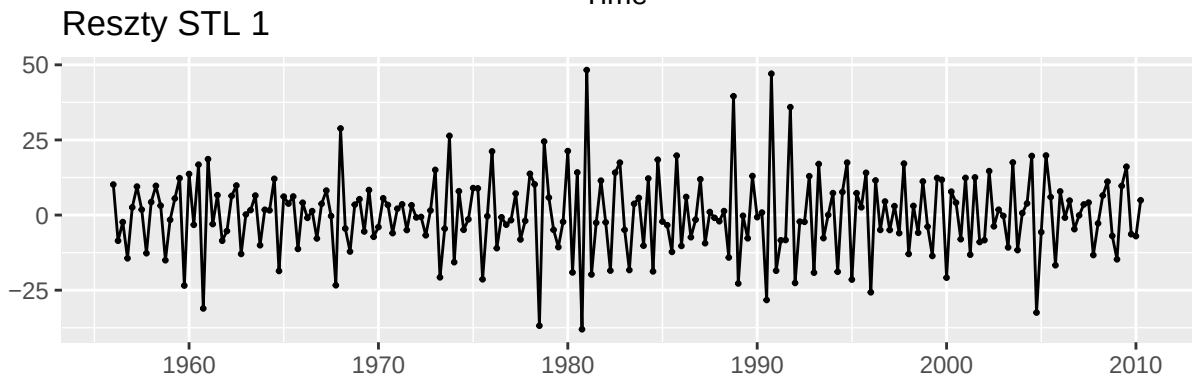

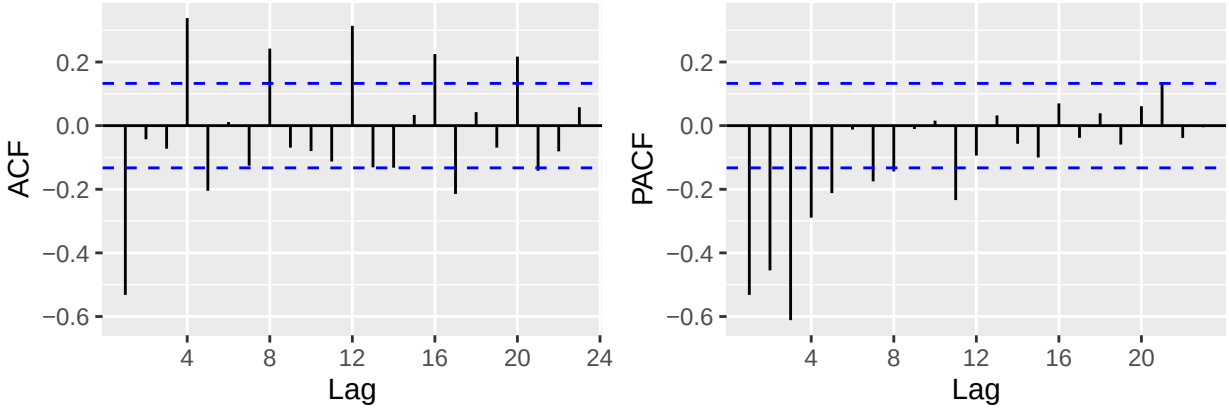

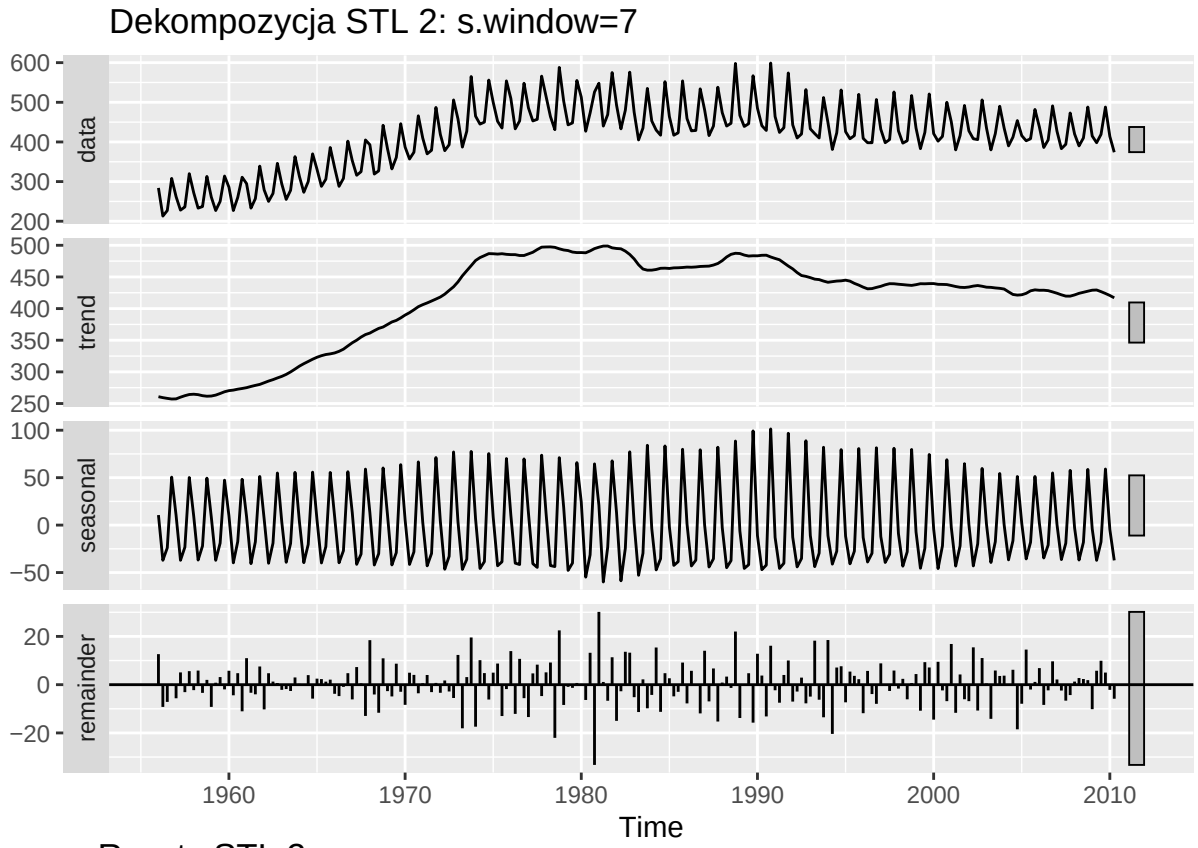
Dekompozycja STL 2: s.window=7
data
trend
seasonal
remainder
Time

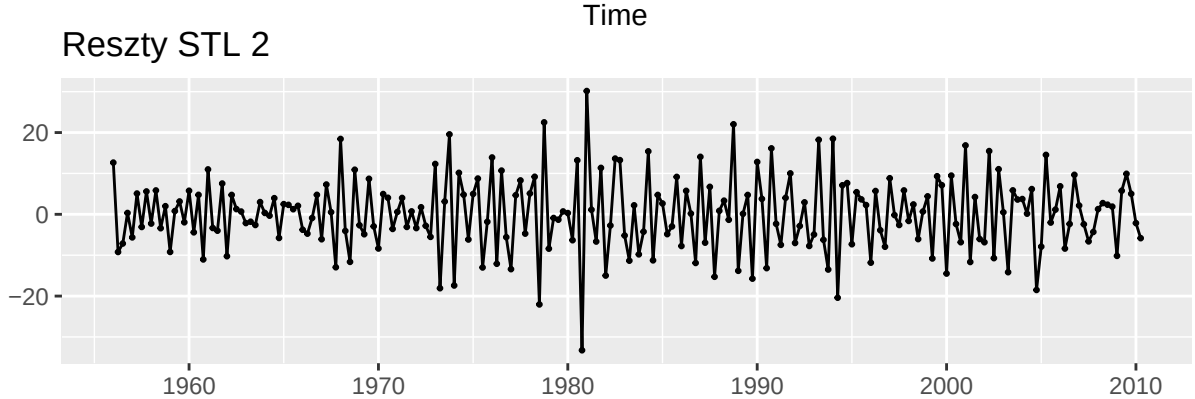
Reszty STL 2

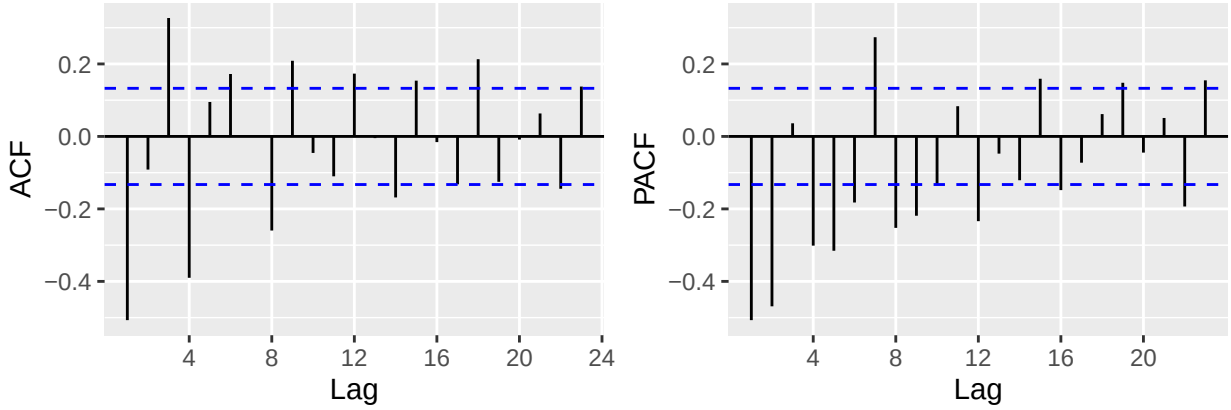
ACF
Lag
PACF
Lag

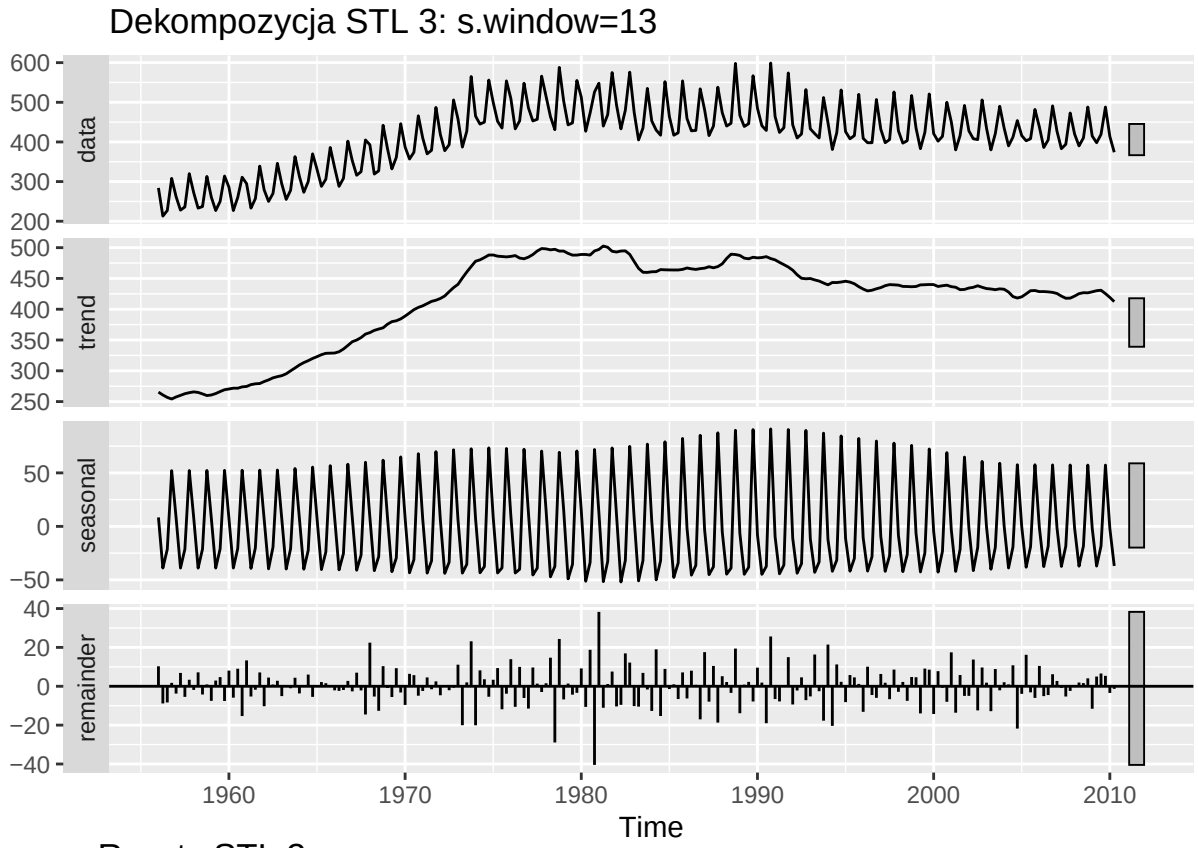
Dekompozycja STL 3: s.window=13
data
trend
seasonal
remainder
Time

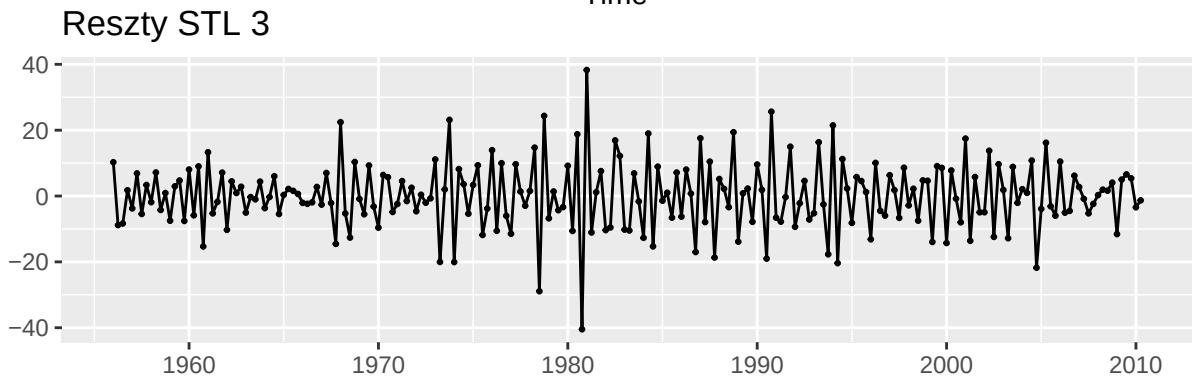
Reszty STL 3

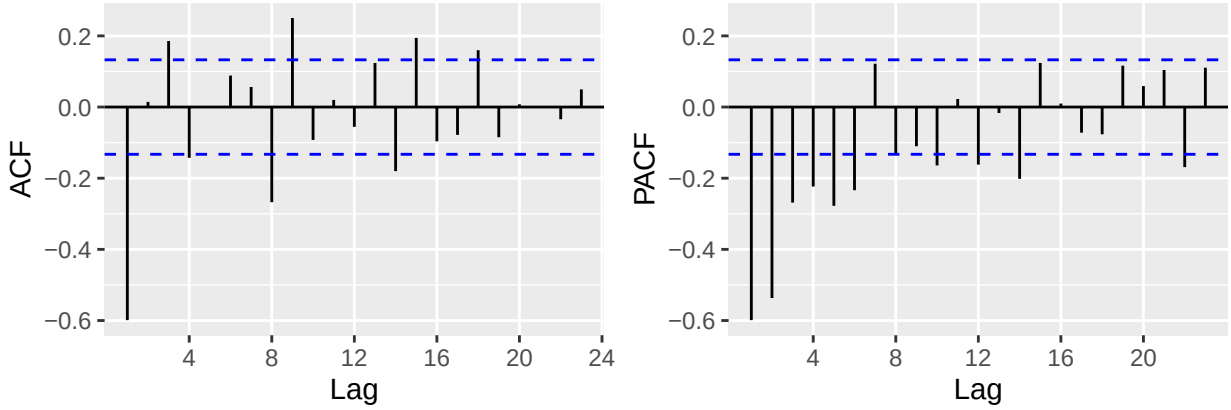
ACF
Lag
PACF
Lag

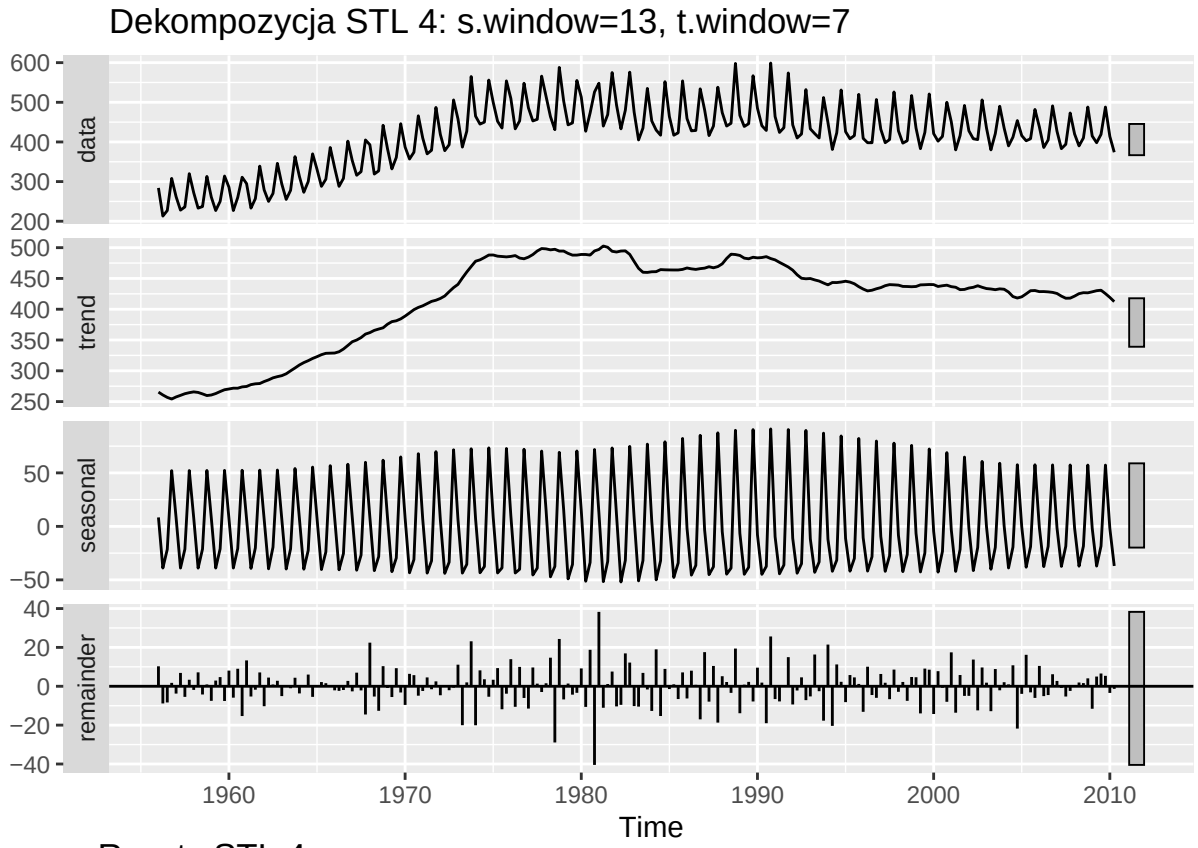

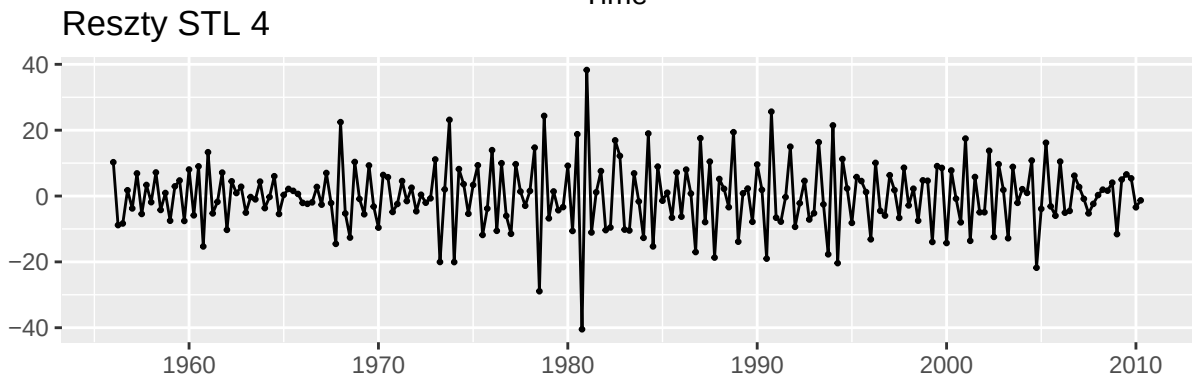

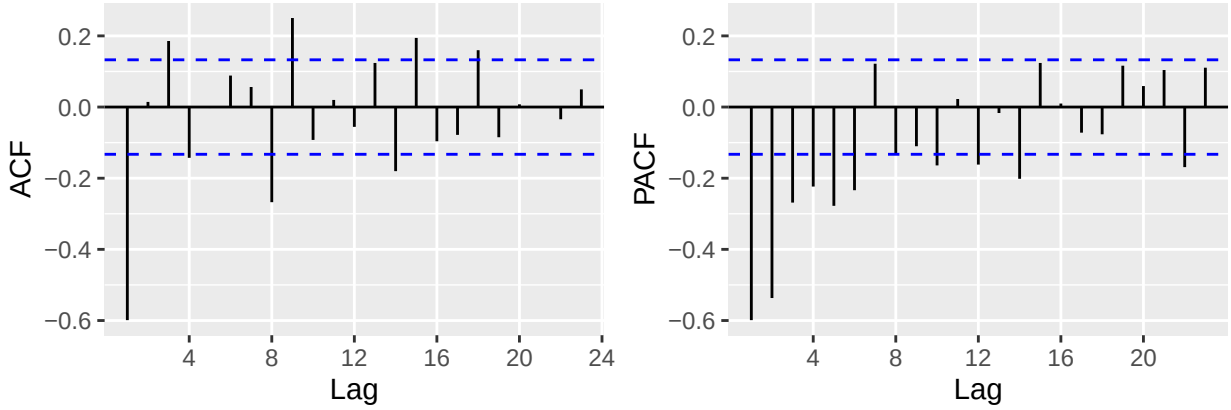

Wnioski dla dekompozycji STL:

- Metoda STL najlepiej ze wszystkich metod poradziła sobie z nieliniowym trendem – linia trendu (komponent trend) gładko podąża za rzeczywistym wzrostem i spadkiem produkcji, nie będąc sztywną linią prostą jak w tslm, ale zaraz będzie to też widać w porówaniu wszytskich metod.
- Reszty w STL są najbardziej zbliżone do stacjonarności (brak widocznych wzorców) w porównaniu do decompose czy prostych modeli tslm.

2.0.6 Porównanie metod dekompozycji

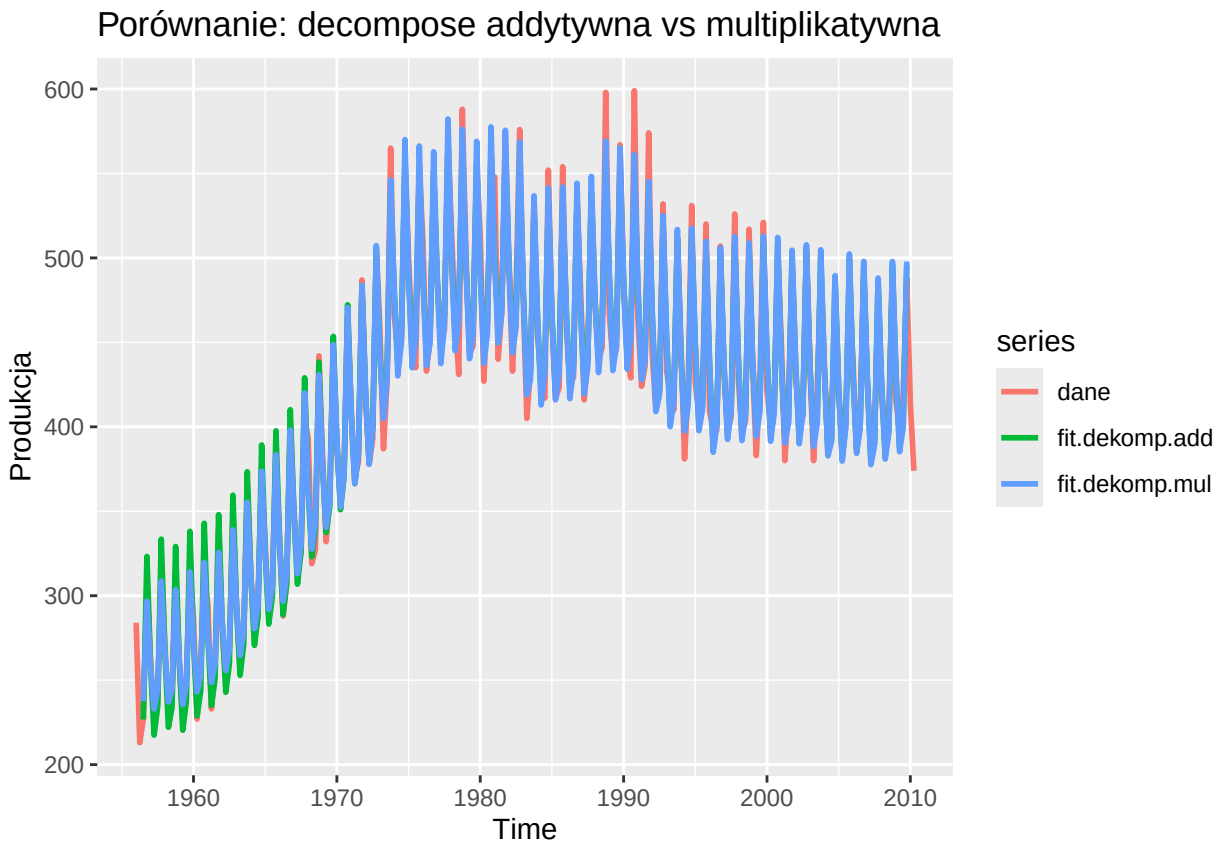

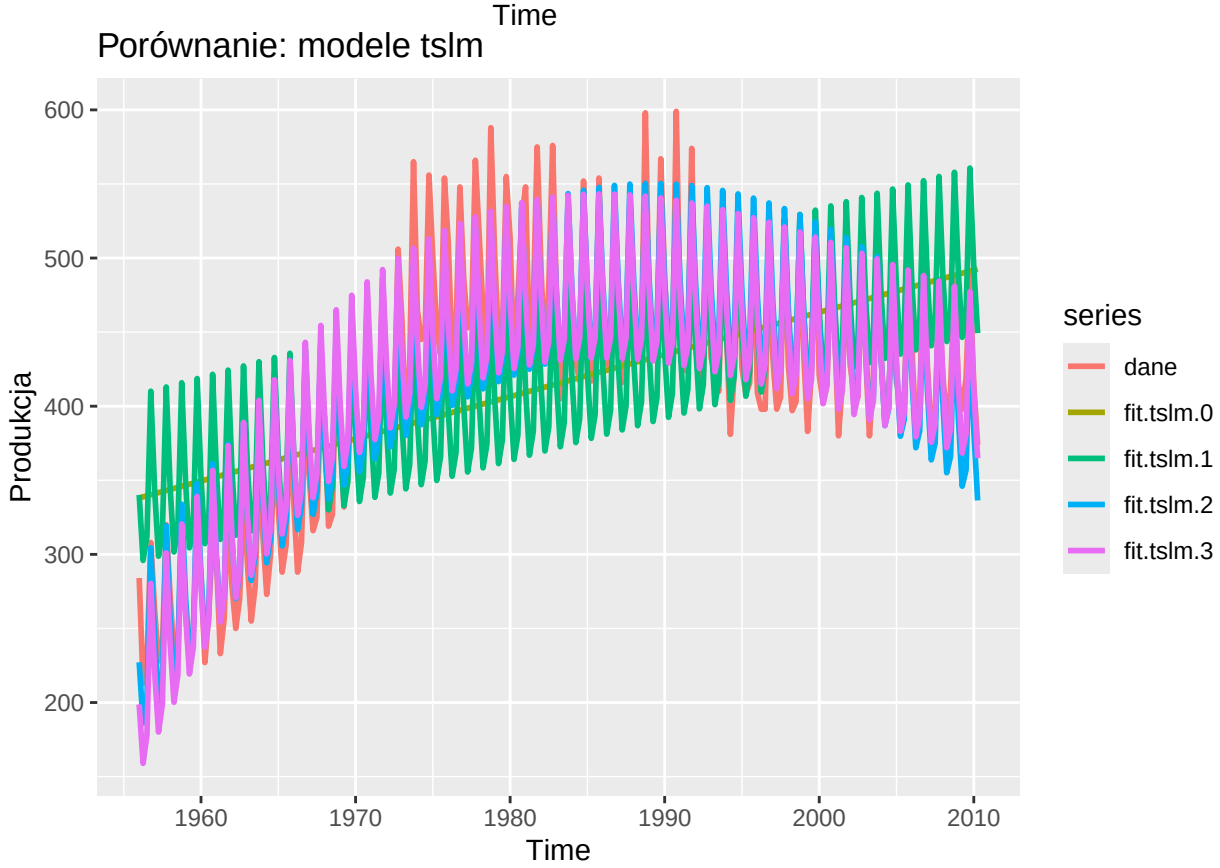

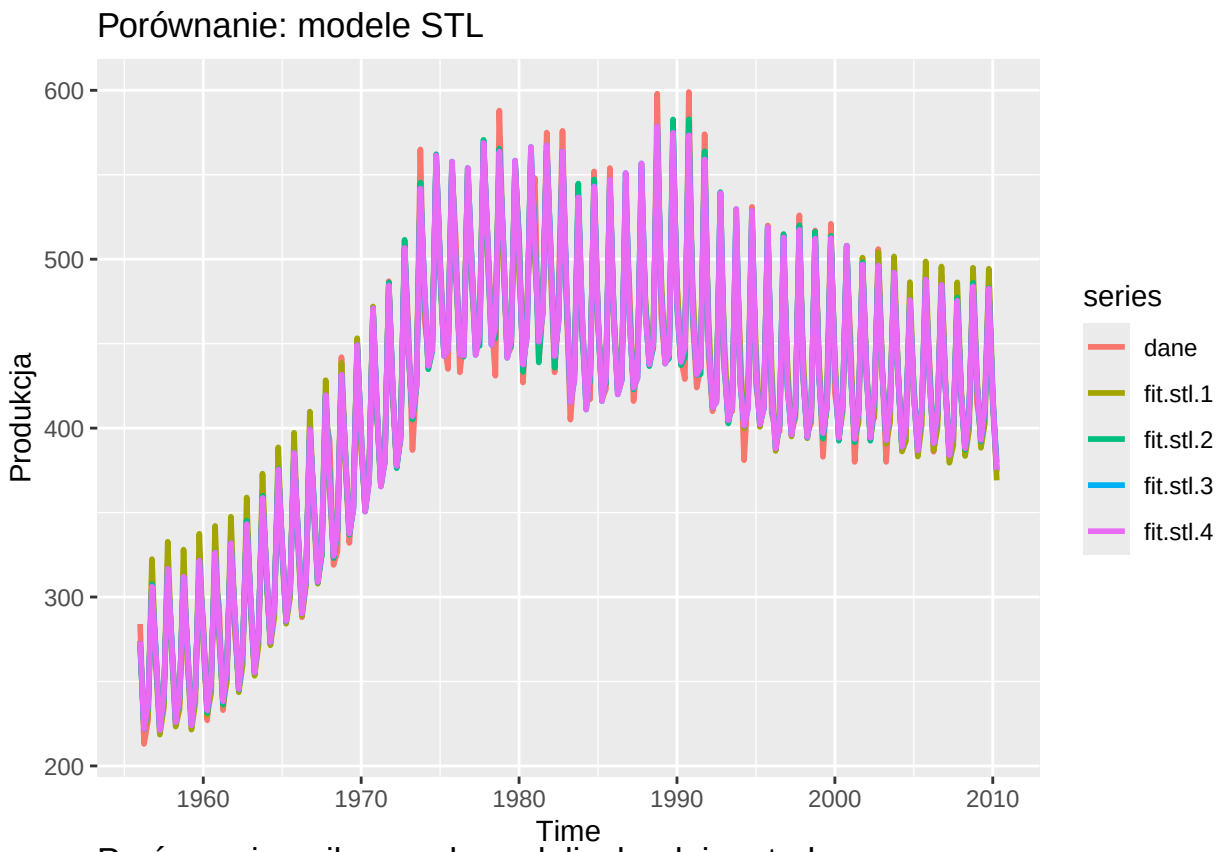
Porównanie: modele STL
Produkcja
600
500
400
300
200
1960
1970
1980
1990
2000
2010
Time
series
dane
fit.stl.1
fit.stl.2
fit.stl.3
fit.stl.4

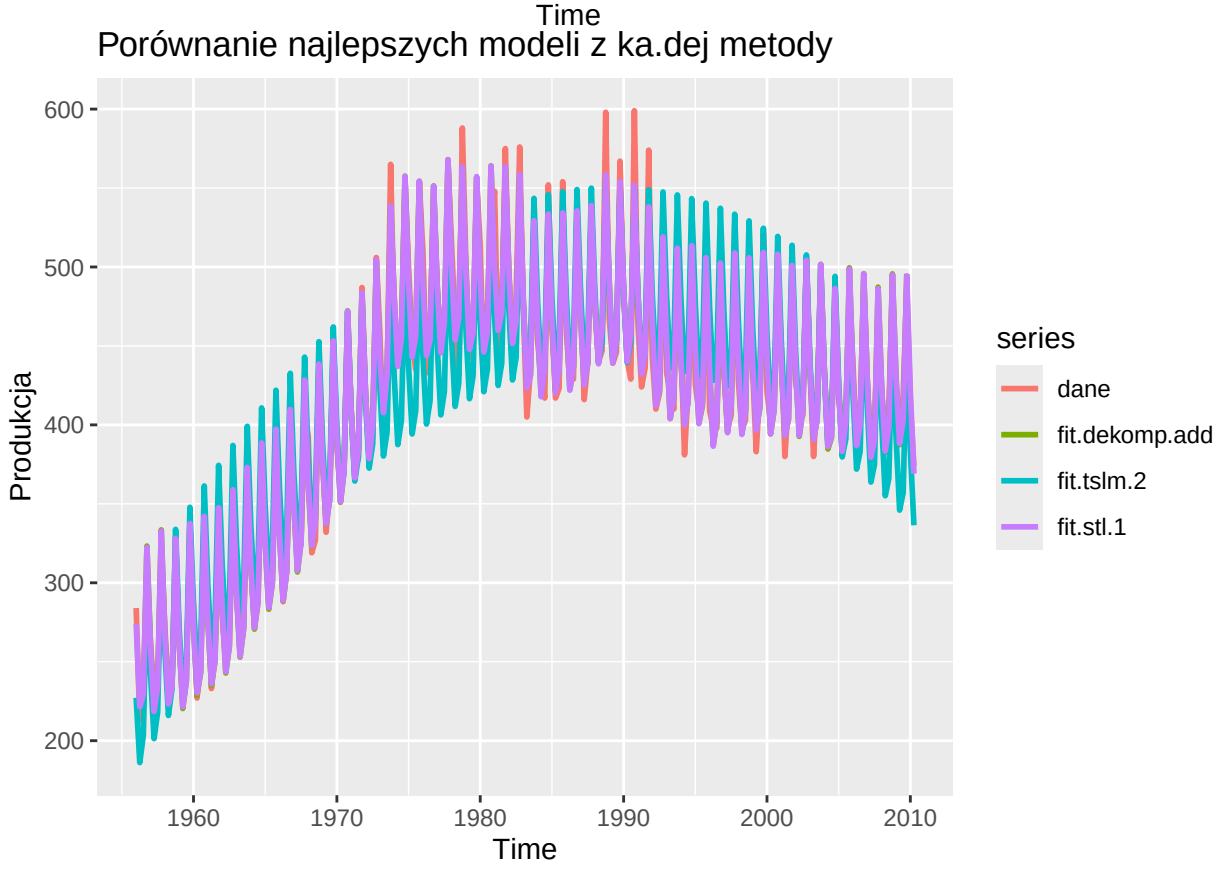
Porównanie najlepszych modeli z ka.dej metody
Produkcja
600
500
400
300
200
1960
1970
1980
1990
2000
2010
Time
series
dane
fit.dekomp.add
fit.tslm.2
fit.stl.1

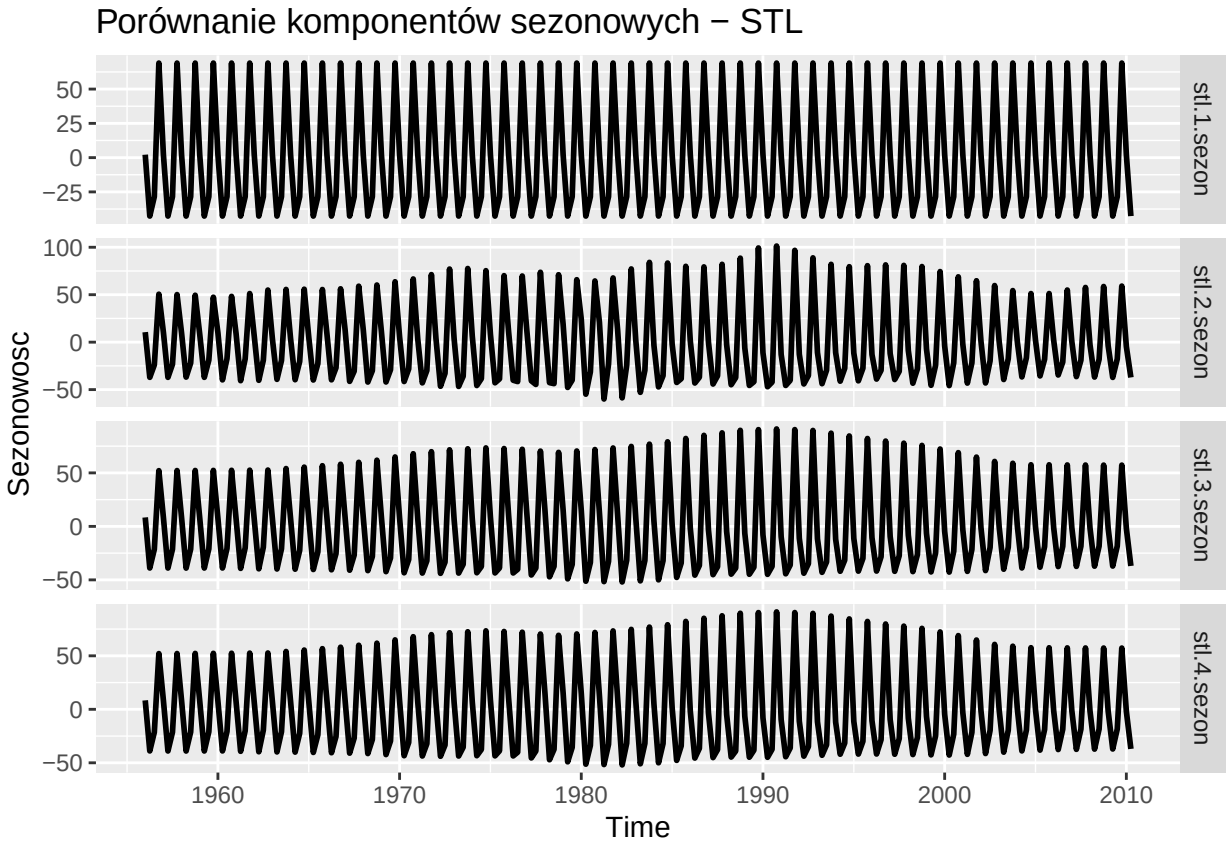

2.0.7 Transformacja Boxa-Coxa

```
## [1] "Optymalna lambda: 0.2047"
```

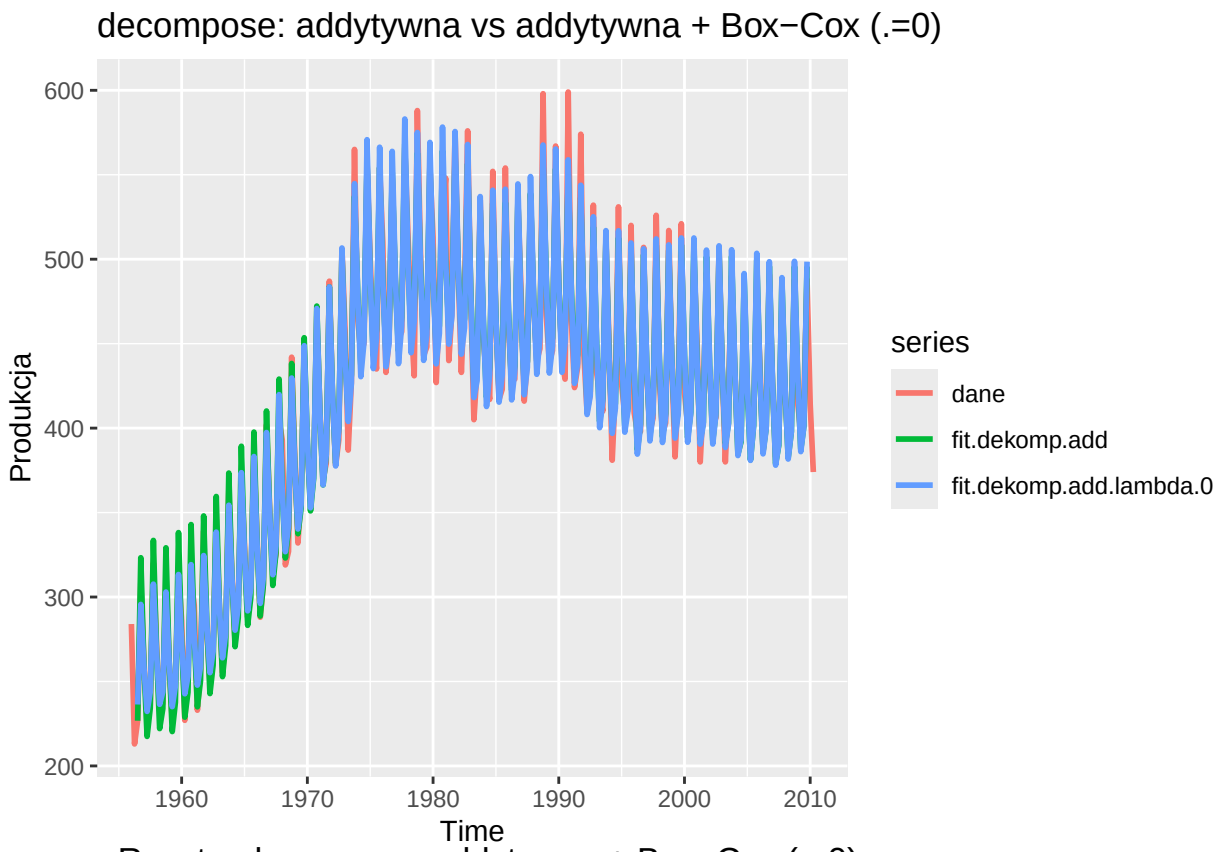
decompose: addytywna vs addytywna + Box−Cox (.=0)
Produkcja
Time
series
dane
fit.dekomp.add
fit.dekomp.add.lambda.0

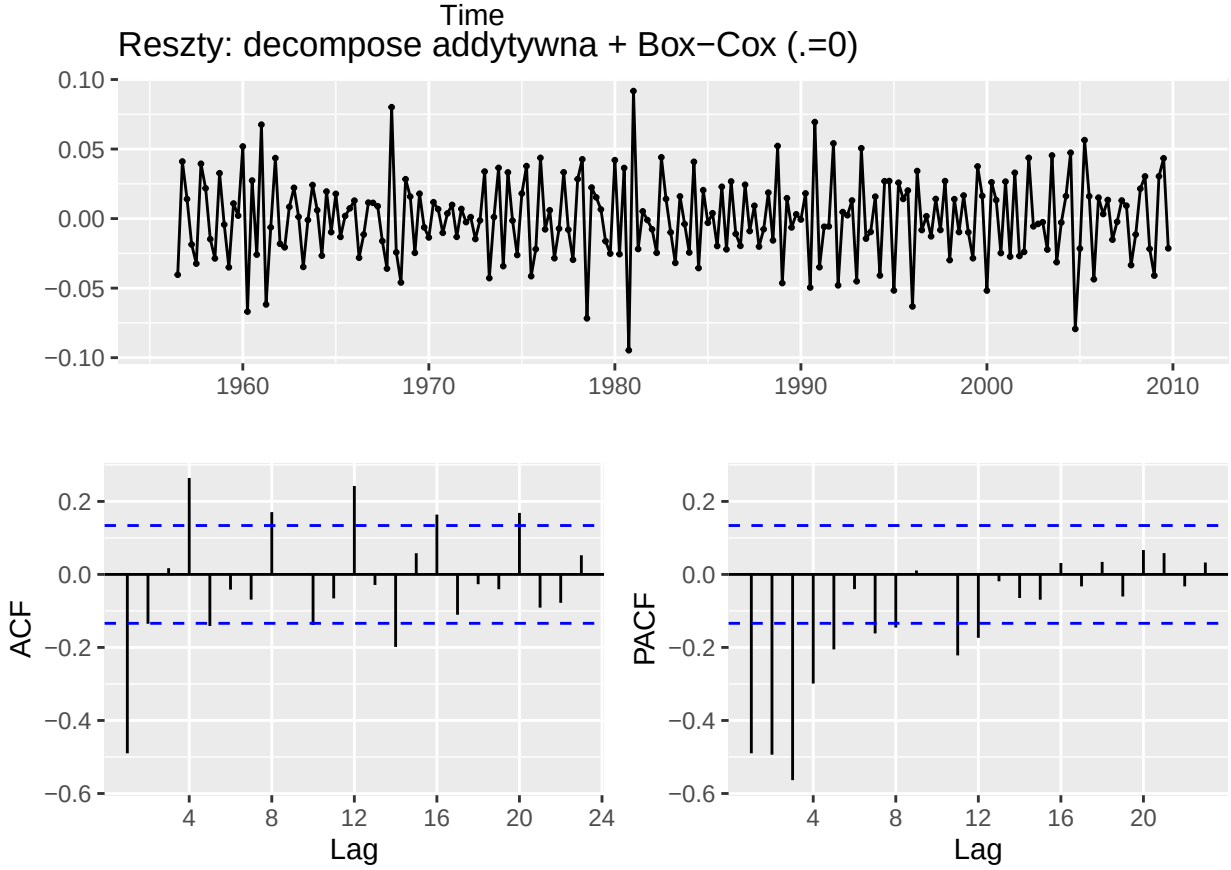
Reszty: decompose addytywna + Box−Cox (.=0)
ACF
Lag
PACF
Lag

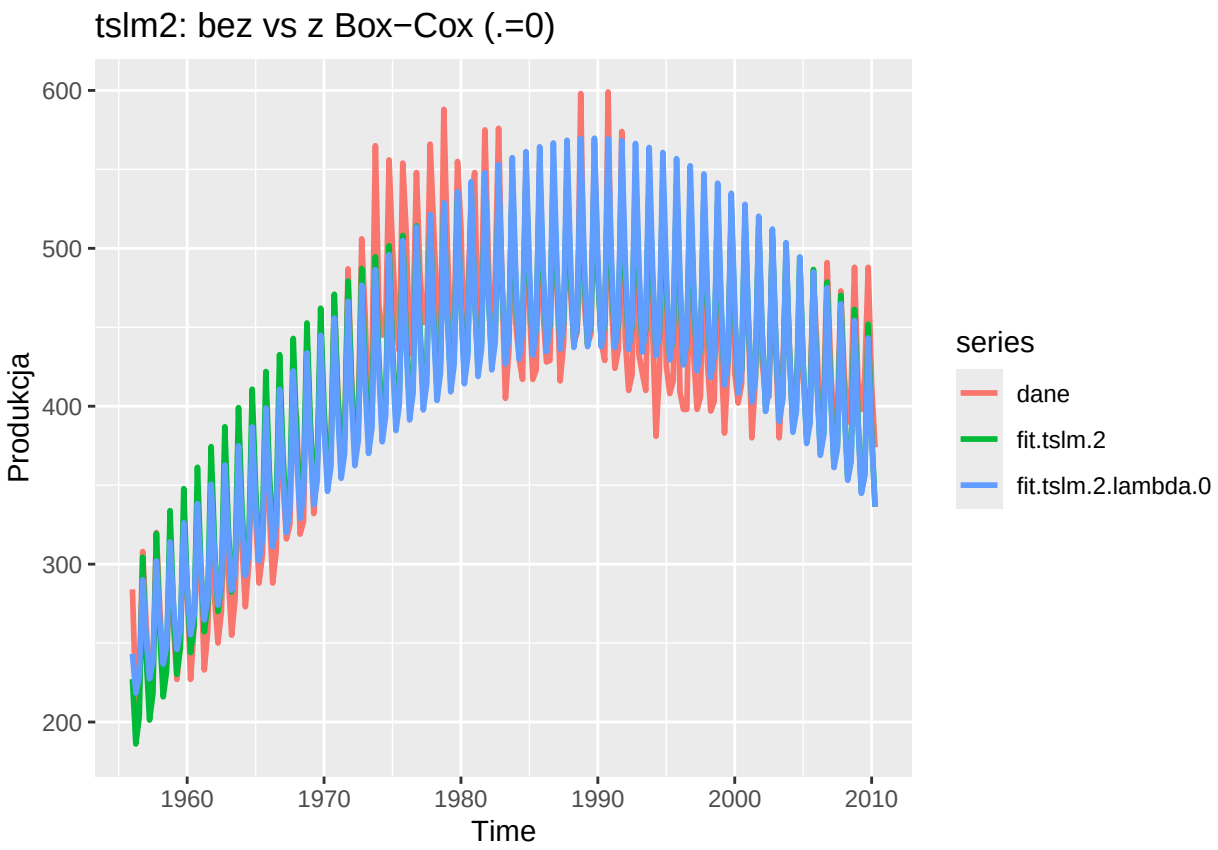


```
## [1] "Porównanie R² dla tslm:"
## [1] "tslm2 bez Box-Cox: R² = 0.8909"
## [1] "tslm2 z Box-Cox:   R² = 0.907"
```

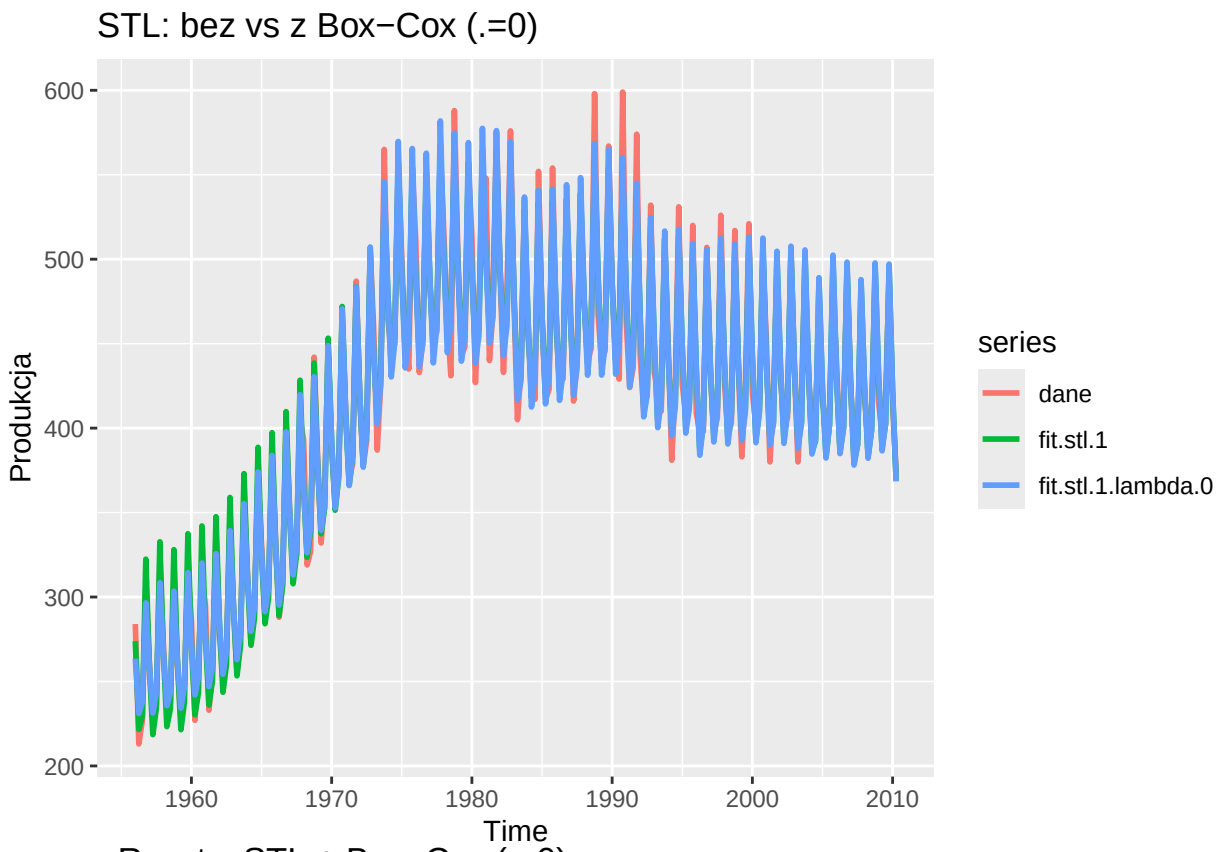

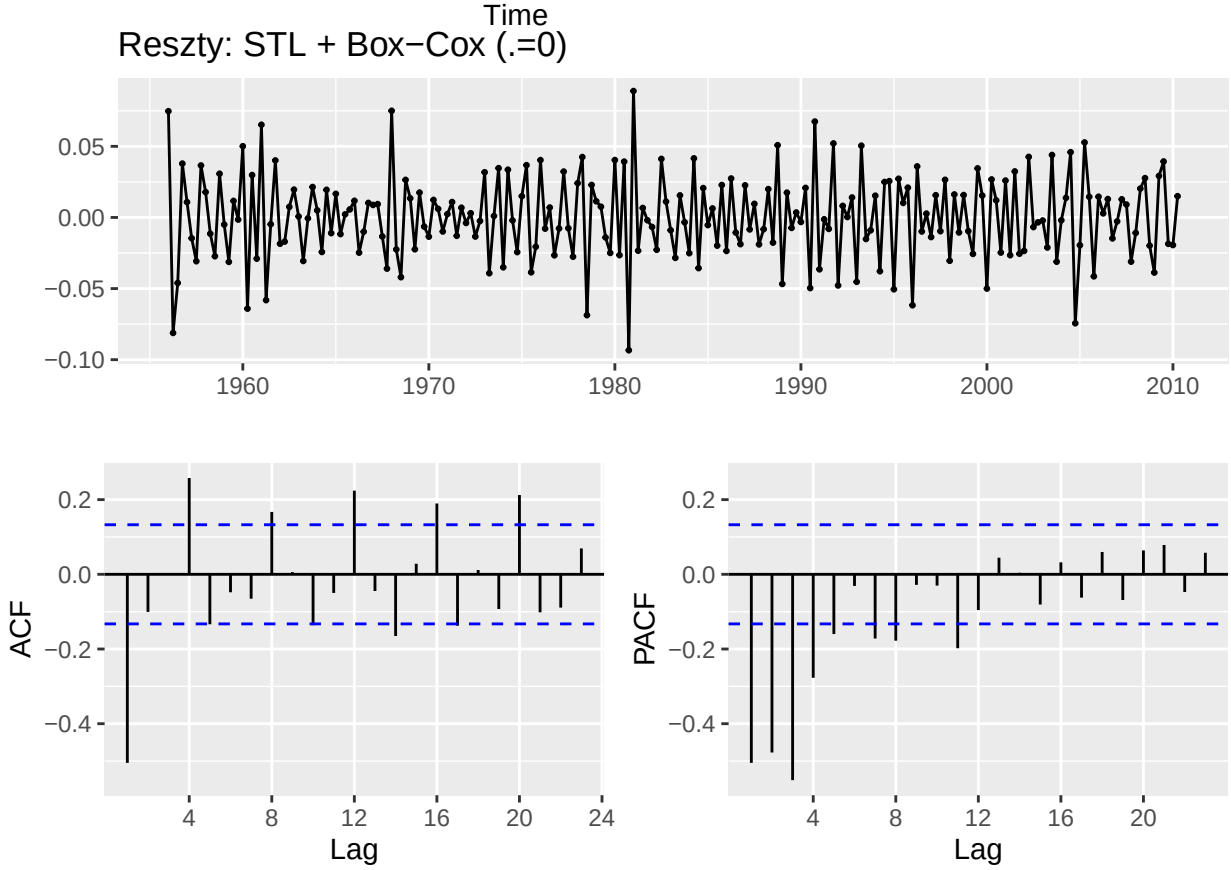

Wnioski dla transformacji Box-Cox:

- Lambda bliska 0 (logarytm) potwierdza, że mamy do czynienia z zależnością multiplikatywną. Transformacja ta skutecznie stabilizuje wariancję (amplitudę wahań sezonowych), co widać na porównaniu wykresów, gdzie niebieski wykres (z Box-Cox) ma równiejsze "górki i dołki" niż zielony.
- Transformacja może poprawić stabilność wariancji
- Box-Cox z modelem addytywnym daje rezultaty zbliżone do multiplikatywnego

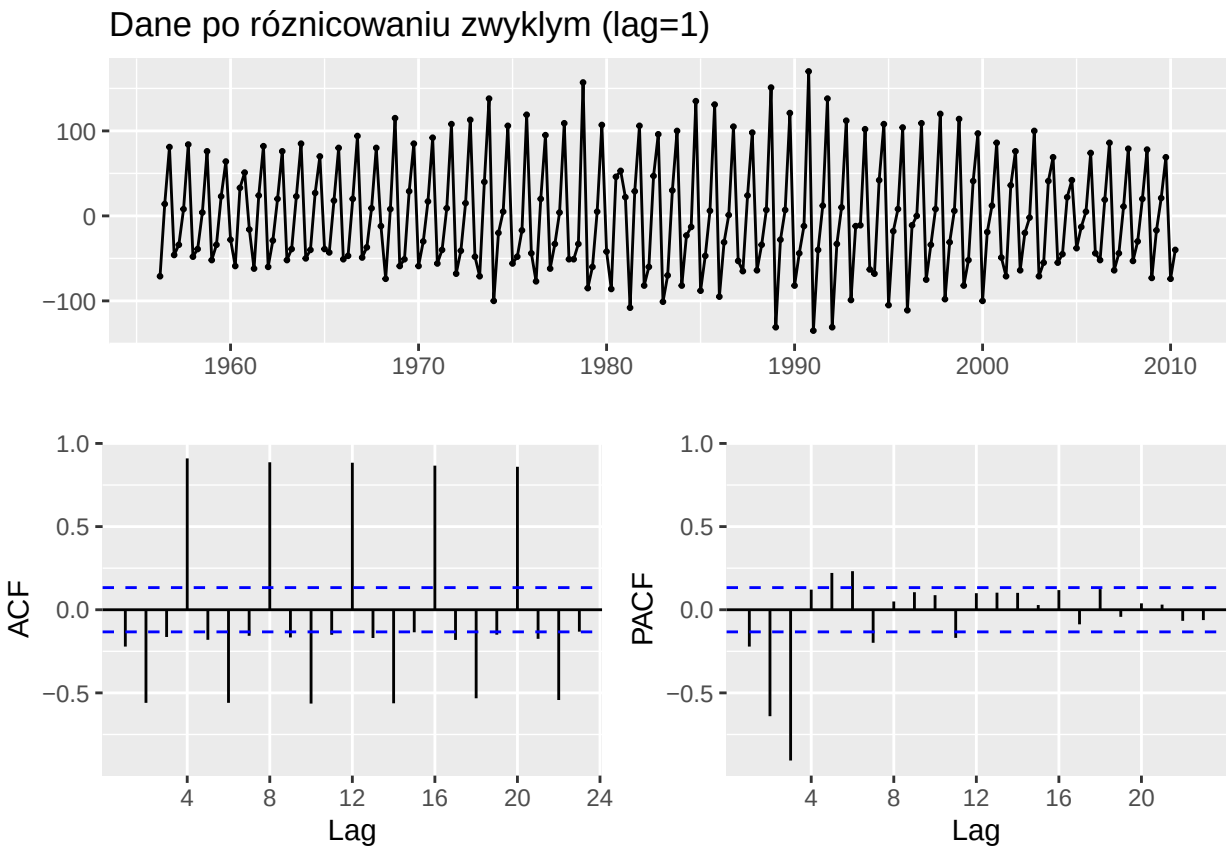

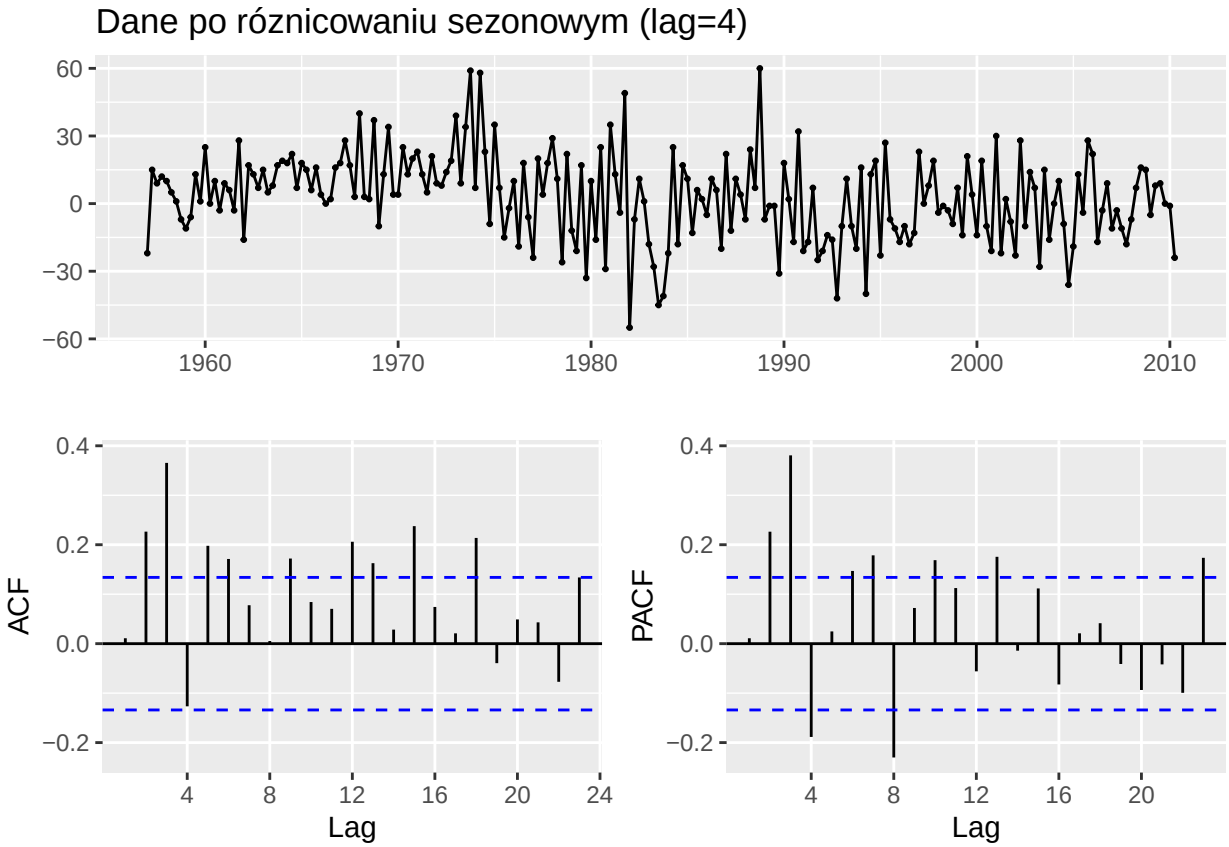

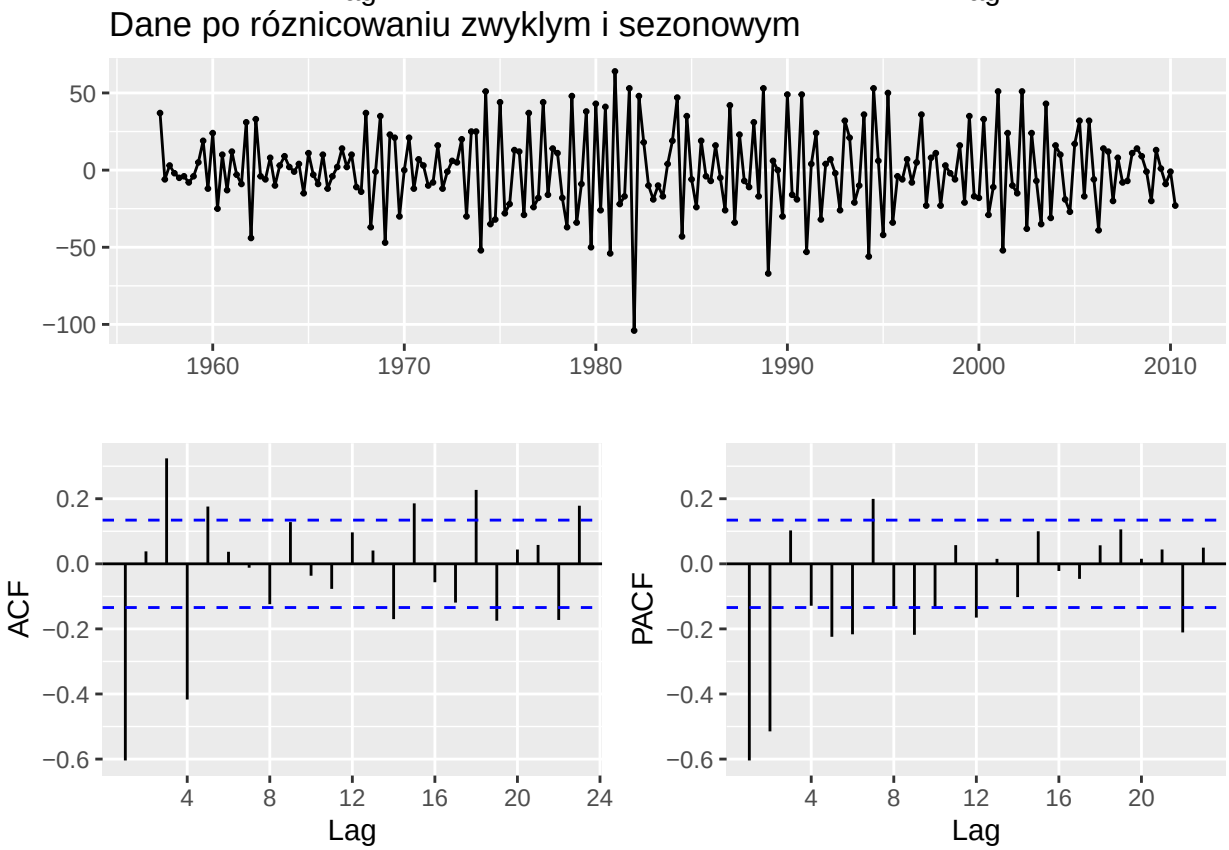

Wnioski dla różnicowania:

- Samo różnicowanie lag=1 usuwa trend, ale zostawia wyraźną sezonowość (regularne fale na wykresie ACF).
- Samo różnicowanie lag=4 usuwa sezonowość, ale zostawia trend (wykres nie oscyluje wokół zera).
- Dopiero podwójne różnicowanie daje reszty przypominające biały szum (brak wystających słupków w ACF poza lag 0). Jest to najskuteczniejsza metoda uzyskania stacjonarności pod kątem np. modelowania ARIMA.

PODSUMOWANIE KOŃCOWE

1. **Charakterystyka szeregu**: Szereg wykazuje nieliniowy trend (wzrost do lat 70., stabilizacja, lekki spadek), a nie malejący w całym okresie. Występuje wyraźna, silna sezonowość kwartalna o rosnącej amplitudzie w pierwszej części szeregu.
2. **Dekompozycja** decompose(): Model multiplikatywny jest bardziej adekwatny niż addytywny ze względu na zmienną amplitudę wahań sezonowych. Reszty modelu addytywnego wykazują niejednorodność wariancji.
3. **Regresja** tslm(): Model liniowy (Model 1) jest niewystarczający, co potwierdza paraboliczny kształt reszt. Wysokie R^2 jest mylące. Warto jest użyć wielomianu 3. stopnia (Model 3), aby poprawnie odwzorować zmianę kierunku trendu, co potwierdza najniższe kryterium AIC.
4. **Metoda STL**: Okazała się najbardziej elastyczna w dopasowaniu nieliniowego trendu, generując reszty o najlepszych właściwościach (najbliższe losowości) spośród metod dekompozycji.
5. **Stacjonarność**: Najlepszym sposobem na sprowadzenie szeregu do stacjonarności (niezbędnej np. dla ARIMA) okazało się podwójne różnicowanie: zwykłe (d=1) oraz sezonowe (D=1,lag=4).