Sprawozdanie z listy 2

Analiza szeregów czasowych

Tadeusz Jagniewski, album 277522

2026-02-03

Spis treści

1 Dopasowanie modeli autoregresji do szeregu gtemp_both **1**
1.1 Sprawdzenie stacjonarności danych i transformacja . . . 1
1.2 Wybór optymalnych rzędów modeli autoregresji (p) . . . 6
1.3 Wyznaczenie estymatorów parametrów . . . 8
1.4 Statystyczna istotność współczynników . . . 9
1.5 Weryfikacja poprawności dopasowania modeli . . . 10
1.6 Prognozowanie . . . 11
1.7 Końcowe wnioski . . . 13

2 Porównanie dokaładności prognoz dla danych *euretail* **13**
2.1 Wstępna analiza i podział danych na zbiór uczący i testowy . . . 13
2.2 Dopasowanie modeli do danych . . . 15
2.3 Prognozy na zbiorze testowym wybranych modeli . . . 28
2.4 Porównaie dokładności prognoz . . . 33
2.5 Wnioski Końcowe . . . 35

1 Dopasowanie modeli autoregresji do szeregu gtemp_both

Dane gtemp_both przedstawiają odchylenia średniej rocznej temperatury (na powierzchni lądów i oceanów) w latach 1850-2023, mierzone względem średniej temperatury globalnej wyznaczonej dla okresu 1991-2020. Celem zadania jest przeprowadzenie kompletnej analizy związanej z dopasowaniem i diagnostyk¡ (weryfikacji poprawności dopasowania) modeli autoregresji (AR(p)).

1.1 Sprawdzenie stacjonarności danych i transformacja

Najpierw przyjrzyjmy się wykresom danych *gtemp_both*

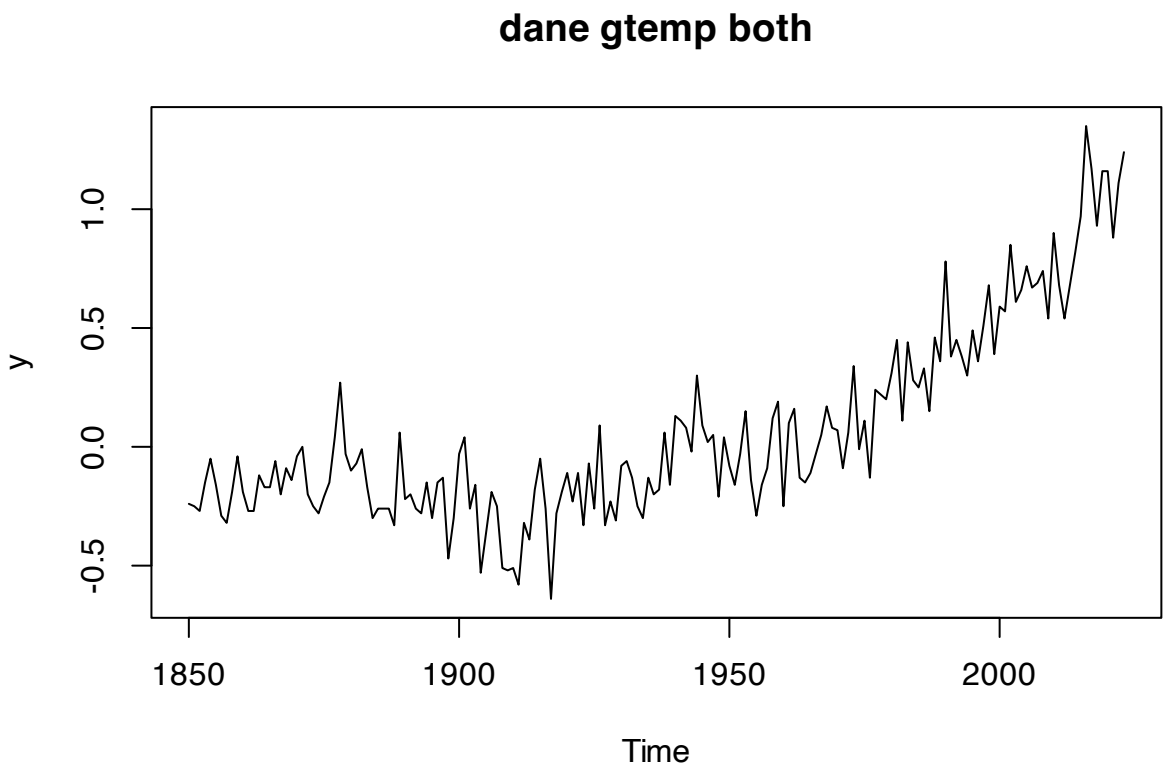

Na wykresie widać ewidentnie trend długoterminowy rosnący, jednak ciężko stwierdzić, czy jest on liniowy czy kwadratowy. Na wykresie za to na pewno nie ma wyraźniej sezonowości i wahania wookół trendu wydają się być losowe.

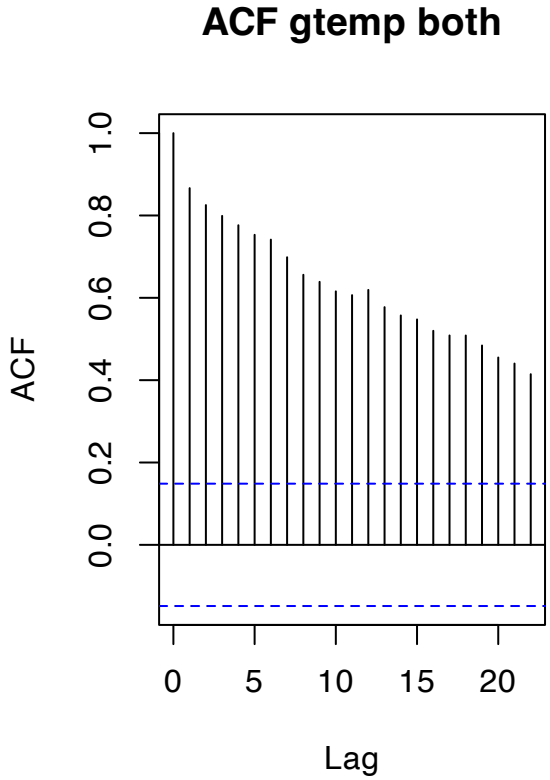

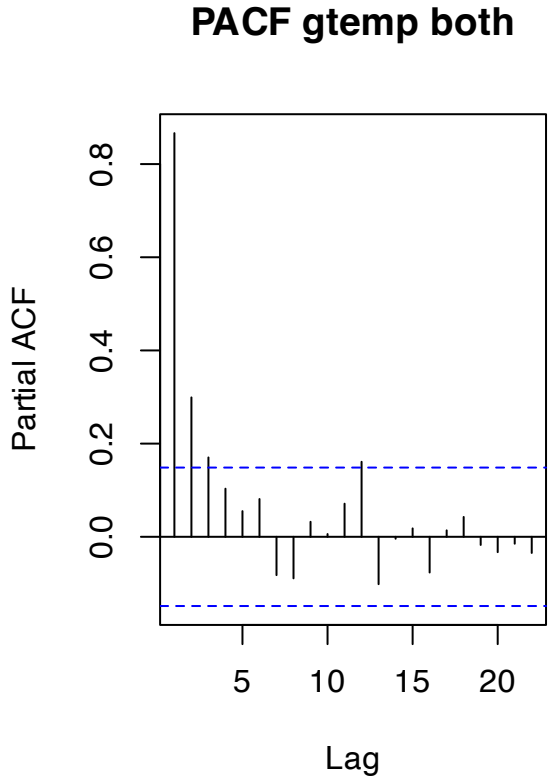

Wykres ACF potwierdza istnienie trendu, ponieważ powoli zanika wraz z rozsnącym opóźnieniem. PACF

urywa się po opóźnieniu h=3, ale jest to dopiero analiza wstępna, więc wynika to raczej z niestacjonarności danych.

1.1.1 Różnicowanie

Teraz zastosuje na danych różnicowanie używając funkcji *diff*.

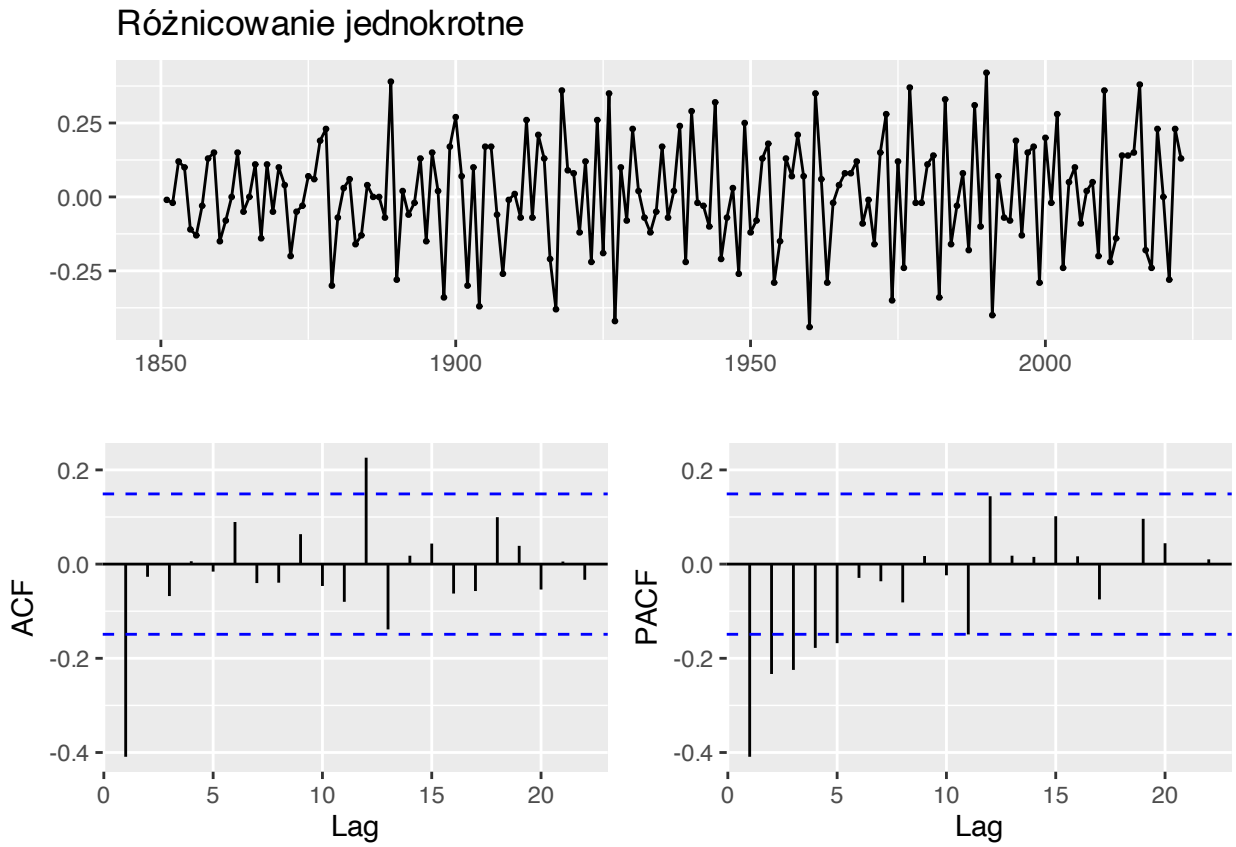

Po pojedyńczym różnicowaniu dane na głównym wykresie wyglądają na praktycznie stacjonarne, jednak znaczące ujemne przekroczenie przedziału ufności dla h=1 na wykresie ACF i urwanie wykresu PACF dopiero po h=5 zostawia pewne wątpliwości.

Wniosek: po *diff()* wygląda na stacjonarny, ale zdecydowanie nie jest białym szumem (zależności zostają), ale z racji że mam wątpliwości spróbuję jeszcze wykonać różnicowanie 2 rzędu.

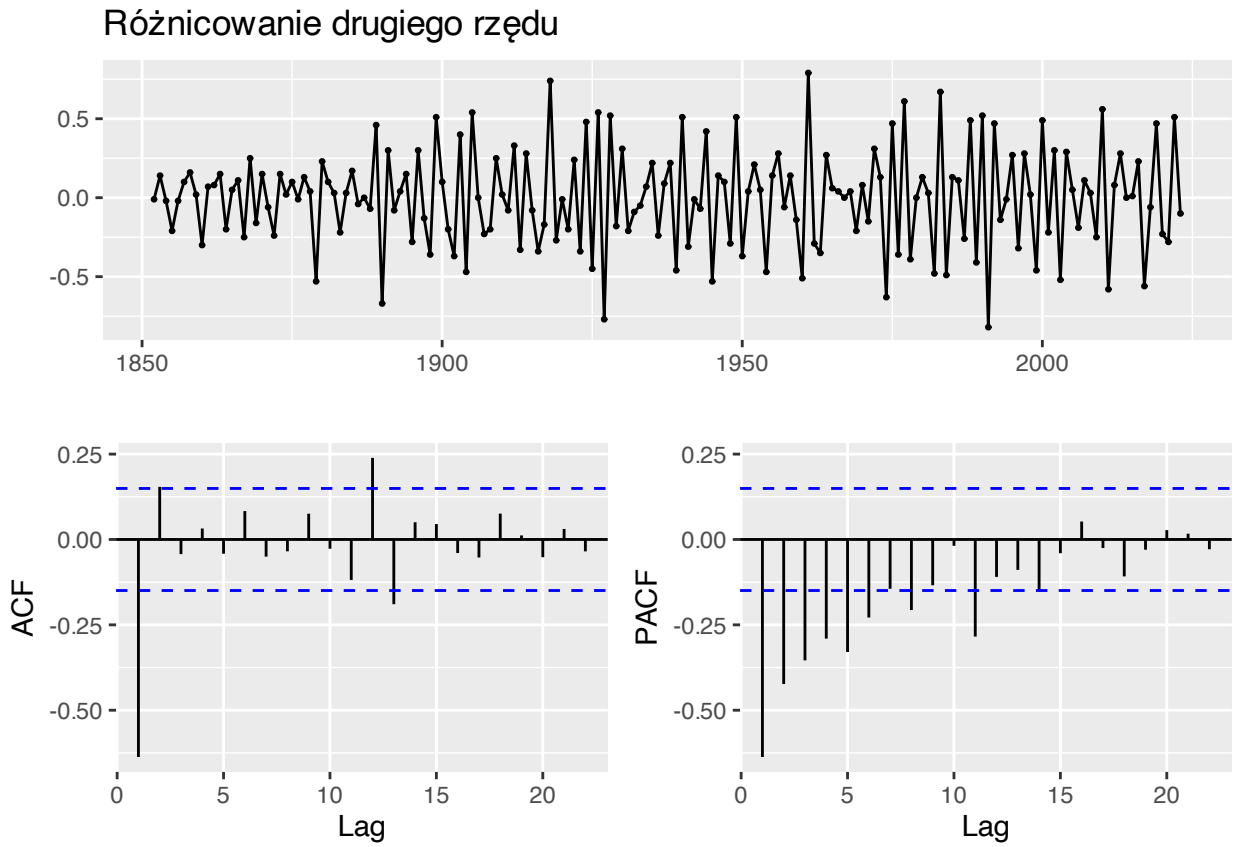

Jeszcze większa wartość ujemna dla h=1 na wykresie ACF oraz większa ilość opóźnień przekraczających przedział ufności na wykresie PACF jasno świadczą, że doszło do tzw. over-differencing. Z resztą nawet wykres nad ACF i PACF również tak średnio przypomina model stacjonarny.

Wobec tego wybieram rząd p modelu autoregresji zgodnie z wykresem PACF dla pojedyńczego różnicowania. Według niego ten rząd w modelu AR powinien wynosić $\mathbf{p_1 = 5}$.

1.1.2 Eliminacja trendu wielomianowego

Spróbuję dopasować trend kwadratowy:

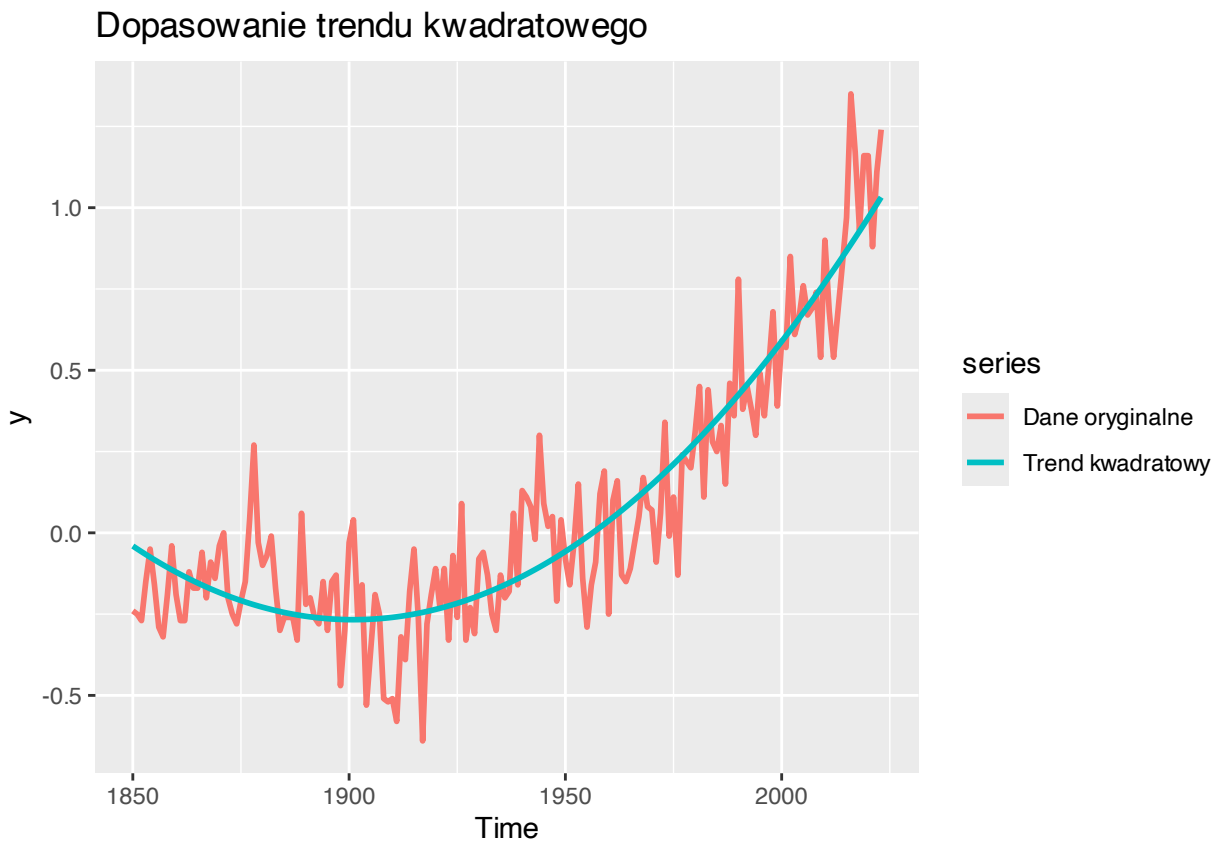

Trend kwadratowy na tym wykresie wygląda na dopasowany prawie idealnie. Wyeliminuje go i przyjrzę się resztom.

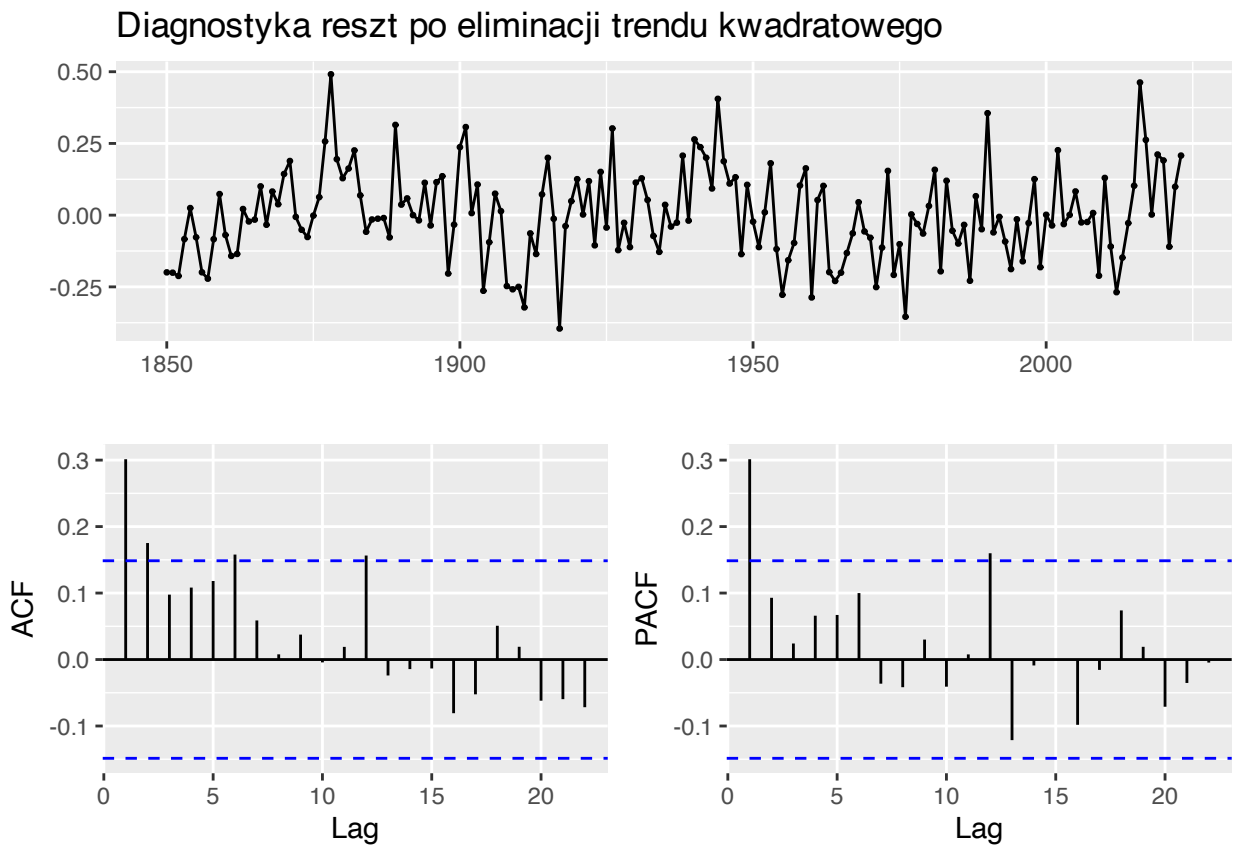

Po odjęciu trendu kwadratowego reszty też wyglądają na serię o stałej średniej i bez trendu, a ACF/PACF poza opóźnieniem h=1 nie przekraczają znacząco przedziału ufności. To również wskazuje na stacjonarność.

Wnioski: Z racji, że trend kwadratowy dopasował się prawie idealnie i reszty wyglądają na stacjonatne, myślę, że w tym przypadku nie trzeba przypasowywać trendu wielomianowego większego stopnia. Dodatkowo wariancja jest stała w czasie, więc nie będę stosował żadnej transformacji.

Na podstawie wykresu PACF wybieram rząd p w modelu autoregresji AR $\mathbf{p_2 = 1}$.

1.2 Wybór optymalnych rzędów modeli autoregresji (p)

Z wykresów PACF wyznaczyłem rząd $\mathbf{p_1 = 5}$ oraz $\mathbf{p_2 = 1}$ odpowiednio dla różnicowania oraz eliminacji trendu kwadratowego. Teraz jednak posłużę się dodatkowymi kryteriami jakimi są AIC i FPE. Wartość p_{max} wyznaczam za pomocą *p.max <-floor(10 * log10(n))*, gdzie n to ilość danych.

1.2.1 Dane po różnicowaniu

Najpierw przyjrzę się jak kryteria działają na dane po różnicowaniu:

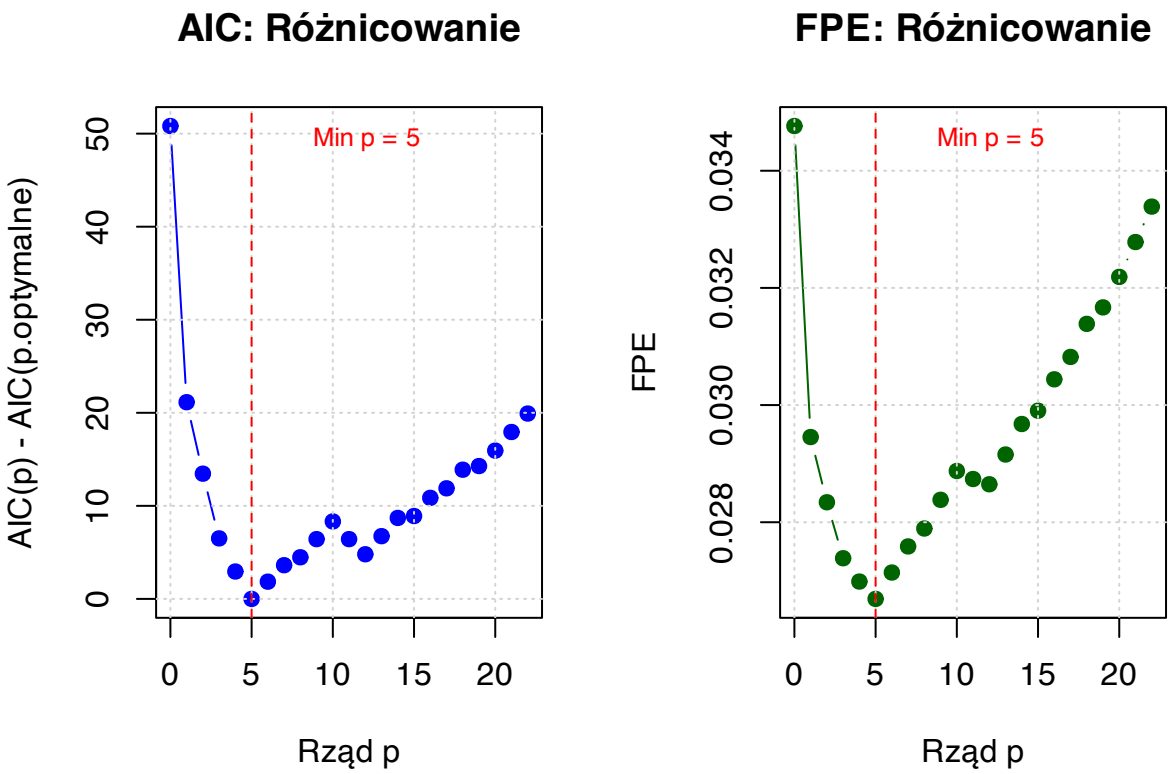

Jak widać na powyższym wykresie obydwa kryteria nie mają wątpliwości, co do tego jaki powinien być rząd modelu AR(p) i wybierają ten rząd zgodnie z analizą graficzną, więc p dla danych po jednokrotnym różnicowaniu wynosi $\mathbf{p_1 = 5}$.

1.2.2 Dane po eliminacji trendu kwadratowego

Znowu przyjrzę się wykresom kryteriów, aby wyznaczyć rząd p modelu AR(p) tylko tym razem będą to dane po eliminacji trendu kwadratowego.

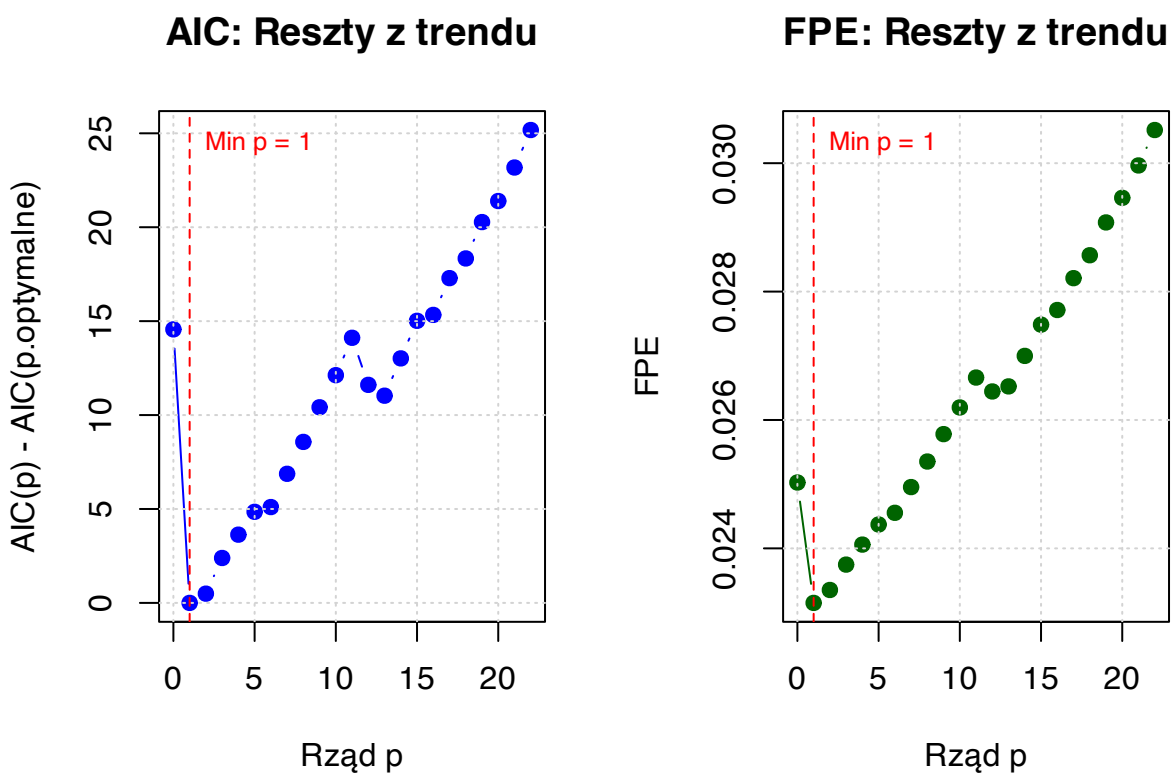

Po raz kolejny analiza PACF nie zawiodła i kryteria wybrały taki sam rząd modelu AR(p) jakim jest $\mathbf{p_2 = 1}$.

1.3 Wyznaczenie estymatorów parametrów

W tym zadaniu wyznaczę estymatory parametrów do zidnetyfikowanych modeli autoregresji, porównując metody Yule'a-Walkera (YW - estymacja wstępna) oraz metody największej wiarogodności (mle).

Najpierw sprawdzę dane po różnicowaniu z rzędem autoregresji $\mathbf{p_1 = 5}$:

Tabela 1: Porównanie współczynników AR (Dane zróżnicowane)

	Parametr	YW Est.	YW SE	MLE Est.	MLE SE
ar1	phi_1	-0.6267	0.0763	-0.6312	0.0747
ar2	phi_2	-0.4626	0.0878	-0.4699	0.0860
ar3	phi_3	-0.3922	0.0898	-0.3940	0.0880
ar4	phi_4	-0.2780	0.0878	-0.2812	0.0860
ar5	phi_5	-0.1678	0.0763	-0.1719	0.0747

Tabela 2: Statystyki modelu (Dane zróżnicowane)

	Statystyka	YW	MLE
	Wariancja szumu (sigma^2)	0.02519	0.02417
intercept	Średnia procesu (mu)	0.00855	0.00783

Wnioski:

1. Stabilność i zbieżność metod: Wyniki uzyskane metodą Yule'a-Walkera oraz metodą Największej Wiarogodności są do siebie bardzo zbliżone. Niewielkie różnice między estymatorami współczynników świadczą o tym, że dla tak długiego szeregu czasowego estymatory asymptotyczne zachowują się stabilnie.

2. Istotność statystyczna parametrów: Analizując iloraz estymatora do jego błędu standardowego ($\hat{\phi}/SE$), można zauważyć, że dla wszystkich pięciu parametrów wartość (modułu) ta przekracza 2.

- Przykładowo dla ϕ_5 w metodzie MLE: $-0.1719/0.0747 \approx 2.30$, co jest wartością większą od 1.96 (wartość krytyczna dla poziomu ufności 95%).
- Oznacza to, że wszystkie współczynniki są statystycznie istotne, co potwierdza słuszność wyboru rzędu p=5 zasugerowanego wcześniej przez wykres PACF (i ewentualnie kryterium AIC).

3. Przewaga metody MLE: Metoda Największej Wiarogodności (MLE) charakteryzuje się nieco mniejszymi błędami standardowymi (SE) estymatorów oraz niższą estymowaną wariancją białego szumu. Wskazuje to na wyższą efektywność metody MLE i lepsze dopasowanie modelu do danych, dlatego to wyniki z kolumny MLE powinny być brane pod uwagę w ostatecznej postać modelu.

Teraz przyjrzę się danym z wyeliminowanym trendem kwadratowym i rzędem autoregresji $\mathbf{p_2 = 1}$.

Tabela 3: Porównanie współczynników AR (Reszty z trendu)

	Parametr	YW Est.	YW SE	MLE Est.	MLE SE
ar1	phi_1	0.3013	0.0727	0.3054	0.0722

Tabela 4: Statystyki modelu (Reszty z trendu)

	Statystyka	YW	MLE
	Wariancja szumu (sigma^2)	0.022886	0.0225789
intercept	Średnia procesu (mu)	0.000000	0.0000002

Wnioski:

1. Dodatnia autokorelacja: Współczynnik ϕ_1 wynosi ok. 0.3 (dla obu metod). Jest to wartość dodatnia, co stoi w kontraście do wyników dla danych zróżnicowanych (gdzie dominowały wartości ujemne). Oznacza to, że po odjęciu głównego trendu ocieplenia, w systemie klimatycznym nadal występuje pewna "krótka pamięć" lub bezwładność – rok cieplejszy od krzywej trendu zwiększa szansę, że kolejny rok również będzie nieco cieplejszy od trendu.

2. Istotność statystyczna: Wartość statystyki t-Studenta dla metody MLE wynosi t=0.3054/0.0722 $\approx$ 4.23. Ponieważ |t|>1.96. parametr ϕ_1. jest wysoce istotny statystycznie. Potwierdza to, że same reszty nie są jeszcze szumem białym i wymagają modelowania autoregresją.

3. Porównanie metod: Metoda MLE osiąga jednak minimalnie niższą wariancję reszt, co sugeruje, że model dopasowany tą metodą jest nieznacznie lepszy w wyjaśnianiu zmienności danych.

4. Skuteczność redukcji wariancji: Wariancja szumu w tym modelu jest niższa niż wariancja modelu dla danych zróżnicowanych. Sugeruje to, że podejście oparte na eliminacji deterministycznego trendu (kwadratowego) i modelowaniu reszt jako AR(1) pozwala na precyzyjniejszy opis danych gtemp_both niż proste różnicowanie.

1.4 Statystyczna istotność współczynników

Już w poprzednim zadaniu we wnioskach, wspominałem o tym ale w tym podrozdziale rozwinę ten temat. Zgodnie z twierdzeniem o asymptotycznej normalności estymatorów (np. Yule'a-Walkera lub Największej Wiarogodności), dla dużych prób estymatory parametrów $\hat{\phi}$ mają rozkład normalny: $\hat{\phi}_i \sim \mathcal{N}(\phi_i, SE(\hat{\phi}_i)^2)$.

Na tej podstawie konstruuje asymptotyczny przedział ufności na poziomie ufności 1 - α (standardowo 95%, dla $\alpha = 0.05$):

$$\left[\hat{\phi}_i - u_{1-\alpha/2} \cdot SE(\hat{\phi}_i), \hat{\phi}_i + u_{1-\alpha/2} \cdot SE(\hat{\phi}_i)\right]$$

gdzie $u_{1-\alpha/2}$ to kwantyl rozkładu normalnego (dla 95% wynosi ok. 1.96).

Weryfikacja hipotez:

Testujemy hipotezę $H_0 : \phi_i = 0$ (parametr nieistotny)

przeciwko $H_1 : \phi_i \neq 0$ (parametr istotny)

Jeśli 0 nie należy do przedziału ufności, odrzucamy H_0 (parametr jest istotny statystycznie).

Jeśli 0 znajduje się w przedziale, nie mamy podstaw do odrzucenia H_0.

Na podstawie wartości wyznaczonych metodą MLE w tabelach powyżej, obliczenia wyglądają nastpująco:

1. Model AR(5) dla danych zróżnicowanych

Dla parametru ϕ_5 (który jest najtrudniejszy do obrony, bo najmniejszy):

- $\hat{\phi}_5 = -0.1719$, $SE = 0.0747$
- Przedział ufności: $-0.1719 \pm 1.96 \cdot 0.0747 \approx [-0.3183, -0.0255]$
- Wniosek: Zero nie należy do przedziału. Parametry tego modelu są istotne statystycznie.

2. Model AR(1) dla reszt z trendu

Dla parametru ϕ_1:

- $\hat{\phi}_5 = 0.3054$, $SE = 0.0722$
- Przedział ufności: $0.3054 \pm 1.96 \cdot 0.0722 \approx [0.1639, 0.4469]$
- Wniosek: Zero leży daleko poza przedziałem. Parametr jest silnie istotny statystycznie

W obu przypadkach skonstruowane przedziały ufności potwierdzają, że wybrane rzędy modeli (odpowiednio p=5 i p=1) są poparte istotnością statystyczną wszystkich współczynników.

1.5 Weryfikacja poprawności dopasowania modeli

Dokonam owej weryfikacji na podstawie analizy reszt m.in. z wykorzystaniem testów białoszumowości. Użyję testów Ljung-Box'a oraz Box-Pierce'a do oceny losowości reszt. Do sprawdzenia normalaności posłużę się testami Shapiro-Wilk'a oraz Jarque-Bera.

A oto ich wyniki:

Tabela 5: Diagnostyka reszt: Szereg zróżnicowany (AR(5))

Test	Statystyka	p-value	Interpretacja (alpha=0.05)
Ljung-Box (autokorelacja)	13.7438	0.54504	Biały szum
Box-Pierce (autokorelacja)	12.5291	0.63862	Biały szum
Shapiro-Wilk (normalność)	0.9921	0.48948	Rozkład normalny
Jarque-Bera (normalność)	2.2565	0.32360	Rozkład normalny

Model AR(5) dla szeregu zróżnicowanego przeszedł pomyślnie weryfikację diagnostyczną. Reszty modelu zachowują się jak Gaussowski Szum Biały, co oznacza, że model jest poprawny i może być wykorzystywany do dalszych analiz lub prognozowania.

W poniższej tabeli można zobaczyć jak poradził sobie drugi model

Tabela 6: Diagnostyka reszt: Reszty z trendu kwadratowego (AR(1))

Test	Statystyka	p-value	Interpretacja (alpha=0.05)
Ljung-Box (autokorelacja)	17.0041	0.58959	Biały szum
Box-Pierce (autokorelacja)	15.7514	0.67379	Biały szum
Shapiro-Wilk (normalność)	0.9924	0.50474	Rozkład normalny
Jarque-Bera (normalność)	0.9257	0.62950	Rozkład normalny

Model oparty na eliminacji trendu kwadratowego i procesie AR(1) jest poprawny statystycznie, bo reszty są Gaussowskim Szumem Białym. Co więcej, w porównaniu do modelu dla danych zróżnicowanych (który wymagał aż 5 parametrów autoregresji), model ten jest znacznie bardziej "oszczędny" – opisuje szereg za pomocą tylko jednego istotnego parametru autoregresyjnego oraz deterministycznej funkcji trendu.

1.6 Prognozowanie

Teraz wykorzystam modele autoregresji do konstrukcji prognoz na najbliższe 10 lat do przodu

Najpierw pokażę prognozę modelem różnicowania:

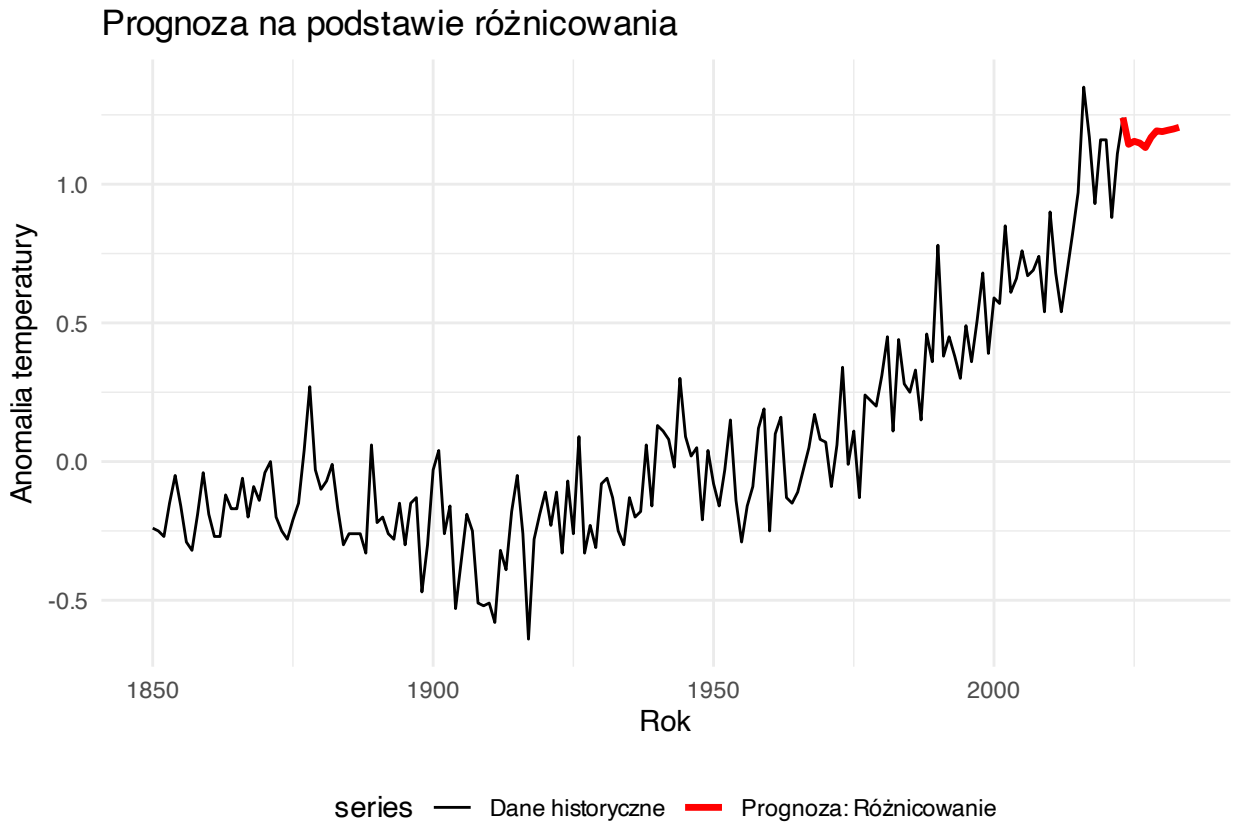

Następnie modelem, który eliminował trend kwadratowy:

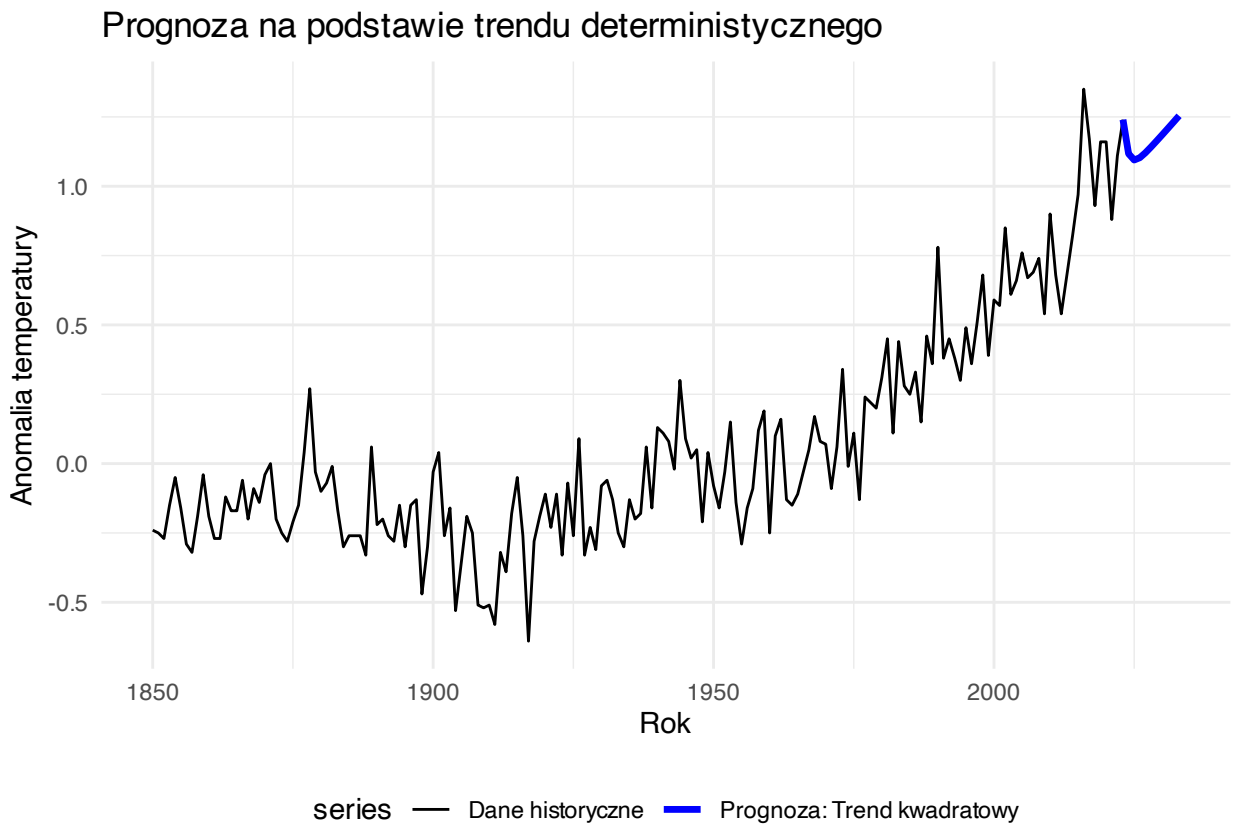

Teraz finalny wykres, na którym najlepiej widać różnice między prognozami

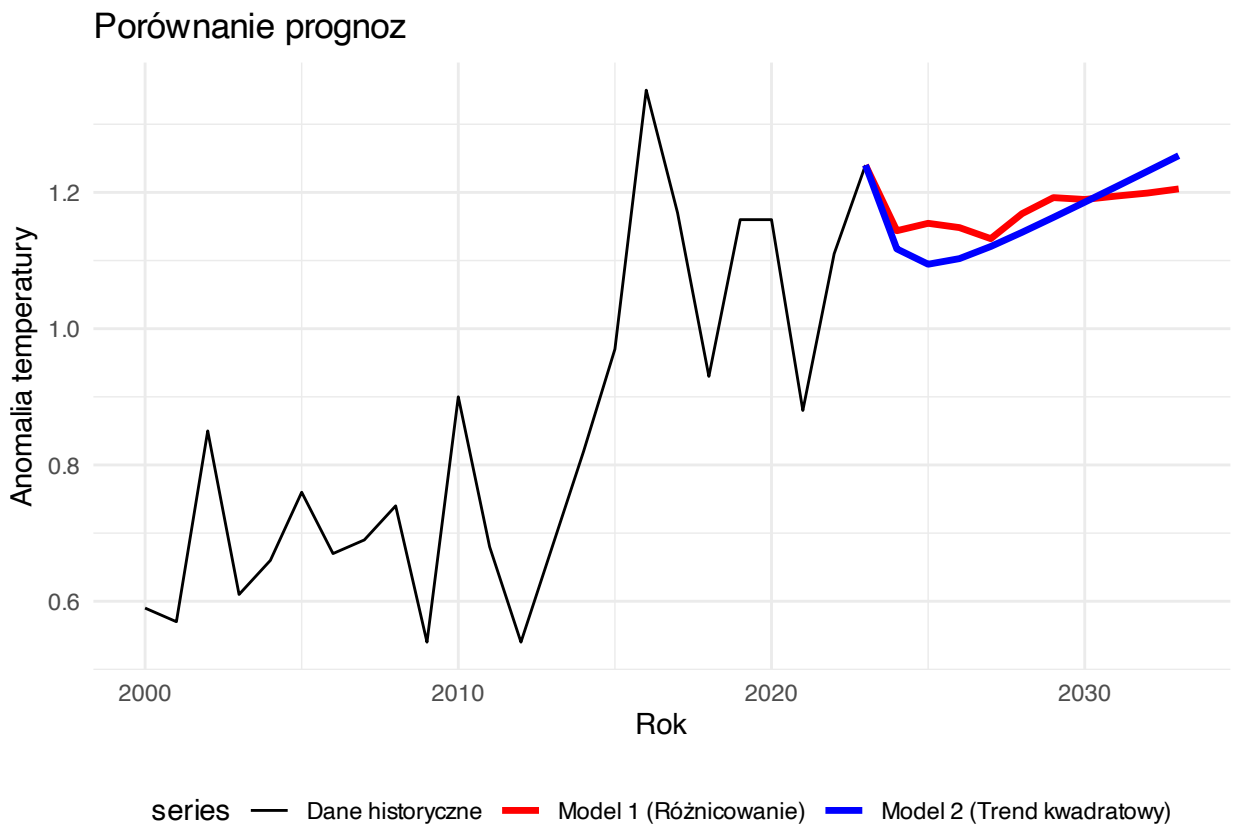

Wykres ukazuje wyraźne różnice w prognozach: model oparty na różnicowaniu (czerwona linia) sugeruje stabilizację anomalii, podczas gdy model z trendem kwadratowym (niebieska linia) przewiduje jej dynamiczny, nieliniowy wzrost po 2026 roku. Wskazuje to, że model uwzględniający deterministyczny trend lepiej oddaje scenariusz przyspieszającego ocieplenia klimatu, w przeciwieństwie do konkurencyjnego modelu, który nie bierze pod uwagę nagłych wzrostów.

1.7 Końcowe wnioski

1. Podejście oparte na eliminacji deterministycznego trendu kwadratowego okazało się bardziej efektywne pod względem ekonomii modelu. Pozwoliło ono na opisanie dynamiki szeregu za pomocą zaledwie jednego istotnego parametru autoregresyjnego (p=1). W przeciwieństwie do tego, model na danych zróżnicowanych wymagał estymacji aż pięciu parametrów (p=5), aby skutecznie wyeliminować autokorelację reszt.
2. Choć oba modele pomyślnie przeszły weryfikację diagnostyczną (reszty w obu przypadkach są Gaussowskim Szumem Białym), model z trendem kwadratowym charakteryzuje się minimalnie lepszym dopasowaniem do danych empirycznych. Świadczy o tym niższa estymowana wariancja składnika losowego w porównaniu do modelu różnicowego.
3. Najistotniejsza różnica ujawnia się w prognozach na lata 2024–2033. Model oparty na różnicowaniu generuje prognozę, sugerującą stabilizację anomalii wokół obecnego poziomu. Z kolei model z trendem deterministycznym przewiduje kontynuację nieliniowego, dynamicznego wzrostu temperatury . Biorąc pod uwagę fizyczną naturę globalnego ocieplenia i widoczne na wykresach przyspieszenie zmian w ostatnich dekadach, model uwzględniający trend kwadratowy wydaje się lepiej oddawać rzeczywisty mechanizm procesów klimatycznych .

Podsumowując, mimo że oba podejścia są poprawne statystycznie, model Trendu Kwadratowego + AR(1) jest preferowany w tej analizie ze względu na prostszą strukturę, mniejszy błąd dopasowania oraz bardziej realistyczną prognozę długoterminową.

2 Porównanie dokaładności prognoz dla danych *euretail*

Głównym celem zadania jest porównanie dokładności prognoz skonstruowanych na bazie modeli (S)ARIMA, modeli dekompozycji oraz lgorytmów wygładzania wykładniczego dla danych *euretail* zawierających kwartyle wartości indeksu handlu detalicznego dla strefy euro.

2.1 Wstępna analiza i podział danych na zbiór uczący i testowy

Na początku wczytajmy dane i przyjrzyjmy się wykresom.

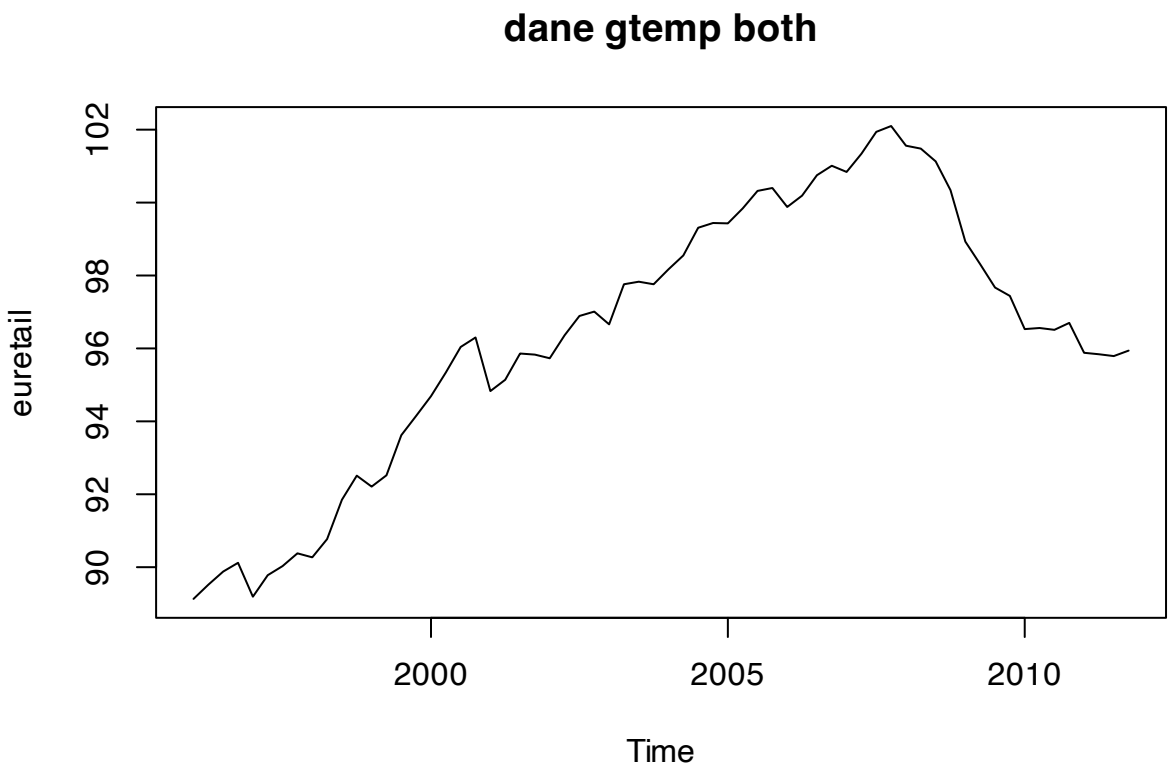

Widać ewidenty trend długoterminowy i potencjalne zalążki sezonowości, sprawdzę jeszcze wykresi ACF i PACF danych.

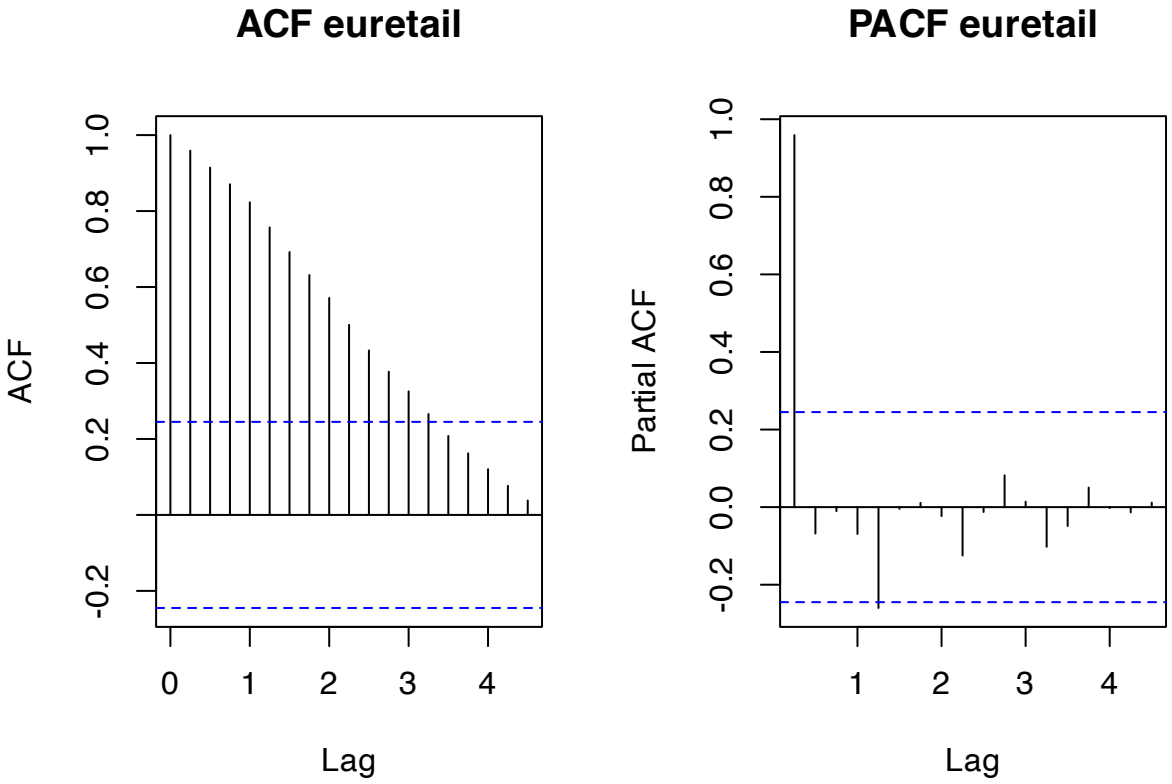

Trend widać bezpodstawnie, aczkolwiek nie widzę sezonowości, co jest sprzeczne z moimi wcześniejszymi założeniami.

Zbadam jeszcze dogłębniej tą sezonowość, używając do tego funkcji *nsdiffs*, która odpowaida na pytanie, czy dane będą potrzebować różnicowania sezonowego (D=1), czy nie (D=0).

```
D <- nsdiffs(euretail)
```

Wartość D wynosi 1, co oznacza, że sezonowość istnieje, ale jest ukryta pod trendem.

2.2 Dopasowanie modeli do danych

2.2.1 Modele (S)ARIMA

Szereg nie wydaje się mieć rosnącej wariancji, więc nie zasosuje żadnej transformacji. Przyjrzę się teraz wykresowi podszeregów.

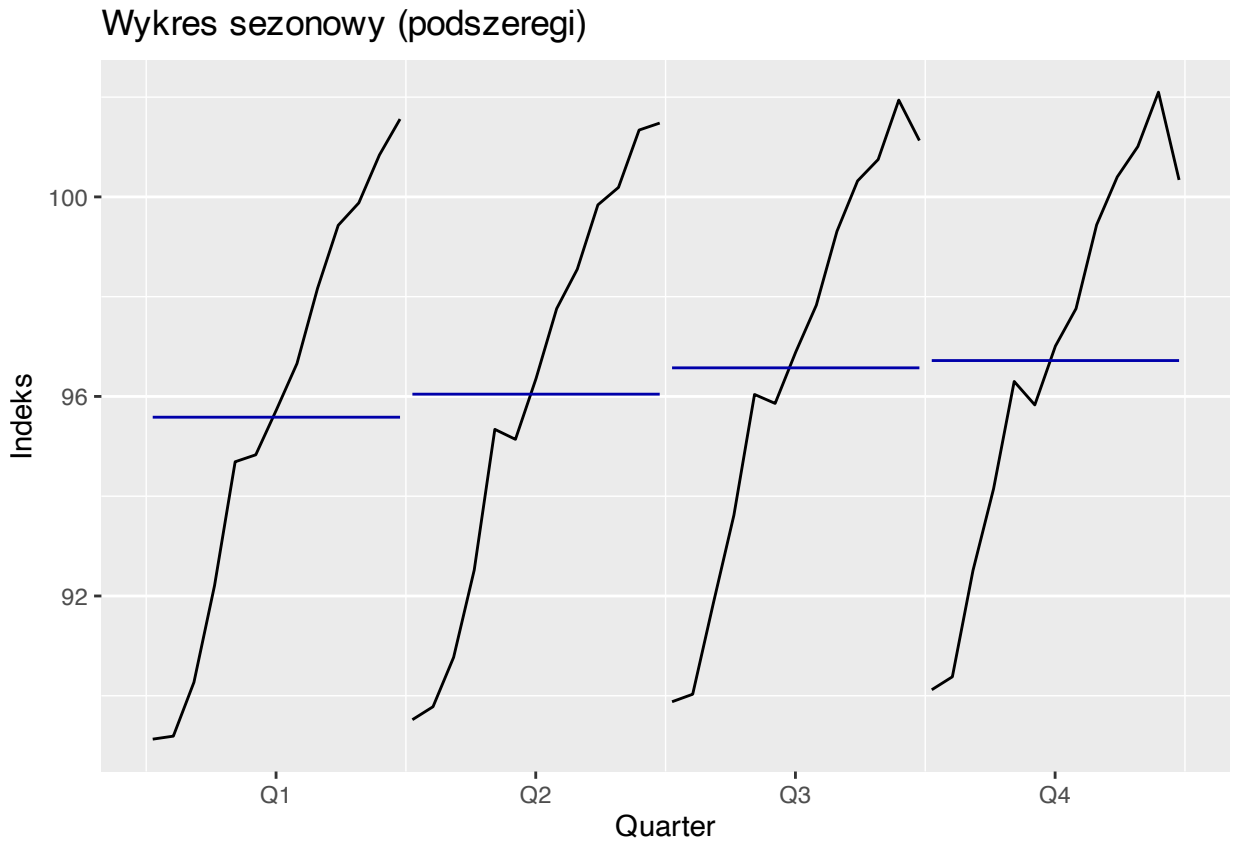

Linie są na minimalnie innym poziomie, co sugeruje sezonowość, co już tak w zasadzie pokazałem w poprzedniej części analizy, kiedy wyszło, że D=1.

Teraz podobną funkcję zastosuję, jak wtedy ale poprotsu dla różnicowania.

```
ndif <- ndiffs(train)
```

Wartość jaką otrzymałem to 2, co sugeruje dwukrotne różnicowanie.

Zastosujmy obydwa różnicowania i przyjrzyjmy się danym:

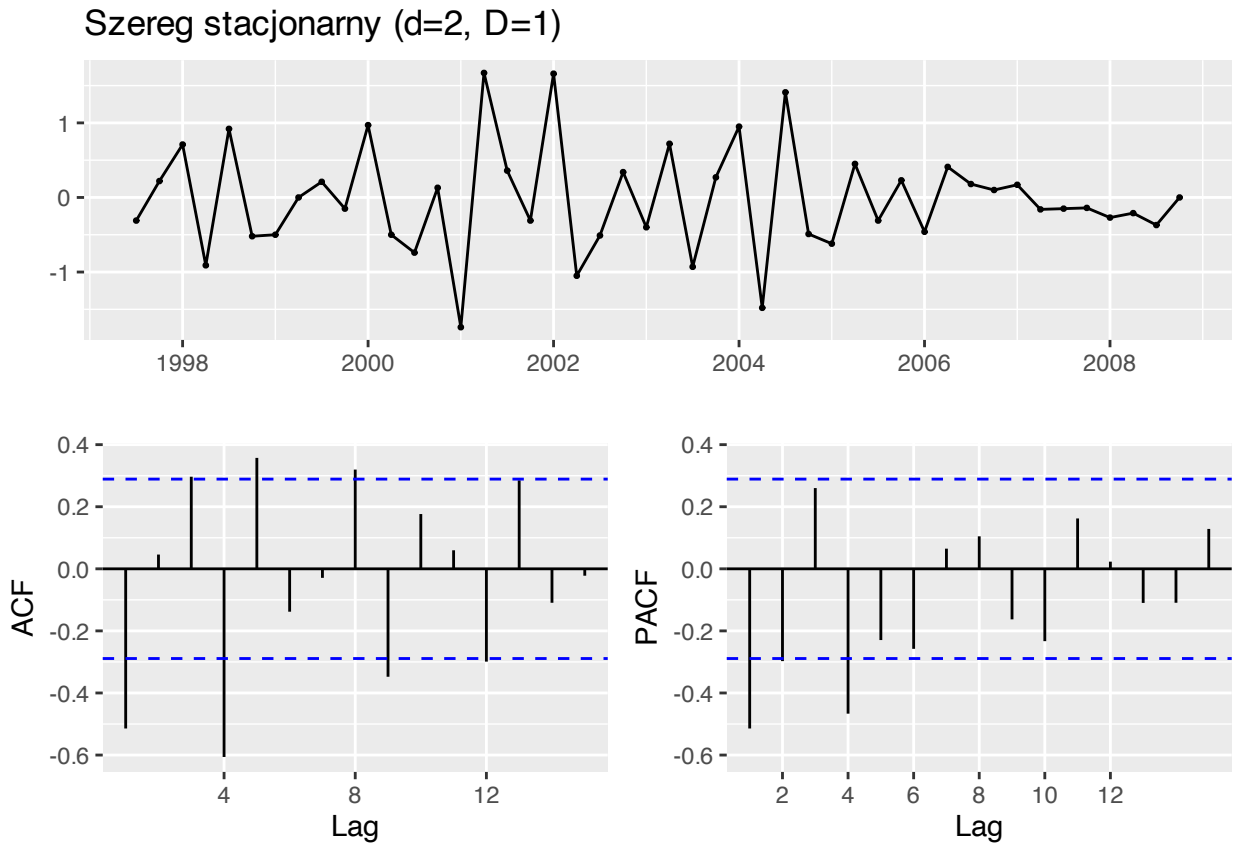

Średnia modelu jest stablina i wynosi -0.025, co jest dobrym znakiem, jednak nieco gorszym są liczne wartości wystające poza przedział ufności na wykresach ACF oraz PACF, próbowałem jednak poza raportem (aby nie był zbyt długi) innych różnicowań i jest jeszcze gorzej, więc spróbuję dobrać model do tego co mam teraz.

Moji kandydaci na model to **ARIMA(0,2,5)x(0,1,0)** oraz **ARIMA(1,2,0)x(0,1,0)**

Do testów wezmę też kilka modeli, bliskich do mojego, oraz kilka automatycznych i sprawdze dla, którego są najlepsze wyniki.

Tabela 7: Porównanie modeli ARIMA (Kryterium AICc)

	Manualny.Auto	Model	AICc
3	Auto 1	ARIMA(1,0,3)(0,1,1)[4]	65.92
4	Auto 2	ARIMA(2,0,0)(1,1,0)[4]	69.31
5	Auto 3	ARIMA(1,0,0)(1,1,0)[4]	69.91
1	Manual 1	ARIMA(0,2,5)(0,1,0)[4]	76.10
2	Manual 2	ARIMA(4,2,0)(0,1,0)[4]	85.98

Modele dobrane automatycznie (Auto) charakteryzują się znacznie lepszym dopasowaniem (niższym AICc) niż modele proponowane manualnie oparte na dwukrotnym różnicowaniu (d=2). Najlepszy wynik osiągnął model ARIMA(1,0,3)(0,1,1) z wartością AICc równą 65.92, podczas gdy modele manualne uzyskały wyniki powyżej 76.

Zbadam istotność parametrów najlepszego modelu:

Tabela 8: Istotność współczynników: Model Auto 1 - ARIMA(1,0,3)(0,1,1)

Parametr	Estymator	SE	p-value	Istotny
ar1	0.9843	0.0305	< 0.0001	TAK
ma1	0.2824	0.1552	0.06873	NIE
ma2	0.2488	0.1704	0.14438	NIE
ma3	0.3898	0.1790	0.02945	TAK
sma1	-0.8155	0.1688	< 0.0001	TAK

Mimo najlepszego wyniku AICc, model ten posiada nieistotne statystycznie parametry. Istotne są jedynie parametry ar1, ma3 oraz sezonowy sma1, co sugeruje nadmierne skomplikowanie modelu i możliwość jego redukcji. Wypróbuję, więc model ARIMA (1,0,0)x(0,1,1):

Tabela 9: Porównanie modeli ARIMA (Kryterium AICc)

Manualny.Auto	Model	AICc
Manual 4	ARIMA(1,0,0)(0,1,1)[4]	65.36
Auto 1	ARIMA(1,0,3)(0,1,1)[4]	65.92

Redukcja modelu do postaci ARIMA(1,0,0)(0,1,1) przyniosła poprawę jakości dopasowania – wartość AICc spadła do 65.36 (względem 65.92 dla modelu wyjściowego). Oznacza to, że usunięcie nieistotnych parametrów średniej ruchomej (MA) wpłynęło korzystnie na oszczędność modelu bez utraty informacji.

Sprawdzę teraz istotność współczynników dla pewności.

Tabela 10: Istotność współczynników: Model - ARIMA(1,0,0)(0,1,1)

Parametr	Estymator	SE	p-value	Istotny
ar1	0.9956	0.0100	< 0.0001	TAK
sma1	-0.8256	0.1528	< 0.0001	TAK

W zredukowanym modelu wszystkie parametry (ar1 oraz sezonowy sma1) są wysoce istotne statystycznie ($p<0.0001$). Potwierdza to słuszność uproszczenia struktury modelu.

Teraz poddam go testom:

Tabela 11: Pełna diagnostyka reszt

Test	Hipoteza_H0	Statystyka	p-value	Decyzja
Ljung-Box (lag=8)	Brak autokorelacji	8.1584	0.22673	BRAK PODSTAW do odrzucenia H0
Box-Pierce (lag=8)	Brak autokorelacji	7.4216	0.28361	BRAK PODSTAW do odrzucenia H0
Shapiro-Wilk	Rozkład normalny reszt	0.9436	0.01573	ODRZUCAMY H0 (Brak normalności)
Jarque-Bera	Rozkład normalny reszt	5.5684	0.06178	BRAK PODSTAW do odrzucenia H0

Model zredukowany pomyślnie eliminuje autokorelację reszt (testy Ljung-Boxa i Boxa-Pierce'a nie odrzucają H_0. Jednakże reszty nie mają rozkładu normalnego – test Shapiro-Wilka nakazuje odrzucenie hipotezy o normalności, co jest wadą tego modelu.

Sprawdzę też orginalny model ARIMA(1,0,3)(0,1,1), czy przechodzi te testy?

Tabela 12: Pełna diagnostyka reszt

Test	Hipoteza_H0	Statystyka	p-value	Decyzja
Ljung-Box (lag=8)	Brak autokorelacji	1.2804	0.7338	BRAK PODSTAW do odrzucenia H0
Box-Pierce (lag=8)	Brak autokorelacji	1.0780	0.7824	BRAK PODSTAW do odrzucenia H0
Shapiro-Wilk	Rozkład normalny reszt	0.9695	0.2013	BRAK PODSTAW do odrzucenia H0
Jarque-Bera	Rozkład normalny reszt	1.5393	0.4632	BRAK PODSTAW do odrzucenia H0

Pierwotny model ARIMA(1,0,3)(0,1,1) (z nieistotnymi parametrami) przechodzi pomyślnie wszystkie testy diagnostyczne. W przeciwieństwie do modelu zredukowanego, tutaj reszty zachowują normalność rozkładu, co czyni ten model statystycznie bezpieczniejszym wyborem mimo nieco gorszego AICc.

Teraz zbadam modele, które ja zaproponowałem, najpierw wezmę na tapet Model ARIMA(0,2,5)(0,1,0).

Tabela 13: Istotność współczynników: Model - ARIMA(0,2,5)(0,1,0)

Parametr	Estymator	SE	p-value	Istotny
ma1	-0.6580	0.1911	0.0005733	TAK
ma2	0.0697	0.2236	0.7552233	NIE
ma3	0.1169	0.1961	0.5512196	NIE
ma4	-1.0325	0.2192	< 0.0001	TAK
ma5	0.5556	0.1938	0.0041523	TAK

W modelu manualnym istotne są tylko wybrane opóźnienia średniej ruchomej: pierwsze (ma1) oraz odległe (ma4, ma5), podczas gdy pośrednie (ma2, ma3) są nieistotne. Wskazuje to na specyficzną strukturę zależności w danych po dwukrotnym różnicowaniu.

Teraz poddam model testom:

Tabela 14: Pełna diagnostyka reszt

Test	Hipoteza_H0	Statystyka	p-value	Decyzja
Ljung-Box (lag=8)	Brak autokorelacji	4.2219	0.2385	BRAK PODSTAW do odrzucenia H0
Box-Pierce (lag=8)	Brak autokorelacji	3.6500	0.3018	BRAK PODSTAW do odrzucenia H0
Shapiro-Wilk	Rozkład normalny reszt	0.9784	0.4600	BRAK PODSTAW do odrzucenia H0
Jarque-Bera	Rozkład normalny reszt	1.8463	0.3973	BRAK PODSTAW do odrzucenia H0

Zaskakująco, model ten przechodzi wzorowo kompletną diagnostykę reszt. Brak autokorelacji oraz brak podstaw do odrzucenia normalności rozkładu ($p>0.05$ dla wszystkich testów) sugeruje, że mimo wysokiego AICc, model ten poprawnie opisuje strukturę szumu białego.

Teraz zbadam drugi model zaproponowany przezemnie jakim jest Model ARIMA(4,2,0)(0,1,0).

Tabela 15: Istotność współczynników: Model - ARIMA(4,2,0)(0,1,0)

Parametr	Estymator	SE	p-value	Istotny
ar1	-0.4428	0.1271	0.0004922	TAK
ar2	-0.1557	0.1467	0.2887728	NIE
ar3	-0.0121	0.1453	0.9335645	NIE
ar4	-0.4707	0.1268	0.0002067	TAK

Podobnie jak w modelu MA, tutaj również istotne są tylko skrajne parametry autoregresji (ar1 i ar4), a pośrednie (ar2, ar3) nie wykazują istotności statystycznej.

Tabela 16: Pełna diagnostyka reszt

Test	Hipoteza_H0	Statystyka	p-value	Decyzja
Ljung-Box (lag=8)	Brak autokorelacji	12.6794	0.01295	ODRZUCAMY H0 (Źle)
Box-Pierce (lag=8)	Brak autokorelacji	10.9028	0.02768	ODRZUCAMY H0 (Źle)
Shapiro-Wilk	Rozkład normalny reszt	0.9763	0.38390	BRAK PODSTAW do odrzucenia H0
Jarque-Bera	Rozkład normalny reszt	0.8694	0.64745	BRAK PODSTAW do odrzucenia H0

Model ten należy odrzucić, ponieważ nie eliminuje autokorelacji reszt – testy Ljung-Boxa i Boxa-Pierce'a wskazują na istotne zależności ($p<0.05$). Oznacza to, że model jest źle wyspecyfikowany i pozostawia w resztach informacje, których nie udało mu się wyjaśnić.

Z tej części, więc do prognozowania przejdą modele:

- **ARIMA(1,0,3)(0,1,1)**
- **ARIMA(0,2,5)(0,1,0)**

2.2.2 Modele dekompozycji

Zacznę od narysowania trzech podstawowych modeli na wykresie razem z danymi zbioru uczącego:

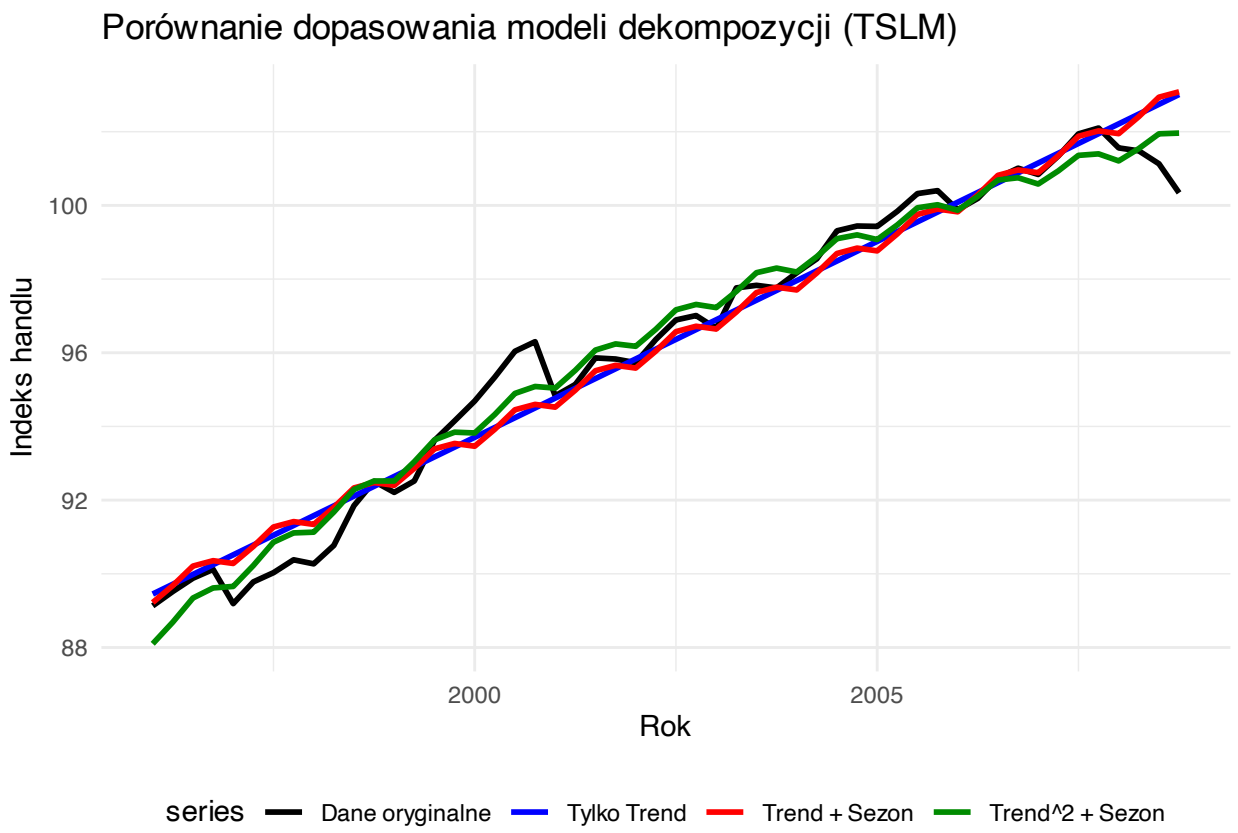

Z wykresu trend kwardratowy plus sezonowość wydaje się być najlepszy jednak lepiej sprawdzić dopsowanie, kryterium AIC:

Tabela 17: Porównanie dopasowania modeli dekompozycji

Model	AIC
Tylko Trend	-16.460
Trend + Sezon	-12.850
Trend^2 + Sezon	-42.566

Model uwzględniający trend kwadratowy i sezonowość jest zdecydowanie najlepszy, osiągając najniższą wartość AIC (-42.57). Znaczna przewaga modelu kwadratowego nad liniowymi (różnica w AIC rzędu 30 punktów) potwierdza, że dynamika indeksu nie jest liniowa, lecz wyhamowuje w czasie. Dodanie samej sezonowości do trendu liniowego pogorszyło wynik (wzrost AIC z -16.46 do -12.85), co sugeruje, że przy błędnie określonym trendzie (liniowym), parametry sezonowe są nieistotne i tylko obciążają model.

Przyjrzę teraz się resztom najlepszego modelu.

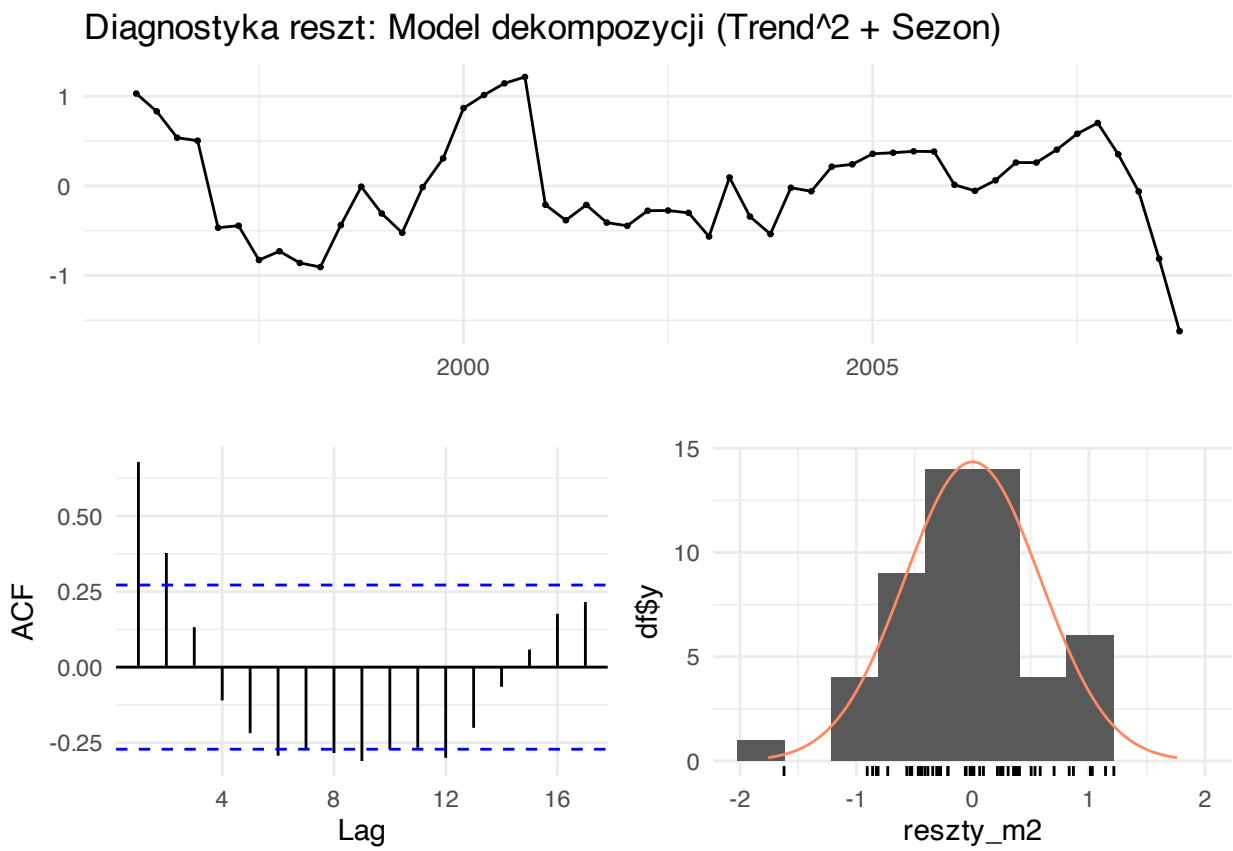

Reszty nie wygladają już tak obiecująco, jednak przeprowadzę jeszcze testy staytsyczne na tym modelu.

Tabela 18: Pełna diagnostyka reszt modelu TSLM (Trend^2 + Sezon)

Test	Hipoteza_H0	Statystyka	p-value	Decyzja
Ljung-Box (lag=8)	Brak autokorelacji	53.1127	<0.0001	ODRZUCAMY H0 (Źle)
Box-Pierce (lag=8)	Brak autokorelacji	48.0494	<0.0001	ODRZUCAMY H0 (Źle)
Shapiro-Wilk	Rozkład normalny reszt	0.9844	0.7243	BRAK PODSTAW do odrzucenia H0
Jarque-Bera	Rozkład normalny reszt	0.0123	0.9939	BRAK PODSTAW do odrzucenia H0

Testy Ljung-Boxa i Boxa-Pierce'a wskazują na silną autokorelację reszt (p<0.0001). Oznacza to, że model dekompozycji (mimo dobrego dopasowania trendu) nie wyłapuje wszystkich zależności czasowych. Reszty nie są białym szumem, co jest typową wadą prostych modeli regresji (TSLM) w porównaniu do modeli ARIMA.

Testy Shapiro-Wilka i Jarque-Bera nie dają podstaw do odrzucenia hipotezy o normalności. Oznacza to, że reszty mają rozkład normalny, co jest bardzo pożądaną cechą – model nie generuje systematycznych, skrajnych błędów.

Do prognozowania wezmę modele **tslm2** i **tslm0**.

2.2.3 Modele ETS

Pierwszy model wykładniczy jaki wezmę pod uwagę to *model.ses <-ses(train, h=h, initial="optimal")* i zbagadm jego reszty:

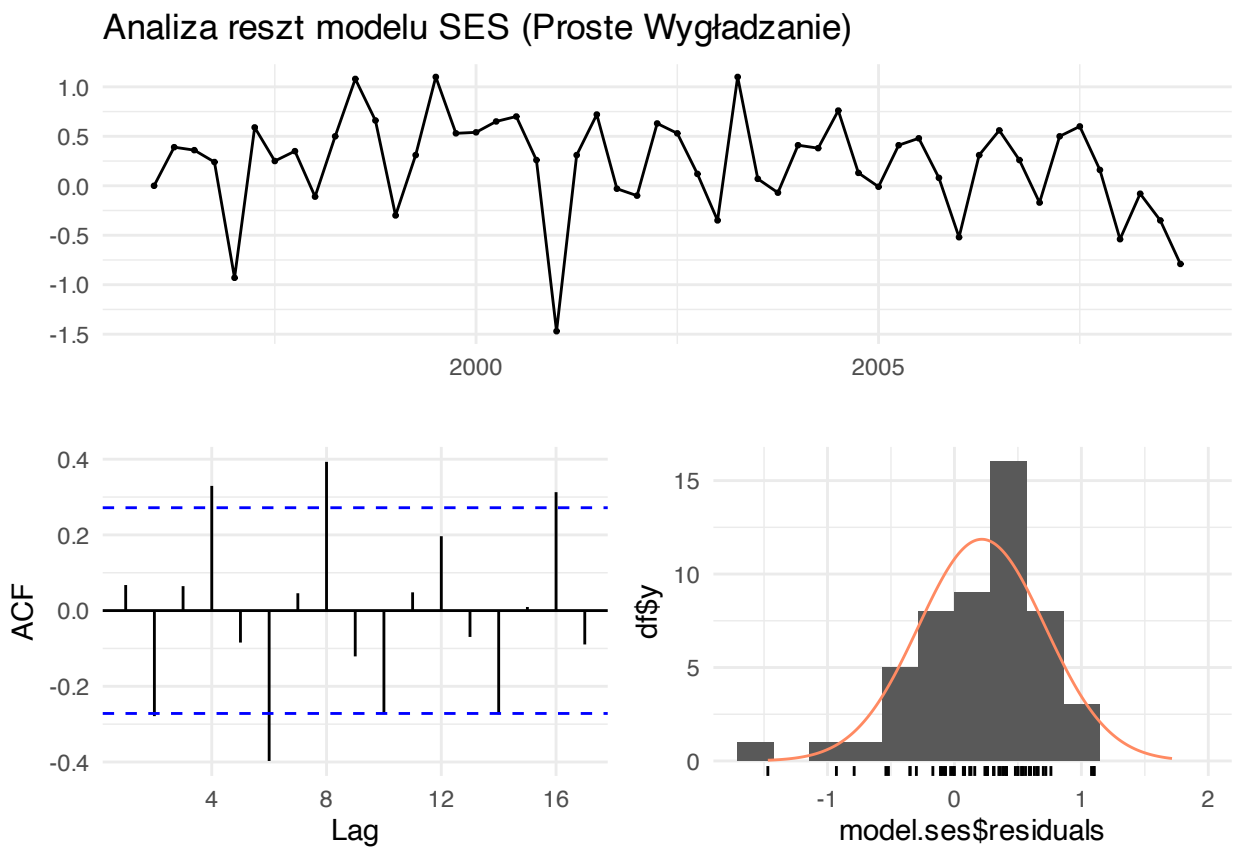

Liczne lagi wystające poza przedział ufności oraz histogram nie prezentujący się najlepiej zapowiadają, że ten model pozostawia wiele do życzenia, ale przyjrzę się jeszcze poniższym testom:

Tabela 19: Testy diagnostyczne reszt dla modelu SES

Test	Hipoteza_H0	Statystyka	p-value	Decyzja
Ljung-Box (df=2, lag=8)	Brak autokorelacji	31.2493	< 0.0001	ODRZUCAMY H0 (Źle)
Box-Pierce (df=2, lag=8)	Brak autokorelacji	26.8555	0.0001541	ODRZUCAMY H0 (Źle)
Shapiro-Wilk	Rozkład normalny reszt	0.9446	0.0172766	ODRZUCAMY H0 (Brak normalności)
Jarque-Bera	Rozkład normalny reszt	12.2701	0.0021656	ODRZUCAMY H0 (Brak normalności)

Model SES okazał się całkowicie nieadekwatny dla danych euretail. Wyniki te są zgodne z oczekiwaniami, ponieważ Proste Wygładzanie Wykładnicze zakłada stały poziom szeregu (brak trendu i sezonowości), podczas gdy analizowane dane wykazują silną dynamikę wzrostową i cykliczność.

Teraz przyjrzę się wykresowi reszt standardowego modelu Holta

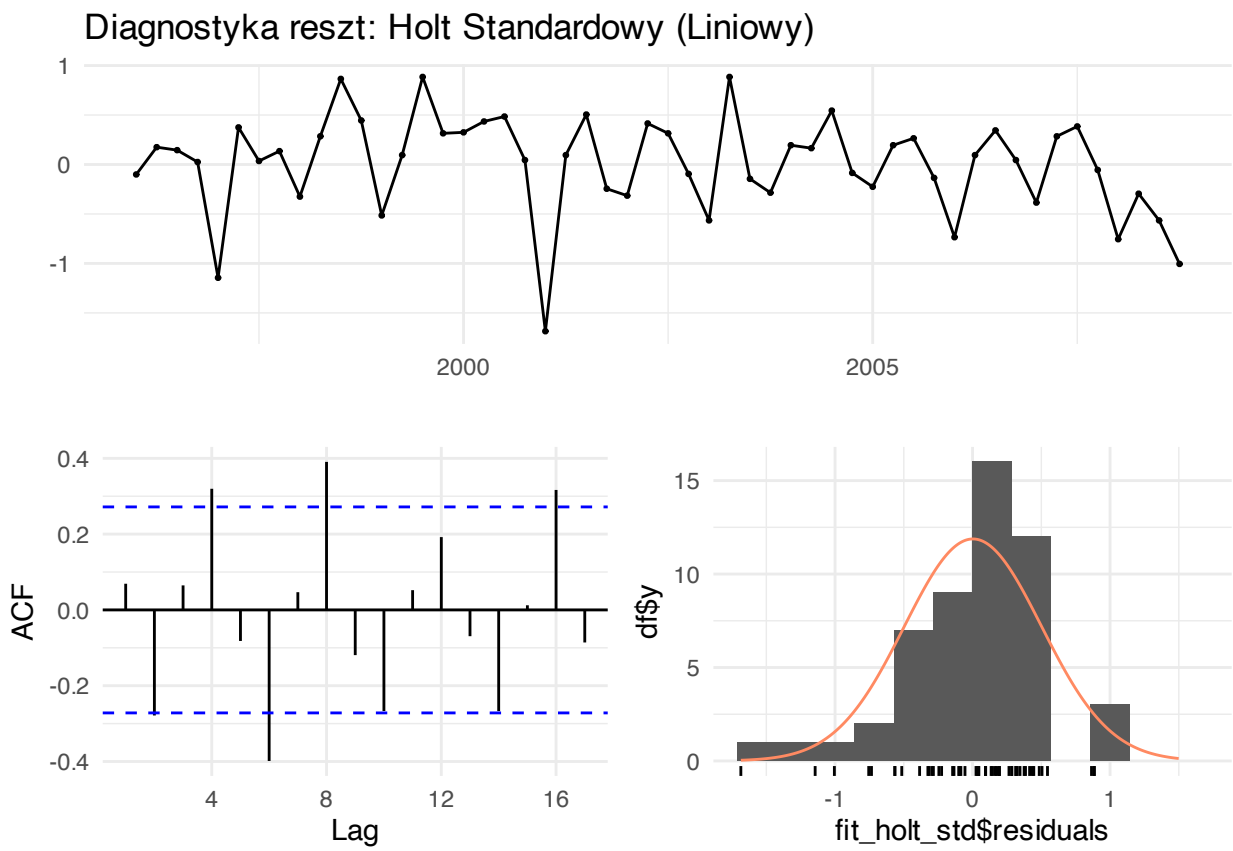

Wyniki są praktycznie analogiczne jak dla poprzedniego modelu, ale trzeba dla pewności przyjrzeć się testom:

Tabela 20: Testy diagnostyczne reszt: Holt Standardowy

Test	Hipoteza_H0	Statystyka	p-value	Decyzja
Ljung-Box (df=4, lag=8)	Brak autokorelacji	30.8134	< 0.0001	ODRZUCAMY H0 (Źle)
Box-Pierce (df=4, lag=8)	Brak autokorelacji	26.4746	< 0.0001	ODRZUCAMY H0 (Źle)
Shapiro-Wilk	Rozkład normalny reszt	0.9430	0.01491	ODRZUCAMY H0 (Brak normalności)
Jarque-Bera	Rozkład normalny reszt	12.8019	0.00166	ODRZUCAMY H0 (Brak normalności)

Mimo że model Holta teoretycznie lepiej pasuje do danych posiadających trend (w porównaniu do płaskiego SES), diagnostyka wykazuje, że jest on nadal niepoprawny statystycznie dla zbioru euretail. Kluczową przyczyną porażki jest brak uwzględnienia cyklicznych wahań kwartalnych.

Sprawdzę jeszcze wygasający model holta, chociaż co do reszt znowu spodziewam się raczej podobnych wyników.

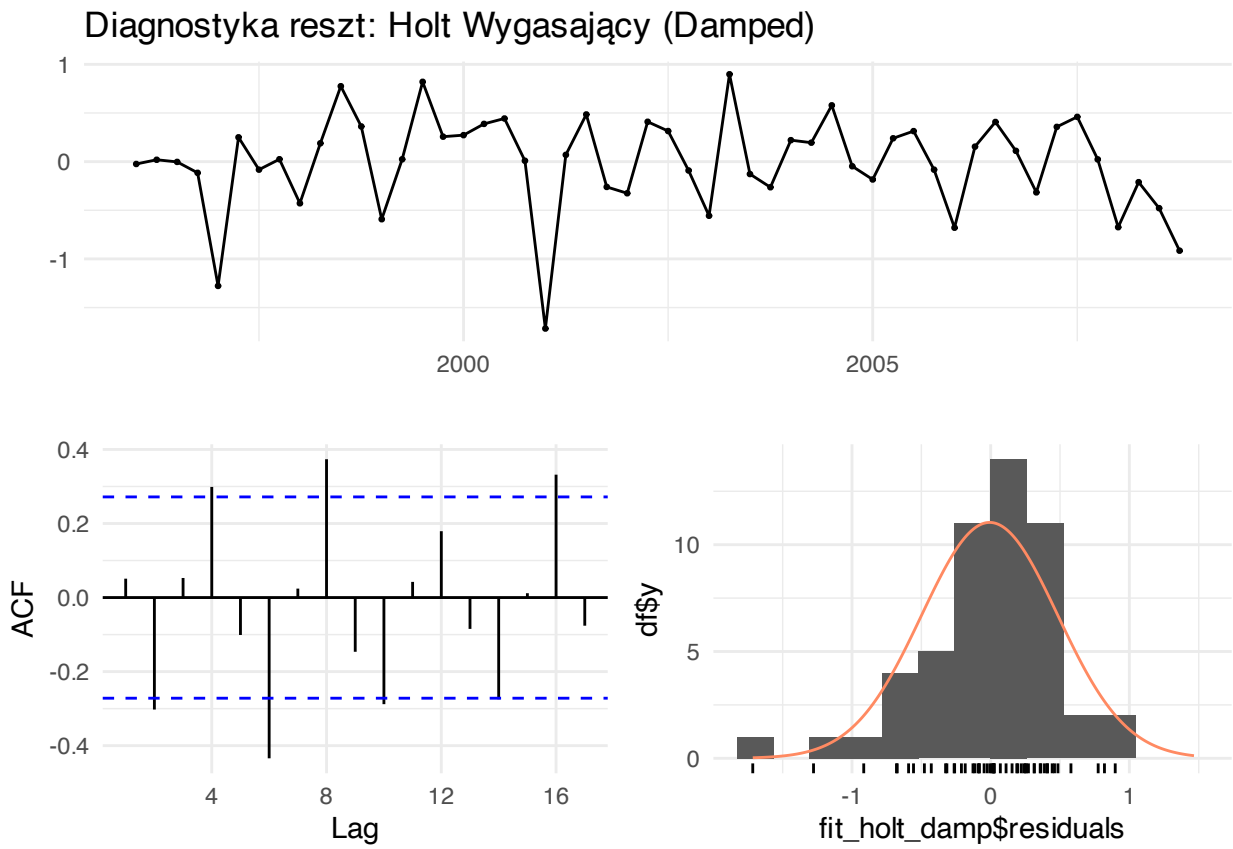

Wykresy potwierdzają moje założenia, ale czy testy też to zrobią?

Tabela 21: Testy diagnostyczne reszt: Holt Wygasający

Test	Hipoteza_H0	Statystyka	p-value	Decyzja
Ljung-Box (df=5, lag=8)	Brak autokorelacji	31.7218	< 0.0001	ODRZUCAMY H0 (Źle)
Box-Pierce (df=5, lag=8)	Brak autokorelacji	27.2992	< 0.0001	ODRZUCAMY H0 (Źle)
Shapiro-Wilk	Rozkład normalny reszt	0.9383	0.0095586	ODRZUCAMY H0 (Brak normalności)
Jarque-Bera	Rozkład normalny reszt	17.9576	0.0001261	ODRZUCAMY H0 (Brak normalności)

Model Holta w wersji wygasającej, podobnie jak jego standardowy odpowiednik i model SES, nie nadaje się do opisu danych euretail. Diagnostyka jednoznacznie wskazuje, że bez uwzględnienia sezonowości żaden wariant wygładzania wykładniczego opartego tylko na poziomie i trendzie nie będzie poprawny statystycznie.

Przejdę teraz do metody HW.

Najpierw przyjrzę się wykresom reszt modelu addytywnego HW:

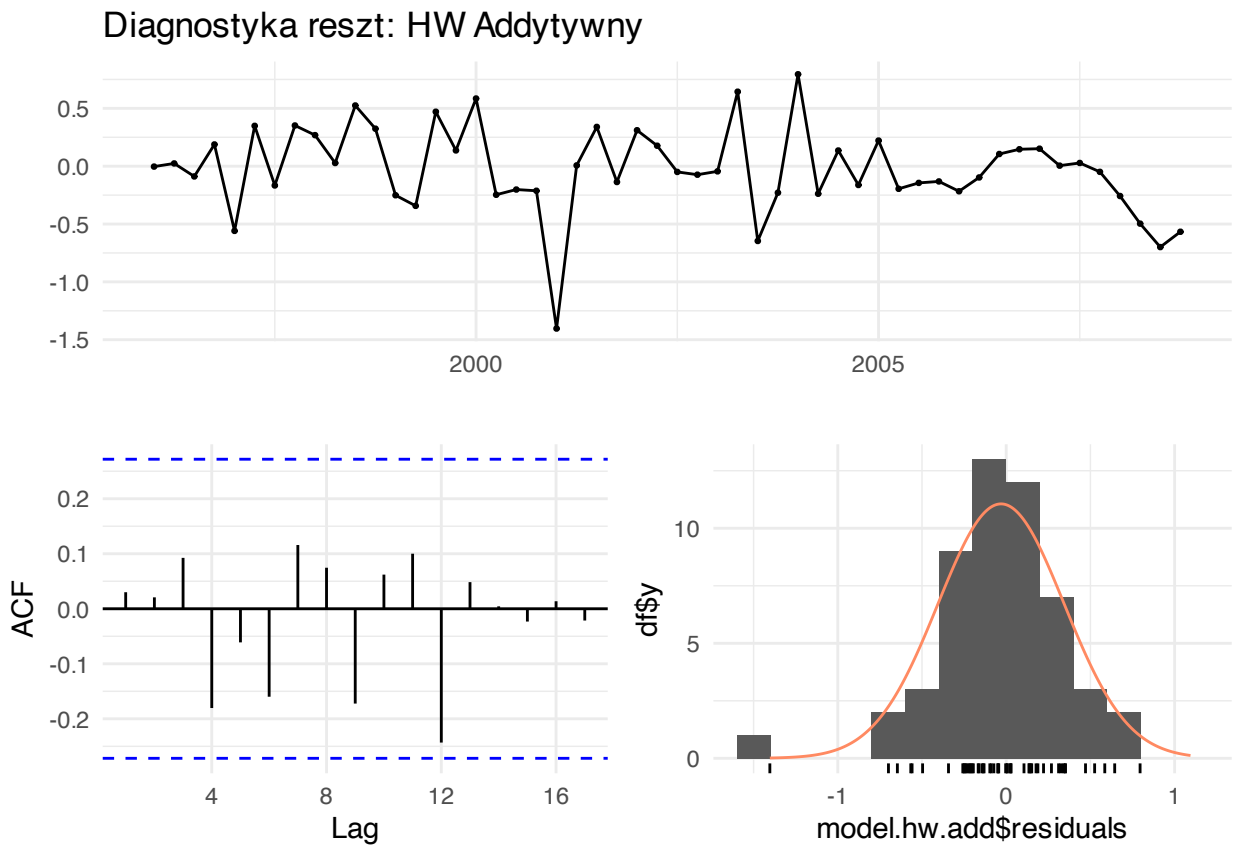

Na pierwszy rzut oka wygląda to zdecydowanie lepiej. Bardzo dobrym sygnałem jest to, że wszystkie lagi mieszczą się w przedziale ufności i histogram prawie przypopina rozkład normalny. Teraz czas na testy:

Tabela 22: Testy diagnostyczne reszt: HW Addytywny

Test	Hipoteza_H0	Statystyka	p-value	Decyzja
Ljung-Box (df=8, lag=8)	Brak autokorelacji	5.4445	< 0.0001	ODRZUCAMY H0 (Źle)
Box-Pierce (df=8, lag=8)	Brak autokorelacji	4.7175	< 0.0001	ODRZUCAMY H0 (Źle)
Shapiro-Wilk	Rozkład normalny reszt	0.9526	0.0375097	ODRZUCAMY H0 (Brak normalności)
Jarque-Bera	Rozkład normalny reszt	15.6415	0.0004013	ODRZUCAMY H0 (Brak normalności)

Model HW Addytywny nie poprawił jednak się w testach, co jest nieco zaskakujące, teraz obejrzę model multiplikatywny HW.

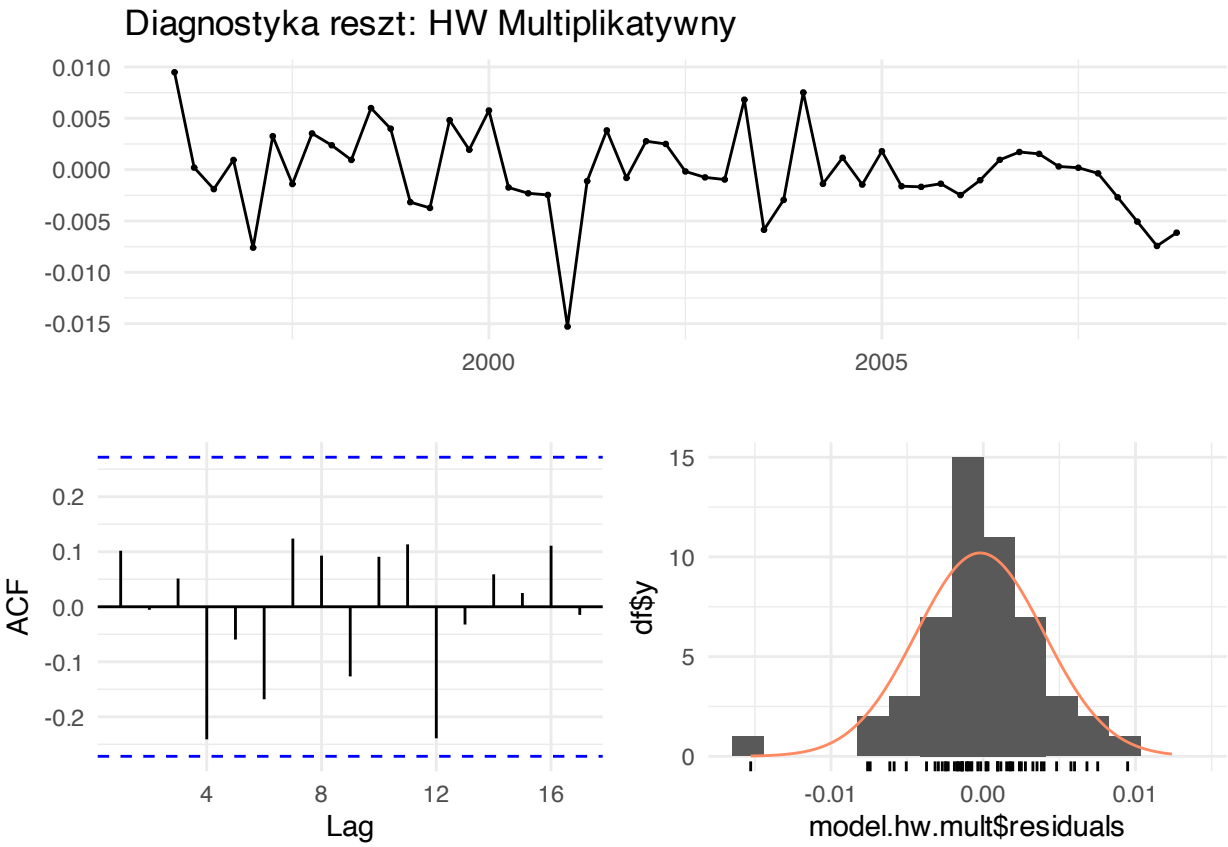

Różnice w porówanianu z poprzednim modelem są znikome, aczkolwiek mam wrażenie, że histogram wygląda odrobinę lepiej. Warto więc przyjrzeć się testom:

Tabela 23: Testy diagnostyczne reszt: HW Multiplikatywny

Test	Hipoteza_H0	Statystyka	p-value	Decyzja
Ljung-Box (df=8, lag=8)	Brak autokorelacji	7.5672	< 0.0001	ODRZUCAMY H0 (Źle)
Box-Pierce (df=8, lag=8)	Brak autokorelacji	6.5991	< 0.0001	ODRZUCAMY H0 (Źle)
Shapiro-Wilk	Rozkład normalny reszt	0.9567	0.056286	BRAK PODSTAW do odrzucenia H0
Jarque-Bera	Rozkład normalny reszt	13.1462	0.001397	ODRZUCAMY H0 (Brak normalności)

Model HW Multiplikatywny jest równie słaby co poprzednie, ostatnią nadzieją wśród modeli wygładzających jest model wybierany automatycznie.

Teraz przejdę do modelu wybranego automatycznie poprzez funkcję *ets()*.

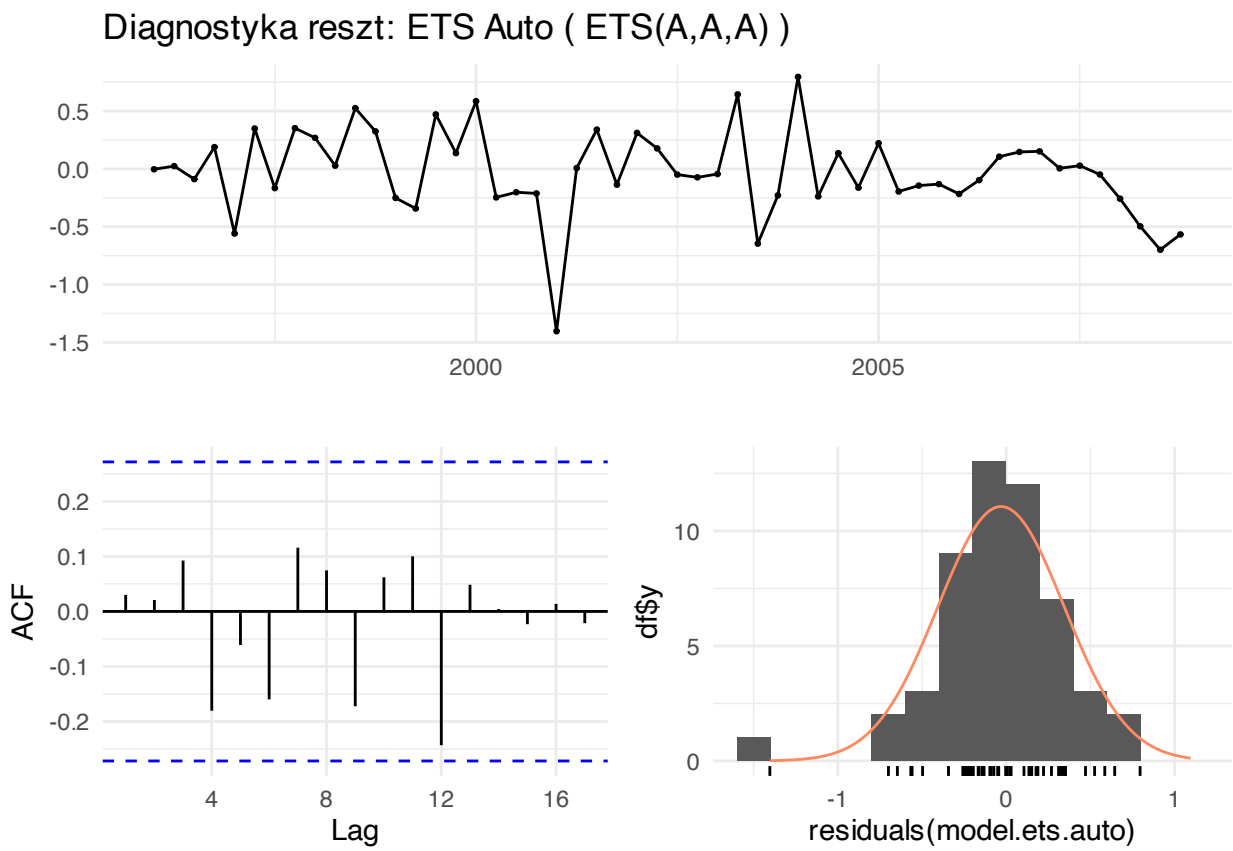

Odnoszę wrażenie, że wykresy nie różnią się od modeli HW.

Tabela 24: Testy diagnostyczne reszt: ETS Auto ETS(A,A,A)

Test	Hipoteza_H0	Statystyka	p-value	Decyzja
Ljung-Box (df=0, lag=8)	Brak autokorelacji	5.4443	0.7092047	BRAK PODSTAW do odrzucenia H0
Box-Pierce (df=0, lag=8)	Brak autokorelacji	4.7174	0.7873135	BRAK PODSTAW do odrzucenia H0
Shapiro-Wilk	Rozkład normalny reszt	0.9526	0.0375357	ODRZUCAMY H0 (Brak normalności)
Jarque-Bera	Rozkład normalny reszt	15.6373	0.0004022	ODRZUCAMY H0 (Brak normalności)

Model skutecznie wyeliminował zależności czasowe z danych. Wysokie wartości p-value w testach Ljung--Boxa (0.71) i Boxa-Pierce'a (0.79) potwierdzają, że reszty są losowe (szum biały). Testy Shapiro-Wilka oraz Jarque-Bera wskazują na brak normalnego rozkładu reszt, co jest jedyną wadą statystyczną tego modelu. Model ETS(A,A,A) jest poprawnie dopasowany do struktury danych (trendu i sezonowości), mimo że rozkład błędów odbiega od idealnej krzywej Gaussa.

Na końcu warto się przyjrzeć wszytskim modelom i ich wartościom kryterium AIC.

Tabela 25: Ranking modeli wygładzania wykładniczego wg kryterium AIC

Model	AIC
ETS Auto (ETS(A,A,A))	120.78
Holt-Winters (Addytywny)	120.78
Holt-Winters (Multiplikatywny)	128.22
Holt (Standardowy Trend)	142.12
Holt (Wygasający Trend)	142.50
SES (Proste Wygładzanie)	147.30

Zwycięzcami rankingu są ex aequo ETS Auto (ETS(A,A,A)) oraz Holt-Winters (Addytywny), osiągając najniższą (najlepszą) wartość AIC równą 120.78. Wynik ten nie jest przypadkowy – model ETS(A,A,A) to w rzeczywistości inna nazwa dla addytywnej metody Holta-Wintersa (Addytywny błąd, Addytywny trend, Addytywna sezonowość).

Kluczową rolę miała sezonowość. Modele uwzględniające sezonowość osiągnęły drastycznie niższe wartości AIC (ok. 120-128) niż modele oparte wyłącznie na trendzie (Holt: ok. 142) czy samym poziomie (SES: 147). Różnica ponad 20 punktów w skali AIC dowodzi, że sezonowość jest najważniejszym składnikiem wyjaśniającym zmienność indeksu euretail.

2.3 Prognozy na zbiorze testowym wybranych modeli

Najpierw przyjrzyjmy się modelom ARIMA i ich prognozie:

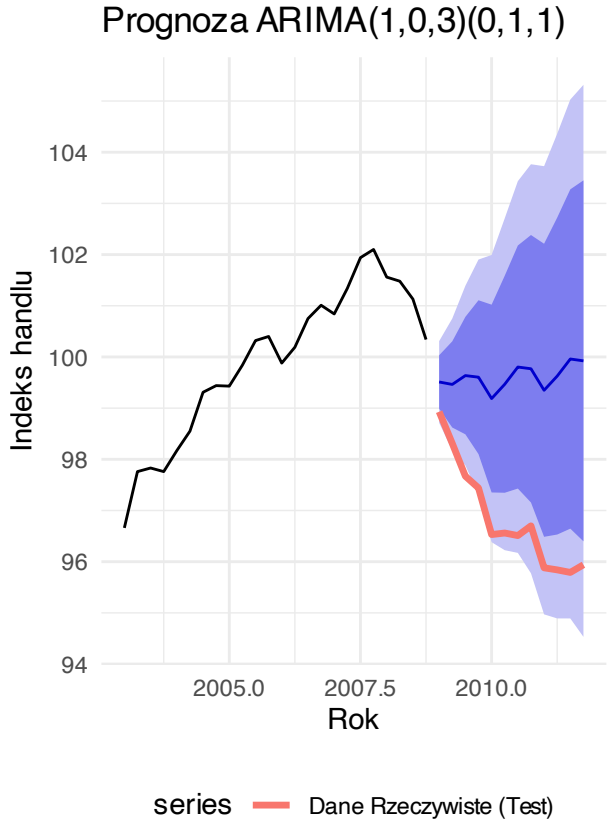

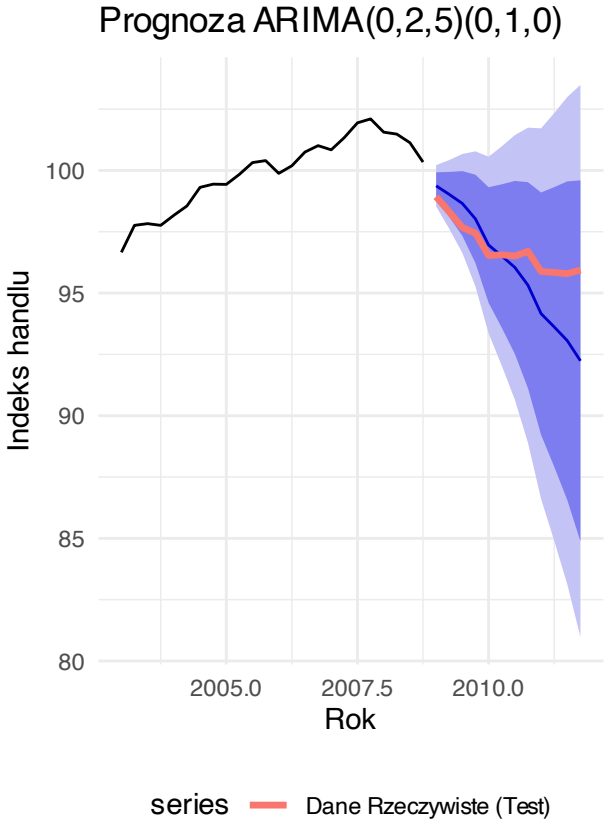

Model ARIMA(0,2,5)(0,1,0) dobrany samodzielnie, jeśli chodzi o preadykcje spisuje się znacznie lepeij niż ten wybrany automatycznie, co jest dla mnie dużym zaskoczeniem.

Teraz przyjrzę się wykresom prognoz modeli dekompozycji:

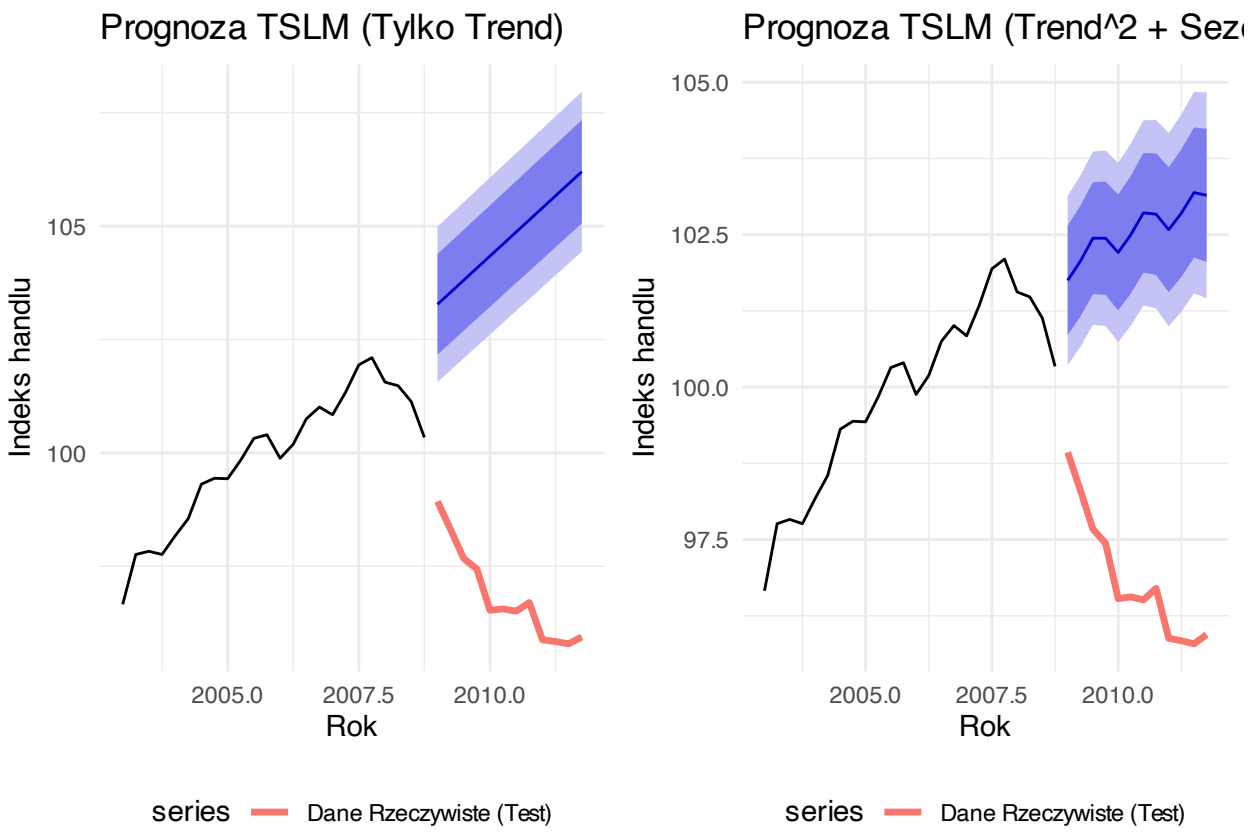

Obydwa modele absolutnie tragicznie poradziły sobie z prognozą, co było dosyć oczekiwane.

Następnymi modelami są modele wykładnicze:

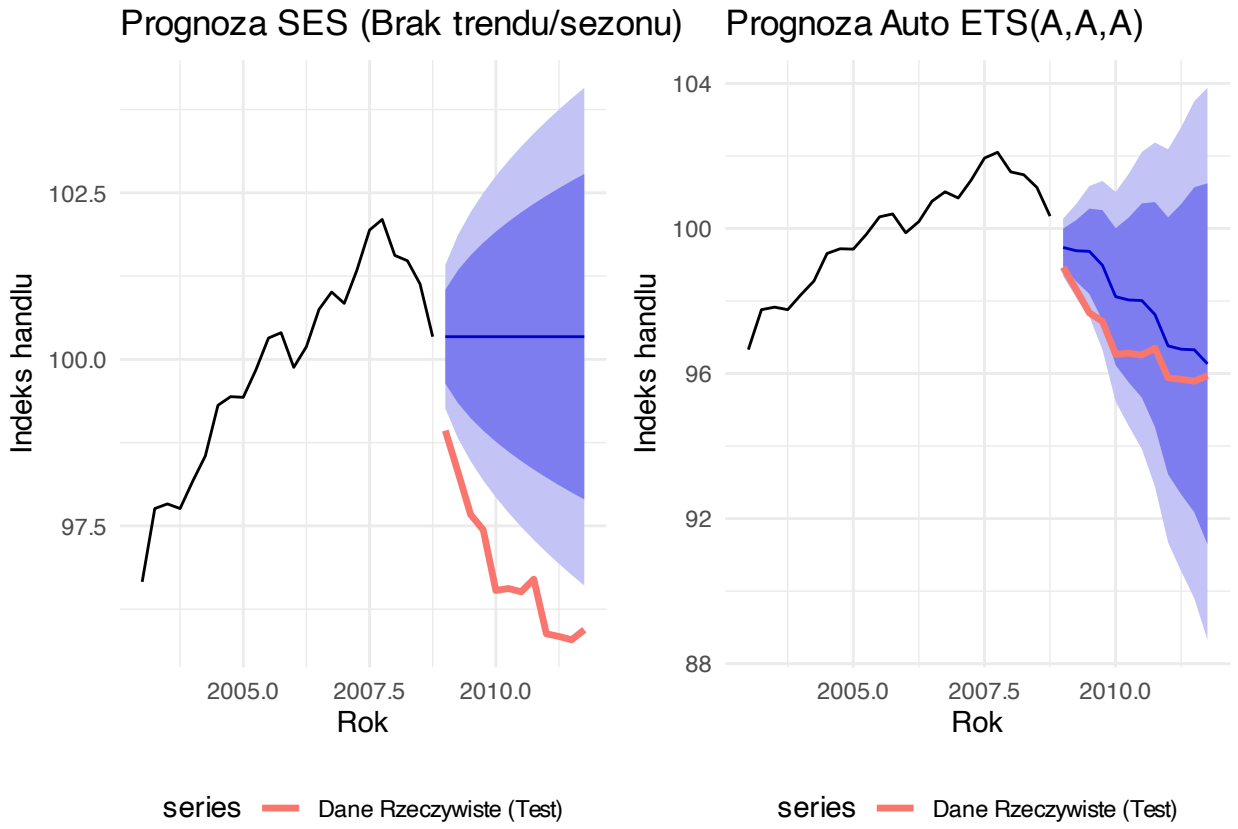

Prosty model ses nie radzi sobie z prognozą, dane testowe nawet nie łapią się do przedziałów ufności, podczas gdy model automatycznie wygenerowany na wykrasie wydaje się mieć naprawdę dobrą prognozę.

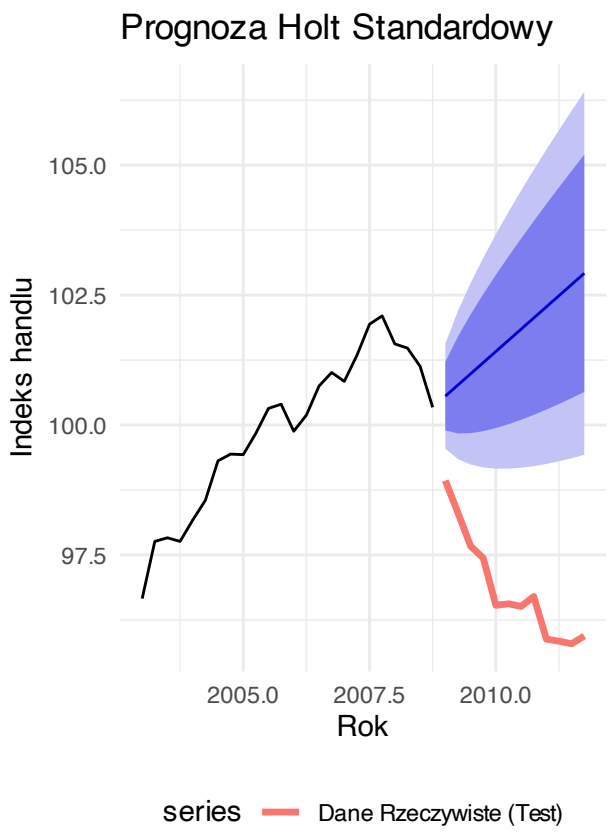

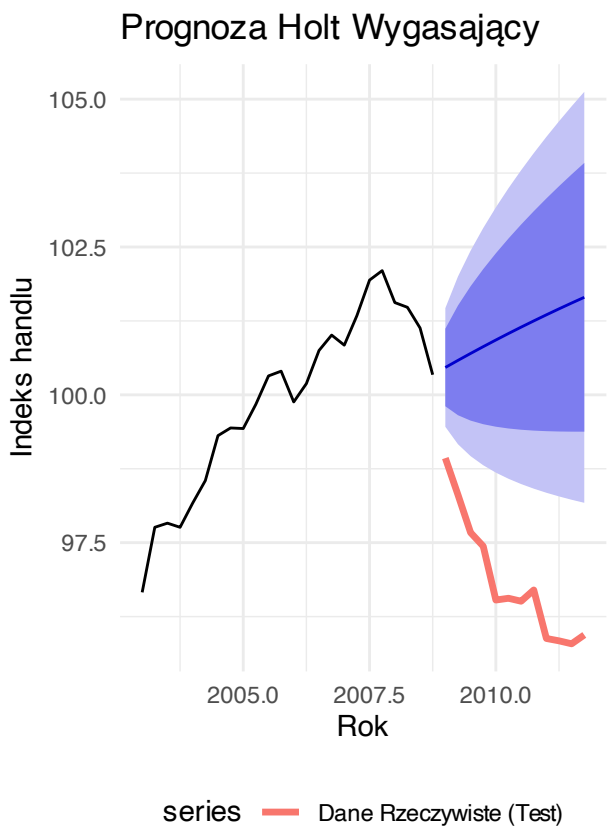

Obydwa powyższe modele są fatalne i nie są nawet blisko poprawnej prognozy.

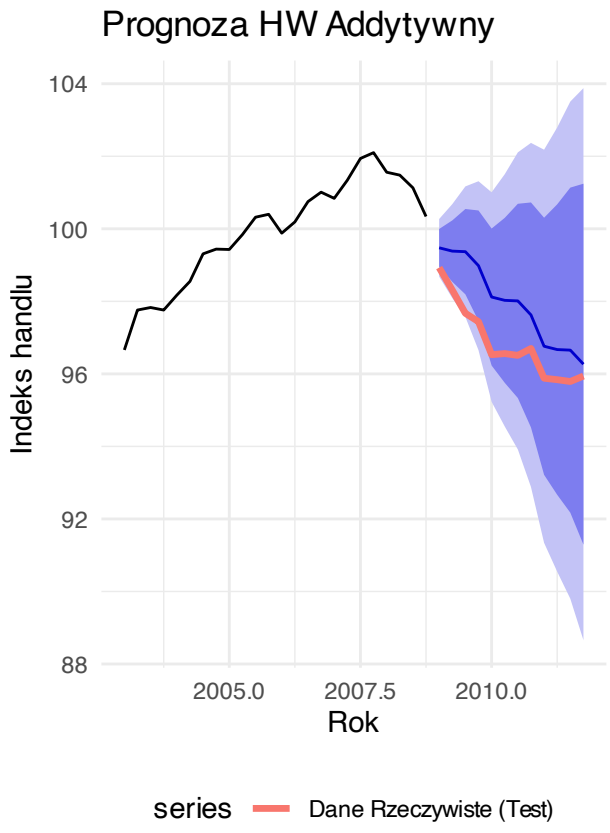

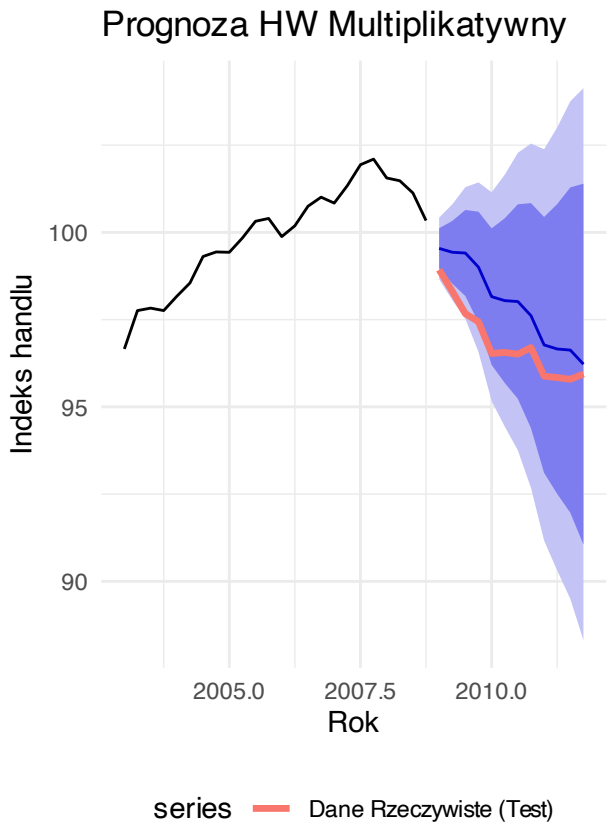

Modele HW prognozują dane z zadawalającą skutecznością.

Jeszcze obejrzyjmy wykresy benchmarków:

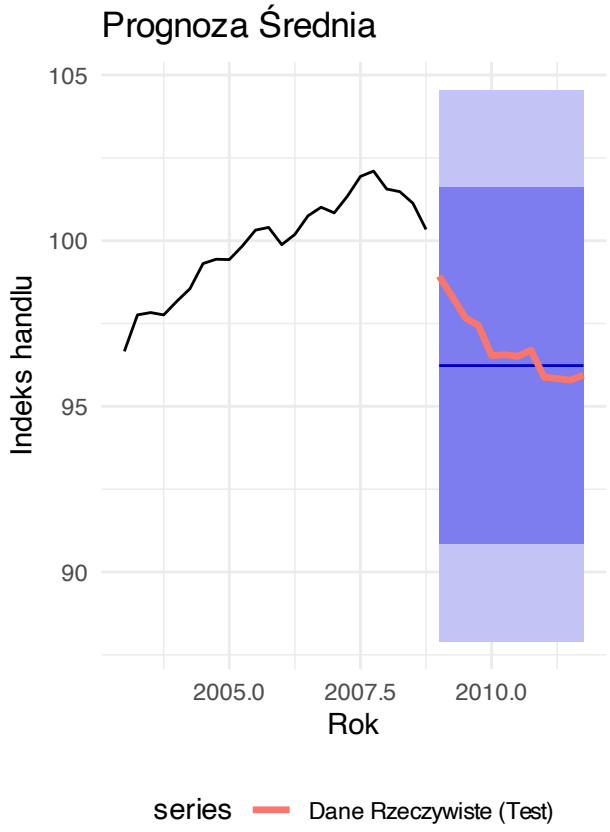

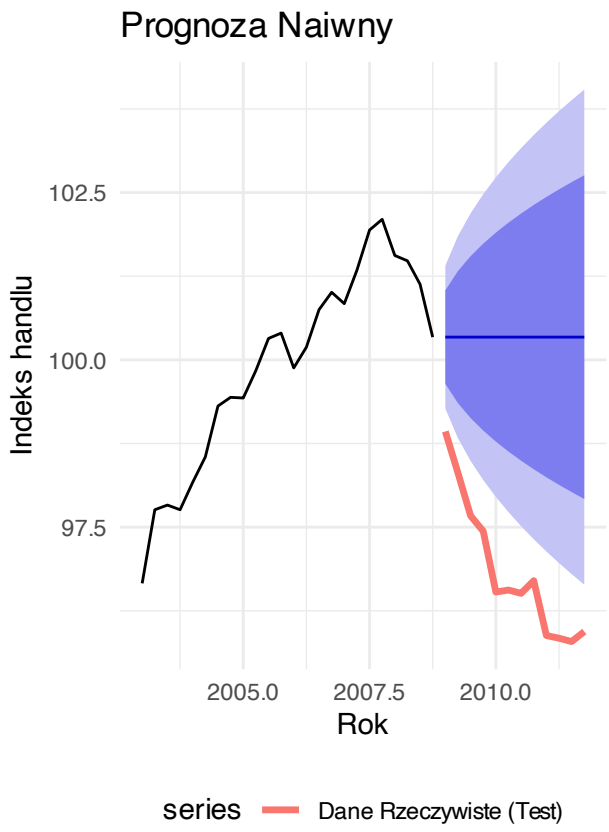

Benchmark Naiwny daje niskojakościowe prognozy, podczas, gdy średnia zdumiewająco dobrze przewiduje.

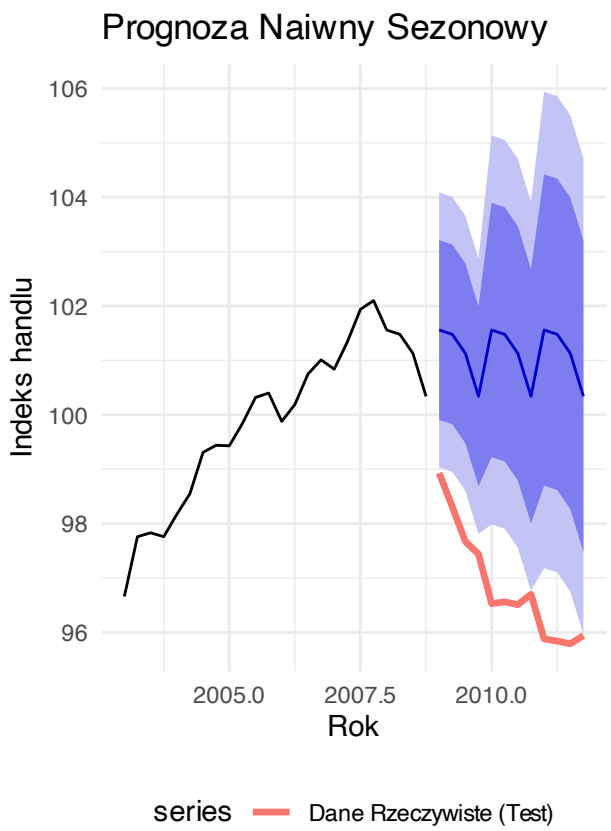

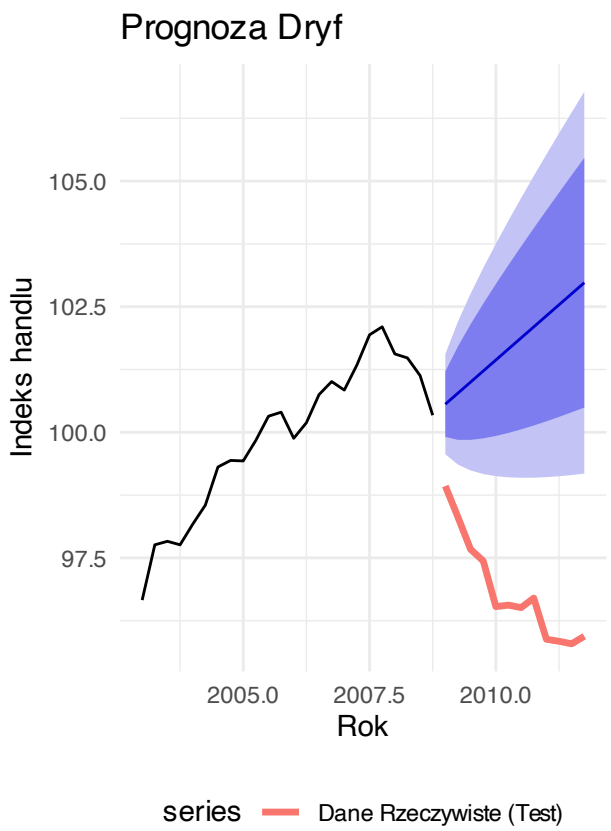

Nieco bardziej wyszukane benchmarki nie dają prognoz nawet zbliżonych do danych testowych.

Ciężko wysnuć konkretne wnioski, co do tego który model jest najlepszy, mimo że jest kilku kandydatów, w kolejnej części analizy poddam prognozy testom oceny dokładności.

2.4 Porównaie dokładności prognoz

W celu porównania dokładności użyję różnych miar dokładności RMSE, MAE, MAPE, MASE.

Tabela 26: Ranking modeli wg miary RMSE (Błąd średniokwadratowy)

Model	Train	Test
Mean (Średnia)	4.071	1.162
ETS Auto	0.373	1.184
HW Addytywny	0.373	1.184
HW Multiplikatywny	0.397	1.202
ARIMA Manual	0.372	1.668
ARIMA Auto	0.370	2.967
Naive (Naiwny)	0.545	3.635
SES	0.540	3.635
SNaive (Naiwny Sezon)	1.290	4.410
Holt Damped	0.486	4.443
Holt Standardowy	0.494	5.181
RWF (Dryf)	0.499	5.217
TSLM (Trend^2 + Sezon)	0.580	5.889
TSLM (Trend Liniowy)	0.806	8.114

Model oparty na prostej średniej osiągnął najniższy błąd RMSE na zbiorze testowym. Jest to sytuacja nietypowa dla danych handlowych i sugeruje, że wartości w okresie testowym uległy spłaszczeniu lub oscylowały wokół historycznej średniej, co "nagrodziło" ten najprostszy model, a "ukarało" modele silnie trendowe, jednak na zbiorze uczącym średnia poradziła sobie najgorzej.

Spośród modeli zaawansowanych, bezkonkurencyjne okazały się ETS Auto oraz HW Addytywny. Różnica między nimi a liderem jest minimalna, co czyni je faktycznymi zwycięzcami, ponieważ w przeciwieństwie do średniej, potrafią one reagować na przyszłe zmiany sezonowości i trendu.

Tabela 27: Ranking modeli wg miary MAE (Średni błąd bezwzględny)

Model	Train	Test
Mean (Średnia)	3.467	0.857
ETS Auto	0.274	1.104
HW Addytywny	0.274	1.104
HW Multiplikatywny	0.293	1.117
ARIMA Manual	0.285	1.284
ARIMA Auto	0.273	2.767
Naive (Naiwny)	0.448	3.498
SES	0.439	3.498
Holt Damped	0.356	4.236
SNaive (Naiwny Sezon)	1.098	4.286
Holt Standardowy	0.374	4.895
RWF (Dryf)	0.379	4.927
TSLM (Trend^2 + Sezon)	0.466	5.731
TSLM (Trend Liniowy)	0.596	7.896

Średnia znowu ma niby najelpszy wynik na zbiorze uczącym, zarazem mając najgorszy na testowym.

Rzeczywistymi liderami są ETS Auto i HW Addytywny (MAE ~1.10). Łączą one bardzo niskie błędy na zbiorze uczącym z wysoką dokładnością prognoz, co czyni je najbardziej wiarygodnymi modelami.

Tabela 28: Ranking modeli wg miary MAPE (Średni błąd procentowy)

Model	Train	Test
Mean (Średnia)	3.635	0.877
ETS Auto	0.285	1.140
HW Addytywny	0.285	1.140
HW Multiplikatywny	0.306	1.153
ARIMA Manual	0.295	1.333
ARIMA Auto	0.283	2.868
Naive (Naiwny)	0.468	3.623
SES	0.459	3.623
Holt Damped	0.370	4.388
SNaive (Naiwny Sezon)	1.137	4.436
Holt Standardowy	0.390	5.073
RWF (Dryf)	0.394	5.106
TSLM (Trend^2 + Sezon)	0.490	5.933
TSLM (Trend Liniowy)	0.622	8.174

Wysoka precyzja liderów: Modele ETS Auto i HW Addytywny mylą się średnio zaledwie o 1.14% względem rzeczywistych wartości sprzedaży. Jest to wynik bardzo dobry i stabilny zarówno na zbiorze uczącym, jak i testowym.

Błędy procentowe dla modelu ARIMA Auto (2.87%) oraz modeli regresji TSLM (nawet do 8.17%) są nieakceptowalnie wysokie w porównaniu do rodziny modeli wykładniczych.

Tabela 29: Ranking modeli wg miary MASE (Skalowany błąd średni)

Model	Train	Test
Mean (Średnia)	3.158	0.780
ETS Auto	0.249	1.006
HW Addytywny	0.249	1.006
HW Multiplikatywny	0.267	1.018
ARIMA Manual	0.259	1.170
ARIMA Auto	0.248	2.520
Naive (Naiwny)	0.408	3.186
SES	0.400	3.186
Holt Damped	0.324	3.858
SNaive (Naiwny Sezon)	1.000	3.904
Holt Standardowy	0.341	4.459
RWF (Dryf)	0.345	4.488
TSLM (Trend^2 + Sezon)	0.425	5.220
TSLM (Trend Liniowy)	0.543	7.192

Model ETS (1.006) okazał się zauważalnie lepszy od modelu manualnego ARIMA (1.170) i drastycznie lepszy od modelu ARIMA automatycznego (2.520), która radzi sobie gorzej niż proste metody naiwne.

2.5 Wnioski Końcowe

Na podstawie przeprowadzonej analizy diagnostycznej oraz rankingu dokładności prognoz, podejście oparte na zaawansowanym wygładzaniu wykładniczym (rodzina modeli ETS / Holt-Winters) okazało się najbardziej adekwatne dla szeregu czasowego *euretail*.

1. Zwycięzca - ETS Auto / HW Addytywny: Modelem najlepszym do prognozowania indeksu handlu detalicznego jest ETS(A,A,A).

- Dokładność: Model ten osiągnął najlepsze wyniki spośród wszystkich modeli uwzględniających dynamikę szeregu, notując RMSE na poziomie 1.184 oraz MAPE wynoszące zaledwie 1.14%. Oznacza to wysoką precyzję prognoz na zbiorze testowym.
- Model skutecznie wyeliminował autokorelację reszt
- Model charakteryzuje się niskim błędem zarówno na zbiorze uczącym (0.373), jak i testowym, co świadczy o braku przeuczenia.

2. Przewaga nad podejściem ARIMA: Mimo że ręcznie dobierane modele ARIMA (np. ARIMA(0,2,5)(0,1,0)) przeszły poprawnie testy diagnostyczne, ich zdolność prognostyczna okazała się gorsza od modeli wykładniczych. Błąd RMSE dla najlepszego modelu ARIMA (Manual) wyniósł 1.668, co jest wynikiem wyraźnie słabszym od ETS. Automatyczny dobór ARIMA całkowicie zawiódł na zbiorze testowym.

3. Modele oparte na sztywnym trendzie deterministycznym (TSLM) oraz proste modele wygładzania (SES, Holt Standard) okazały się nieadekwatne dla tego szeregu. Generowały one błędy wielokrotnie wyższe (RMSE > 4.4) i nie potrafiły poprawnie uchwycić złożonej struktury sezonowości połączonej ze zmiennym trendem.

4. Choć model Średniej uzyskał najniższy błąd na zbiorze testowym (RMSE 1.162), wynik ten należy uznać za anomalię statystyczną wynikającą ze specyfiki okresu testowego, a nie za dowód jakości modelu. Gigantyczny błąd na zbiorze uczącym oraz brak mechanizmu modelowania trendu i sezonowości dyskwalifikują to podejście w zastosowaniach praktycznych.

Konkluzja: Optymalnym wyborem jest model ETS(A,A,A). Zapewnia on najlepszy kompromis między złożonością a dokładnością, doskonale radzi sobie z sezonowością występującą w danych handlowych i generuje wiarygodne statystycznie prognozy.